

Chapitre 3: Méthodes d'estimation

Rabah Messaci

Département de Probabilités-Statistique
USTHB

Octobre 2011

Introduction

Pour certaines quantités, moments, variances, covariances, probabilités il a été vu qu'il existe des estimateurs simples ayant de bonnes qualités : sans biais et convergents. Pour des paramètres quelconques, il est nécessaire d'avoir des méthodes d'estimation conduisant à des estimateurs de bonne qualité. Il existe plusieurs grandes méthodes d'estimation

- Méthode des moments
- Méthode du maximum de vraisemblance
- Recherche des estimateurs sans biais de variance minimale

Autres méthodes - estimation par les moindres carrés qui sera utilisée dans le contexte de la régression linéaire - estimation bayésienne qui ne sera pas abordée ici

Méthode des moments : exemples

Les moments empiriques sont des estimateurs sans biais et convergents des moments théoriques. La méthode des moments consiste à évaluer les uns aux autres. Soit le modèle d'échantillon $(\mathcal{X}, \mathcal{B}, (\mathcal{P}_\theta)_{\theta \in \Theta})^{(n)}$ associé à n observations (x_1, x_2, \dots, x_n) d'une v.a de loi P_θ .

On suppose $\theta = (\theta_1, \theta_2, \dots, \theta_p)$. On veut estimer θ i.e p paramètres.

$$E(X) = \overline{X_n} = \frac{\sum_{i=1}^n X_i}{n}$$

$$E(X^2) = \frac{\sum_{i=1}^n X_i^2}{n}$$

.....

$$E(X^p) = \frac{\sum_{i=1}^n X_i^p}{n} :$$

Méthode des moments

Exemples :

- Soit le modèle d'échantillon poissonien $(N, \mathcal{P}(N), \{P(\lambda), \lambda \in \mathbb{R}_+^*\})^{(n)}$ associé à n observations (x_1, x_2, \dots, x_n) d'une v.a de loi $P(\lambda)$.

Estimer λ par la méthode des moments.

$$E(X) = \lambda = \bar{x} \implies \hat{\lambda} = \bar{x}$$

- Soit le modèle d'échantillon gaussien $(R, \mathcal{P}(R), \{N(m, \sigma^2), m \in R\})^{(n)}$. On suppose σ^2 connu.

Estimer m .

$$E(X) = m = \bar{x} \implies \hat{m} = \bar{x}$$

- Soit le modèle d'échantillon gaussien $(R, \mathcal{P}(R), \{N(m, \sigma^2), m \in R\})^{(n)}$

Estimer m et σ^2

$$E(X) = m = \bar{x}$$

$$E(X^2) = \sigma^2 + m^2 = m_2 \implies$$

$$\hat{m} = \bar{x} \text{ et } \hat{\sigma}^2 = m_2 - \bar{x}^2 = S_n^2$$

Méthode du maximum de vraisemblance

Considérons une pièce de monnaie pour laquelle la probabilité d'obtenir pile est inconnue. Cette pièce est lancée 10 fois et on obtient 6 piles. Une méthode d'estimation intuitive est de considérer que l'évènement réalisée, ici 6 piles et 4 faces, a une forte probabilité (puiqu'il s'est réalisé contrairement aux autres). On estime alors p par la valeur \hat{p} de $[0,1]$ qui attribue à cet évènement, la plus forte probabilité, ou en d'autres termes par la valeur \hat{p} qui maximise la vraisemblance.

On a $L(p, \tilde{x}) = p^6(1 - p)^4$

$$\frac{\partial}{\partial p} L(p, \tilde{x}) = 0 \iff \frac{\partial}{\partial p} \log L(p, \tilde{x}) = 0$$

$$\iff \hat{p} = \frac{6}{10}$$

Méthode du maximum de vraisemblance

Définition : Estimateurs du maximum de vraisemblance

Soit $\tilde{x} = (x_1, x_2, \dots, x_n)$ un n -échantillon d'une v.a X de loi $(f_\theta)_{\theta \in \Theta}$. On appelle estimateur du maximum de vraisemblance de θ , s'il existe, la statistique $\hat{\theta}$ telle que

$$L(\hat{\theta}, \tilde{x}) = \max_{\theta \in \Theta} L(\theta, \tilde{x})$$

La maximisation de la fonction de vraisemblance peut se faire de différentes manières

Méthode du maximum de vraisemblance

Cas 1 : θ réel et $L(\theta, \tilde{x})$ dérivable par rapport à θ

$\hat{\theta}$ est alors solution du système d'équations dit équations du maximum de vraisemblance

$$\begin{cases} \frac{\partial}{\partial \theta} L(\theta, \tilde{x}) = 0 : \text{condition du 1}^{er} \text{ ordre} \\ \frac{\partial^2}{\partial \theta^2} L(\theta, \tilde{x}) < 0 : \text{condition du 2}^{ème} \text{ ordre} \end{cases}$$
$$\iff \begin{cases} \frac{\partial}{\partial \theta} \log L(\theta, \tilde{x}) = 0 : \text{condition du 1}^{er} \text{ ordre} \\ \frac{\partial^2}{\partial \theta^2} \log L(\theta, \tilde{x}) < 0 : \text{condition du 2}^{ème} \text{ ordre} \end{cases}$$

Car la fonction log est continue et strictement monotone.

Méthode du maximum de vraisemblance

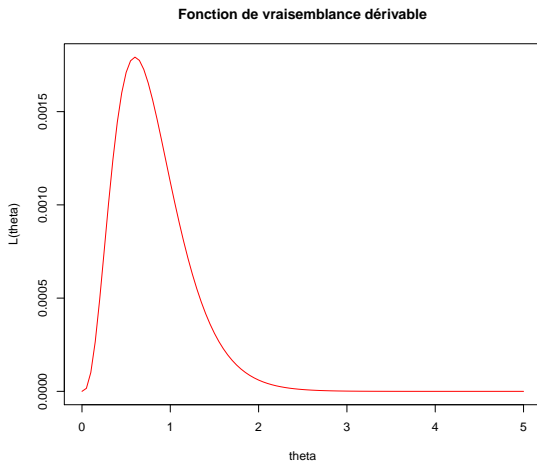


FIGURE: Fonction de vraisemblance

Méthode du maximum de vraisemblance




FIGURE: Fonction de log-vraisemblance

Méthode du maximum de vraisemblance

Cas 2 : θ réel et $L(\theta, \tilde{x})$ non dérivable par rapport à θ

Il faut maximiser la vraisemblance directement

Cas 3 : $\theta = (\theta_1, \theta_2, \dots, \theta_p)$ vectoriel et $L(\theta, \tilde{x})$ dérivable par rapport à θ

$$\left\{ \begin{array}{l} \frac{\partial}{\partial \theta_1} \log L(\theta, \tilde{x}) = 0 \\ \frac{\partial}{\partial \theta_2} \log L(\theta, \tilde{x}) = 0 \\ \dots \\ \frac{\partial}{\partial \theta_p} \log L(\theta, \tilde{x}) = 0 \end{array} \right. \quad \text{conditions du 1}^{\text{er}} \text{ ordre}$$

La condition du 2^{ème} ordre s'exprime à l'aide de la matrice Hessienne qui doit être définie négative.

Méthode du maximum de vraisemblance

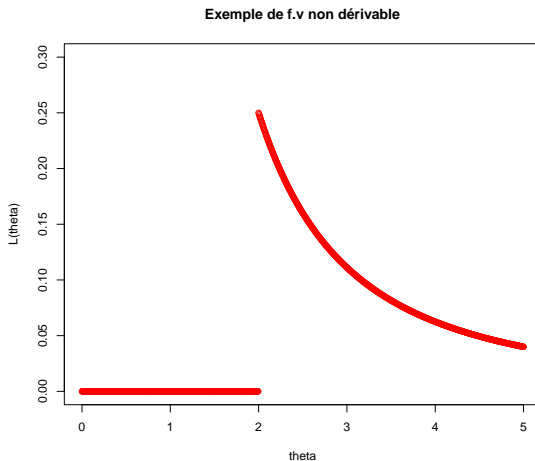


FIGURE: Fonction de vraisemblance

Méthode du maximum de vraisemblance

Théorème

Soit $\tilde{x} = (x_1, x_2, \dots, x_n)$ un n -échantillon d'une v.a X de loi $(f_\theta)_{\theta \in \Theta}$.

S'il existe une statistique exhaustive T pour θ alors l'estimateur du maximum de vraisemblance de θ est fonction de T .

Conséquence du théorème de factorisation

Théorème : invariance fonctionnelle

Soit $\hat{\theta}$ l'estimateur du maximum de vraisemblance de θ alors l'estimateur du maximum de vraisemblance de $g(\theta)$ est $g(\hat{\theta})$ pour toute fonction g .

Risque quadratique

Définition : Risque quadratique

Soit T un estimateur de $g(\theta)$

On appelle risque quadratique de l'estimateur T , l'erreur quadratique moyenne de T , i.e

$$R_{\theta}(T) = E_{\theta}((T(X) - g(\theta))^2)$$

Proposition

On a

$$R_{\theta}(T) = E_{\theta}((T(X) - E_{\theta}(T(X)))^2 + (E_{\theta}(T(X)) - g(\theta))^2)$$

i.e

$$R_{\theta}(T) = \text{Var}(T) + \text{biais}(T)^2$$

Risque quadratique

Définition

Un estimateur T_1 est dit meilleur qu'un autre estimateur T_2 au sens du risque quadratique si

$$R_{\theta}(T_1) \leq R_{\theta}(T_2) \quad \forall \theta \in \Theta$$

(uniformément en θ)

Proposition

Parmi tous les estimateurs sans biais le meilleur au sens du risque quadratique est celui qui a la plus petite variance.

$$\text{Var}_{\theta}(T_1) \leq \text{Var}_{\theta}(T_2) \quad \forall \theta \in \Theta$$

pour tout T_2 autre estimateur sans biais.

Si un tel estimateur existe, il est alors dit estimateur sans biais de variance minimale (ou uniformément minimale) : ESBVUM.

Estimation sans biais

amélioration d'un estimateur

Soit T un estimateur sans biais de $g(\theta)$ et S une statistique exhaustive pour θ .
Alors

- 1) $E_{\theta}(T/S)$ est un estimateur sans biais de $g(\theta)$
- 2) $Var_{\theta}(E_{\theta}(T/S)) \leq Var_{\theta}(T)$

Conclusion : $E_{\theta}(T/S)$ est un meilleur estimateur sans biais de $g(\theta)$

Estimation sans biais

Démonstration :

$E_{\theta}(T/S)$ est un estimateur de $g(\theta)$ car ne dépend pas de θ .

$$1) E_{\theta}(E_{\theta}(T/S)) = E_{\theta}(T) = g(\theta)$$

(Théorème de l'espérance conditionnelle)

$$2) \text{Var}_{\theta}(T) = \text{Var}_{\theta}(E_{\theta}(T/S)) + E_{\theta}(\text{Var}_{\theta}(T/S))$$

(Théorème de la variance conditionnelle)

$$\implies \text{Var}_{\theta}(E_{\theta}(T/S)) = \text{Var}_{\theta}(T) - E_{\theta}(\text{Var}_{\theta}(T/S)) \leq \text{Var}_{\theta}(T)$$

Remarque : Si $T = h(S)$ alors $E_{\theta}(h(S)/S) = h(S) = T$

Dans ce cas il n'y a pas d'amélioration.

Estimation sans biais

Théorème de Lehmann-Scheffé

Soit T un estimateur sans biais de $g(\theta)$ et S une statistique exhaustive et complète pour θ . Alors

$E_{\theta}(T/S)$ est l'unique estimateur sans biais de $g(\theta)$ dit estimateur sans biais de variance uniformément minimale (ESBVUM)

Démonstration

Estimation sans biais

Théorème de Rao-Cramer

Soit T un estimateur sans biais de $g(\theta)$. On suppose les conditions de régularité de Fischer vérifiées, alors

$$\text{Var}_{\theta}(T) \geq \frac{(g'(\theta))^2}{I(\theta)}$$

La quantité $\frac{(g'(\theta))^2}{I(\theta)}$ est dite borne de Rao-Cramer (*BRC*)

$$\text{Var}_{\theta}(T) = \frac{(g'(\theta))^2}{I(\theta)}$$

Estimation sans biais

Démonstration : Rappel :

$$|\rho_{X,Y}| = \left| \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} \right| \leq 1 \implies \text{Cov}(X,Y)^2 \leq \sigma_X^2 \sigma_Y^2$$

$$E_\theta(T(X)) = \int_{\mathcal{X}} T(x) f_\theta(x) dx = \int_{\mathcal{X}} T(x) L(\theta, x) dx = g(\theta) \implies$$

$$\frac{\partial}{\partial \theta}(E_\theta(T(X))) = \int_{\mathcal{X}} T(x) \frac{\partial}{\partial \theta}(L(\theta, x)) dx = g'(\theta)$$

$$= \int_{\mathcal{X}} T(x) \frac{\partial}{\partial \theta}(\log L(\theta, x)) L(\theta, x) dx = \text{Cov}(T(X), \frac{\partial}{\partial \theta}(\log L(\theta, X)))$$

$$\implies \text{Cov}^2(T(X), \frac{\partial}{\partial \theta}(\log L(\theta, X))) \leq \text{Var}_\theta(T(X)) \text{Var}(\frac{\partial}{\partial \theta}(\log L(\theta, X)))$$

$$\implies \text{Var}_\theta(T(X)) \geq \frac{\text{Cov}^2(T(X), \frac{\partial}{\partial \theta}(\log L(\theta, X)))}{\text{Var}(\frac{\partial}{\partial \theta}(\log L(\theta, X)))} = \frac{g'(\theta)^2}{I(\theta)}$$

Estimation sans biais

Cas particulier : $g(\theta) = \theta$

$$BCR = \frac{1}{I(\theta)}$$

Remarque :

$$\text{Pour que } \text{Var}_{\theta}(T(X)) \geq \frac{\text{Cov}^2(T(X), \frac{\partial}{\partial \theta}(\log L(\theta, X)))}{\text{Var}(\frac{\partial}{\partial \theta}(\log L(\theta, X)))} = \frac{g'(\theta)^2}{I(\theta)}$$

Il est nécessaire et suffisant que $\frac{\partial}{\partial \theta}(\log L(\theta, X)) = k(\theta)T(X) + l(\theta)$

$$\implies E_{\theta}(\frac{\partial}{\partial \theta}(\log L(\theta, X))) = k(\theta)E_{\theta}(T(X)) + l(\theta)$$

$$\implies E_{\theta}(T(X)) = g(\theta) = -\frac{l(\theta)}{k(\theta)}$$

$$\iff \frac{\partial}{\partial \theta}(\log L(\theta, X)) = k(\theta)(T(X) - g(\theta))$$

Estimation sans biais

Définition : estimateur efficace

Un estimateur sans biais T de $g(\theta)$ est dit efficace si

$$\text{Var}_{\theta}(T) = \frac{(g'(\theta))^2}{I(\theta)}$$

Information de Fischer : cas vectoriel

Cas d'un paramètre vectoriel $\theta = (\theta_1, \theta_2, \dots, \theta_p)$

L'information de Fischer est alors donnée par la matrice des variances-covariances

$$\mathcal{I}(\theta) = \mathcal{V}(\text{Grad} \log L(\theta, X))$$

$$\text{du vecteur } \text{Grad} \log L(\theta, X) = \begin{cases} \frac{\partial}{\partial \theta_1} \log L(\theta, X) \\ \frac{\partial}{\partial \theta_2} \log L(\theta, X) \\ \vdots \\ \frac{\partial}{\partial \theta_p} \log L(\theta, X) \end{cases}$$

Comme pour le cas réel on peut montrer que

$$\mathcal{I}(\theta) = -\left(E\left(\frac{\partial}{\partial \theta_i} \frac{\partial}{\partial \theta_j} \log L(\theta, X)\right)\right)_{1 \leq i \leq p, 1 \leq j \leq p},$$

Information de Fischer : cas vectoriel

Exemple

Soit x une observation de $X \sim N(m, \sigma^2)$

$$\mathcal{I}(m, \sigma^2) = - \begin{pmatrix} E\left(\frac{\partial^2}{\partial m^2} \log L(\theta, X)\right) & E\left(\frac{\partial}{\partial m} \frac{\partial}{\partial \sigma^2} \log L(\theta, X)\right) \\ E\left(\frac{\partial}{\partial m} \frac{\partial}{\partial \sigma^2} \log L(\theta, X)\right) & E\left(\frac{\partial^2}{\partial (\sigma^2)^2} \log L(\theta, X)\right) \end{pmatrix}$$

$$\mathcal{I}(m, \sigma^2) = - \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2\sigma^4} \end{pmatrix}$$

Théorème de Rao-Cramer : cas vectoriel

Soit deux matrices définies positives A et B , on dit que $A \geq B$ si

$$Q_A(x) = x^t A x \geq Q_B(x) = x^t B x$$

On rappelle que les matrices de variances-covariances sont définies positives.

Théorème de Rao-Cramer : cas vectoriel

Soit T un estimateur sans biais de $g(\theta)$ (à valeurs dans R^p). On suppose les conditions de régularité de Fischer vérifiées, alors

$$\mathcal{V}_\theta(T) \geq \text{Grad}(g(\theta))^t \mathcal{I}(\theta)^{-1} \text{Grad}(g(\theta))$$

$\mathcal{V}_\theta(T)$ est la matrice de variances-covariances de T .