

# Chapitre 4: Estimation par régions de confiance

Rabah Messaci

Département de Probabilités-Statistique  
USTHB

Novembre 2011

# Propriétés asymptotiques des EMV

Les estimateurs du maximum de vraisemblance n'ont pas de propriétés connus pour des échantillons de taille finie (sauf la propriété d'invariance fonctionnelle).

Cependant ils ont de très bonnes propriétés asymptotiques.

## Théorème

Soit  $\hat{\theta}_n$  l'EMV de  $\theta$  basé sur un  $n$ -échantillon et  $I_n(\theta)$  l'information de Fischer ramenée par les observations sur  $\theta$ . (On suppose les conditions de régularité de Fischer vérifiées). On a

$$\frac{\hat{\theta}_n - \theta}{\sqrt{\frac{1}{I_n(\theta)}}} \xrightarrow[n \rightarrow +\infty]{Loi} \mathcal{X}$$

## Théorème

Soit  $g$  une fonction dérivable et  $g(\hat{\theta})$  l'EMV de  $g(\theta)$  On a sous les hypothèses du théorème précédent

$$\frac{\widehat{g(\theta_n)} - g(\theta)}{\sqrt{\frac{g'(\theta)^2}{I_n(\theta)}}} \xrightarrow[n \rightarrow +\infty]{Loi} \mathcal{X}$$

Les estimateurs du maximum de vraisemblance sont donc asymptotiquement gaussiens, asymptotiquement sans biais et asymptotiquement efficaces.

## Théorème

Soit  $g$  une fonction dérivable et  $g(\hat{\theta})$  l'EMV de  $g(\theta)$  On a sous les hypothèses du théorème précédent

$$\frac{\widehat{g(\theta_n)} - g(\theta)}{\sqrt{\frac{g'(\theta)^2}{I_n(\theta)}}} \xrightarrow[n \rightarrow +\infty]{Loi} \mathcal{X}$$

Les estimateurs du maximum de vraisemblance sont donc asymptotiquement gaussiens, asymptotiquement sans biais et asymptotiquement efficaces. On a si  $n$  est grand

$$\hat{\theta}_n \approx N\left(\theta, \frac{1}{I_n(\theta)}\right)$$

et

$$g(\hat{\theta}_n) \approx N\left(g(\theta), \frac{g'(\theta)^2}{I_n(\theta)}\right)$$

## Théorème

Soit  $g$  une fonction dérivable et  $g(\hat{\theta})$  l'EMV de  $g(\theta)$  On a sous les hypothèses du théorème précédent

$$\frac{\widehat{g(\theta_n)} - g(\theta)}{\sqrt{\frac{g'(\theta)^2}{I_n(\theta)}}} \xrightarrow[n \rightarrow +\infty]{Loi} \mathcal{X}$$

Les estimateurs du maximum de vraisemblance sont donc asymptotiquement gaussiens, asymptotiquement sans biais et asymptotiquement efficaces. On a si  $n$  est grand

$$\hat{\theta}_n \approx N\left(\theta, \frac{1}{I_n(\theta)}\right)$$

et

$$g(\hat{\theta}_n) \approx N\left(g(\theta), \frac{g'(\theta)^2}{I_n(\theta)}\right)$$

# Propriétés asymptotiques des EMV

Pour les applications le fait que la variance soit inconnue (dépend de  $\theta$ ) est gênant. On a cependant les théorèmes suivants obtenus en remplaçant la variance par la variance estimée.

## Théorème

On a sous certaines hypothèses de régularité

$$\frac{\hat{\theta}_n - \theta}{\sqrt{\frac{1}{I_n(\hat{\theta}_n)}}} \xrightarrow[n \rightarrow +\infty]{Loi} \mathcal{N}$$

## Théorème

On a sous certaines hypothèses de régularité

$$\frac{\widehat{g(\theta_n)} - g(\theta)}{\sqrt{\frac{g'(\hat{\theta}_n)^2}{I_n(\hat{\theta}_n)}}} \xrightarrow[n \rightarrow +\infty]{Loi} \mathcal{N}$$

On peut alors écrire si  $n$  est grand

$$\hat{\theta}_n \approx N\left(\theta, \frac{1}{I_n(\hat{\theta}_n)}\right)$$

et

$$g(\hat{\theta}_n) \approx N\left(g(\theta), \frac{g'(\hat{\theta}_n)^2}{I_n(\hat{\theta}_n)}\right)$$

Estimer poctuellement un paramètre  $\theta$ , c'est lui associer une valeur  $\hat{\theta}(X_1, ..X_n)$  qui est censée l'approcher correctement. En statistique cette valeur est fonction des observations. Cette estimation se fait toujours avec une erreur. En physique, les mesures effectuées le sont toujours avec erreurs, chaque mesure  $m$  est accompagnée d'un intervalle de la forme  $[m - \Delta m, m + \Delta m]$ ,  $\Delta m$  étant l'erreur absolue de mesure. En statistique on fait accompagner chaque estimation d'une région  $C_\alpha(X_1, ..X_n)$  (dépendant des observations) ayant une forte probabilité de contenir la vraie valeur inconnue du paramètre.



## Définition : Région de confiance

Soit  $X_1, \dots, X_n$  un n-échantillon d'une v.a  $X$  de loi  $P_\theta, \theta \in \Theta$ .

On appelle région de confiance de niveau  $1 - \alpha$ , ( $0 \leq \alpha \leq 1$ ) pour  $\theta$  une région  $C_\alpha(X_1, \dots, X_n) \subset \Theta$  telle que

$$P_\theta(\theta \in C_\alpha(X_1, \dots, X_n)) = 1 - \alpha \quad \forall \theta \in \Theta$$

## Définition : Région de confiance

Soit  $X_1, \dots, X_n$  un n-échantillon d'une v.a  $X$  de loi  $P_\theta, \theta \in \Theta$ .

On appelle région de confiance de niveau  $1 - \alpha$ , ( $0 \leq \alpha \leq 1$ ) pour  $\theta$  une région  $C_\alpha(X_1, \dots, X_n) \subset \Theta$  telle que

$$P_\theta(\theta \in C_\alpha(X_1, \dots, X_n)) = 1 - \alpha \quad \forall \theta \in \Theta$$

Notation : Pour simplifier l'écriture on notera plus simplement la région  $C_\alpha$  au lieu de  $C_\alpha(X_1, \dots, X_n)$

## Définition : Région de confiance

Soit  $X_1, \dots, X_n$  un n-échantillon d'une v.a  $X$  de loi  $P_\theta, \theta \in \Theta$ .

On appelle région de confiance de niveau  $1 - \alpha$ , ( $0 \leq \alpha \leq 1$ ) pour  $\theta$  une région  $C_\alpha(X_1, \dots, X_n) \subset \Theta$  telle que

$$P_\theta(\theta \in C_\alpha(X_1, \dots, X_n)) = 1 - \alpha \quad \forall \theta \in \Theta$$

Notation : Pour simplifier l'écriture on notera plus simplement la région  $C_\alpha$  au lieu de  $C_\alpha(X_1, \dots, X_n)$

## Définition : Région de confiance asymptotique

On appelle région de confiance de niveau asymptotique  $1 - \alpha$ , ( $0 \leq \alpha \leq 1$ ) une région  $C_{n,\alpha} \subset \Theta$  telle que

$$\lim_{n \rightarrow +\infty} P_\theta(\theta \in C_{n,\alpha}) = 1 - \alpha \quad \forall \theta \in \Theta$$

Interprétation :

La région de confiance  $C_\alpha$  est telle qu'elle contient la vraie valeur du paramètre avec une probabilité  $1 - \alpha$ . C'est le niveau de confiance qu'on accorde à l'intervalle. Il n'y a donc qu'une probabilité  $\alpha$  qu'elle ne la contienne pas.

Interprétation :

La région de confiance  $C_\alpha$  est telle qu'elle contient la vraie valeur du paramètre avec une probabilité  $1 - \alpha$ . C'est le niveau de confiance qu'on accorde à l'intervalle. Il n'y a donc qu'une probabilité  $\alpha$  qu'elle ne la contienne pas. C'est l'erreur. Généralement les valeurs de  $\alpha$  sont prises égales à 0.05, 0.02, 0.01 ect... Les régions de confiance sont alors généralement de niveau 95%, 98%, 99% ect..

Interprétation :

La région de confiance  $C_\alpha$  est telle qu'elle contient la vraie valeur du paramètre avec une probabilité  $1 - \alpha$ . C'est le niveau de confiance qu'on accorde à l'intervalle. Il n'y a donc qu'une probabilité  $\alpha$  qu'elle ne la contienne pas. C'est l'erreur. Généralement les valeurs de  $\alpha$  sont prises égales à 0.05, 0.02, 0.01 ect... Les régions de confiance sont alors généralement de niveau 95%, 98%, 99% ect.. Lorsque  $\Theta \subset R$  on choisit souvent des intervalles : on parle alors d'intervalles de confiance  $I_\alpha$  et ils sont tels que :

$$P_\theta(\theta \in [a(X_1, \dots, X_n), b(X_1, \dots, X_n)]) = 1 - \alpha \quad \forall \theta \in \Theta$$

Une technique très utile pour la détermination de régions de confiance se base sur les fonctions pivotales.

Une technique très utile pour la détermination de régions de confiance se base sur les fonctions pivotales.

## Définition : Fonctions pivotales

Une variable aléatoire  $g(\theta, T(\tilde{X}))$  est dite fonction pivotale pour  $\theta$  si sa loi est indépendante de  $\theta$ .



Une technique très utile pour la détermination de régions de confiance se base sur les fonctions pivotales.

## Définition : Fonctions pivotales

Une variable aléatoire  $g(\theta, T(\tilde{X}))$  est dite fonction pivotale pour  $\theta$  si sa loi est indépendante de  $\theta$ .

Application à la détermination des intervalles de confiance

On veut déterminer  $a$  et  $b$  telles que  $P_{\theta}(a \leq \theta \leq b) = 1 - \alpha$

$$P_{\theta}(a' \leq g(\theta, T(\tilde{X})) \leq b') = 1 - \alpha$$

$$P_{\theta}(h_1(a', T(\tilde{X})) \leq \theta \leq h_2(b', T(\tilde{X}))) = 1 - \alpha$$

Point important :  $a'$  et  $b'$  ne dépendent pas de  $\theta$ , car  $g$  fonction pivotale

## Exemples : Fonctions pivotaes

- $X \sim N(m, \sigma^2) : \frac{X - m}{\sigma} \sim N(0, 1)$

## Exemples : Fonctions pivotales

- $X \sim N(m, \sigma^2) : \frac{X - m}{\sigma} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$

## Exemples : Fonctions pivotales

- $X \sim N(m, \sigma^2) : \frac{X - m}{\sigma} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{s}{\sqrt{n}}} \sim St_{n-1}$

## Exemples : Fonctions pivotaes

- $X \sim N(m, \sigma^2) : \frac{X - m}{\sigma} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{s}{\sqrt{n}}} \sim St_{n-1}$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \sum_{i=1}^n \frac{(X_i - m)^2}{\sigma^2} \sim \chi_n^2$

## Exemples : Fonctions pivotales

- $X \sim N(m, \sigma^2) : \frac{X - m}{\sigma} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \frac{\bar{X} - m}{\frac{s}{\sqrt{n}}} \sim St_{n-1}$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \sum_{i=1}^n \frac{(X_i - m)^2}{\sigma^2} \sim \chi_n^2$
- $(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m, \sigma^2) : \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1}^2$

## Exemples : Fonctions pivotales

$(X_1, X_2, \dots, X_n)$  échantillon de  $X \sim N(m_1, \sigma_1^2)$ ,  $(Y_1, Y_2, \dots, Y_p)$

échantillon de  $Y \sim N(m_2, \sigma_2^2)$

X et Y indépendantes

$$\frac{p}{n} \frac{\sum_{i=1}^n \frac{(X_i - m_1)^2}{\sigma_1^2}}{\sum_{i=1}^p \frac{(Y_i - m_2)^2}{\sigma_2^2}} \sim F_{(n,p)}$$

$$\frac{p-1}{n-1} \frac{\sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma_1^2}}{\sum_{i=1}^p \frac{(Y_i - \bar{Y})^2}{\sigma_2^2}} \sim F_{(n-1,p-1)}$$

# Tests d'hypothèses bilatères

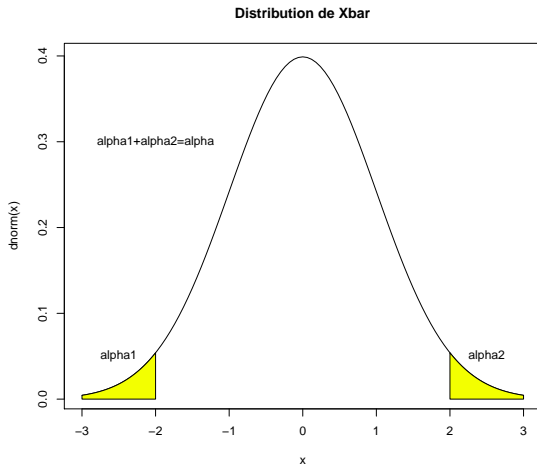


FIGURE: Région critique 3