

Exercice 1 Soient les variables aléatoires indépendantes et de Bernoulli X_1, \dots, X_n . Nous avons donc, pour tout $i = 1, \dots, n$, $P[X_i = 1] = p$ et $P[X_i = 0] = 1 - p$.

1. Montrez que $T = \sum_{i=1}^n X_i$ est une statistique exhaustive pour le paramètre p .

2. Pour $n = 3$, la statistique $\tilde{T} = e^{X_1+X_2+X_3}$ est-elle aussi exhaustive ? Même question pour $S = X_1 + 2X_2 + X_3$.

Exercice 2 Soient les variables aléatoires X_1, \dots, X_n i.i.d. $\mathcal{P}(\lambda)$. Montrez que $T = \sum_{i=1}^n X_i$ est une statistique exhaustive pour le paramètre λ .

Exercice 3 Soit X_1, \dots, X_n un échantillon aléatoire simple issu d'une population de densité $f(x) = \theta x^{\theta-1}$ si $0 < x < 1$ et 0 sinon où $\theta > 0$. Déterminez une statistique exhaustive pour le paramètre.

Exercice 4 Soient les variables aléatoires X_1, \dots, X_n iid $\mathcal{U}[\theta - 1/2, \theta + 1/2]$. Déterminez une statistique exhaustive pour le paramètre.

Exercice 5 Soit X_1, \dots, X_n un échantillon aléatoire simple issu d'une population de densité $f(x) = \theta e^{\theta-x}$ si $x > \theta$ et 0 sinon où $\theta > 0$. Déterminez une statistique exhaustive pour le paramètre θ .

Exercice 6 Les éléments d'une population possèdent un caractère X qui suit une loi de probabilité dont la densité est $f(x) = 2\theta x e^{-\theta x^2}$ si $0 < x < \theta$ et 0 sinon où $\theta > 0$. Une suite de n expériences indépendantes a donné les valeurs x_1, \dots, x_n .

1. Montrez que l'estimateur $\tilde{T} = n / \sum_{i=1}^n X_i^2$ est une statistique exhaustive pour le paramètre θ .

2. Ecrire la fonction de répartition Y en posant $y = \theta x^2$ ainsi que la fonction de densité de Y . Déduire la loi de $Z = \sum_{i=1}^n Y_i$.

3. Etudier la convergence de \tilde{T} .

Exercice 7 Soit X une v.a de loi $\mathcal{N}(\theta_1, \theta_2)$ et Y une v.a de loi $\mathcal{N}(\theta_3, \theta_4)$. On suppose que X et Y sont indépendantes. On dispose d'un n -échantillon de (X, Y) .

1. Déterminer une statistique exhaustive et complète lorsque $\theta_1, \theta_2, \theta_3, \theta_4$ sont inconnus.

2. Déterminer une statistique exhaustive lorsque $\theta_1 = \theta_3$. Montrer qu'elle n'est pas complète.

3. On suppose $\theta_2 = \theta_4$. Existe-t-il une statistique exhaustive et complète ?

Exercice 8 Cas gaussien,

1. Montrer que $a(\underline{x}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$ est exhaustive pour (m, σ^2) .
2. En déduire que $a(\underline{x})$ est une statistique complète.

Exercice 9 Ecrire la vraisemblance et déterminer une statistique exhaustive pour un échantillon de n observations i.i.d. de lois :

- 1) loi de Poisson de paramètre λ : $P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$; $k \in \mathbb{N}^*$
- 2) loi de Pareto de paramètres α et θ avec $\alpha > 1$, $\theta > 0$ de densité : $f(x) = \frac{\alpha-1}{\theta} \left(\frac{x}{\theta}\right)^{\alpha} 1_{[0,+\infty]}(x)$.
- 3) loi de Weibull de paramètre α et θ avec $\alpha > 0$, $\theta > 0$ de densité : $f(x) = \alpha \theta x^{\alpha-1} e^{-\theta x^{\alpha}} 1_{[0,+\infty]}(x)$.

Exercice 10 Calculer l'information de Fisher dans les modèles statistiques suivants :

- 1) une loi de Poisson de paramètre : $P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$; $k \in \mathbb{N}^*$
- 2) une loi de Pareto de paramètres α et θ avec $\alpha > 0$, $\theta > 0$ de densité : $f(x) = \alpha \theta x^{\alpha-1} e^{-\theta x^{\alpha}} 1_{[0,+\infty]}(x)$.
- 3) une loi de Weibull de α et θ avec $\alpha > 0$, $\theta > 0$ de densité : $f(x) = \alpha \theta x^{\alpha-1} e^{-\theta x^{\alpha}} 1_{[0,+\infty]}(x)$.
- 4) loi uniforme sur $[0, \theta]$ avec $\theta > 0$ inconnu.

Exercice 11 On étudie une variable aléatoire X , de densité $f(., \theta)$.

- 1) Quelle est la fonction score du modèle, notée $S(X, \theta)$? Donner l'expression de l'information de Fisher $I_X(\theta)$.

- 2) En fait, on ne parvient pas à observer X , mais seulement Y définie par :

$$Y = \begin{cases} 1 & \text{si } X \geq s \\ 0 & \text{si } X < s \end{cases} \quad \text{où } s \text{ est un seuil connu.}$$

On suppose que l'on peut intervertir l'intégrale et la dérivée. Donner la fonction score du modèle, notée $S_Y(y, \theta)$. En déduire que $S_Y(y, \theta) = E(S(X, \theta) | Y = y)$

- 3) En déduire alors que $I_X(\theta) \gg I_Y(\theta)$, où $I_Y(\theta)$ est l'information de Fisher associée à Y (l'inégalité s'entend au sens des matrices symétriques). Quelle interprétation pouvez-vous donner à l'inégalité ci-dessus ?

Exercice 12 1) Calculer l'estimateur du maximum de vraisemblance (e.m.v.) \hat{p} de p dans le modèle X_i iid et suivent la loi $B(1, p)$ et calculer la loi limite de $\sqrt{n}(\hat{p} - p)$.

- 2) Calculer l'e.m.v. $(\hat{m}, \hat{\sigma}^2)$ de (m, σ^2) dans le modèle X_i iid et suivent la loi $\mathcal{N}(m, \sigma^2)$ et donner la loi limite du vecteur $\sqrt{n} \begin{pmatrix} \hat{m} - m \\ \hat{\sigma}^2 - \sigma^2 \end{pmatrix}$

Exercice 13 Soit $x = (x_1, x_2, \dots, x_n)$ n -échantillon de $X \sim U[0, \theta]$

- 1- Montrer que $T_1 = 2\bar{X}$ et $T_2 = \frac{n+1}{n} \max_{1 \leq i \leq n} (X_i)$ sont des estimateurs sans biais de θ .

- 2- Montrer que T_2 est un estimateur sans biais de variance minimale uniformément minimale (ESBVUM).

Corrigé

EXO1

Par définition, une statistique $T(X)$ est exhaustive si

$$P(X = (x_1, \dots, x_n) | T(X) = y)$$

est indépendant de la valeur du paramètre. Calculons donc

$$P(X = (x_1, \dots, x_n) | T(X) = y) = P(X_1 = x_1 \ X_2 = x_2 \dots X_n = x_n | \sum_{i=1}^n X_i = y)$$

$$= \frac{P(X_1 = x_1 \text{ et } X_2 = x_2 \dots X_n = x_n \text{ et } \sum_{i=1}^n X_i = y)}{P(\sum_{i=1}^n X_i = y)} = \frac{P(X_2 = x_2 \dots X_n = x_n \text{ et } X_1 = y - x_2 - \dots - x_n)}{P(\sum_{i=1}^n X_i = y)}$$

Par indépendance, on obtient alors (en se rappelant que la somme de n v.a. de Bernoulli est une binomiale de paramètres (n, p) , pour $x_1 = y - x_2 - \dots - x_n$,

$$P(X = (x_1, \dots, x_n) | T(X) = y) = \frac{P(X_2 = x_2) \dots P(X_n = x_n) P(X_1 = y - x_2 - \dots - x_n)}{P(\sum_{i=1}^n X_i = y)}$$

$$= \frac{p^{x_2} (1-p)^{1-x_2} \dots p^{x_n} (1-p)^{1-x_n} p^{y-x_2-\dots-x_n} (1-p)^{1-(y-x_2-\dots-x_n)}}{\binom{n}{y} p^y (1-p)^{n-y}} = \frac{1}{\binom{n}{y}}$$

Cette quantité est indépendante de p . La statistique $T(X)$ est donc exhaustive. Remarquons que le calcul effectué ci-dessus revient exactement à calculer la vraisemblance conditionnelle et à vérifier que celle-ci ne dépend de p que via une fonction de y (apparaissant dans la condition).

Pour $n = 3$, la statistique \tilde{T} est en bijection avec T . Elle est donc exhaustive. Ce n'est pas le cas de S .

EXO2

On applique ici la même construction qu'à l'exercice précédent...et on obtient (la somme de n v.a. de Poisson de paramètre λ est une v.a. de Poisson de paramètre $n\lambda$) :

$$P(X = (x_1, \dots, x_n) | T(X) = y) = \frac{P(X_2 = x_2) \dots P(X_n = x_n) P(X_1 = y - x_2 - \dots - x_n)}{P(\sum_{i=1}^n X_i = y)}$$

$$= \frac{e^{-\lambda} \lambda^{x_2} (x_2!)^{-1} \dots e^{-\lambda} \lambda^{x_n} (x_n!)^{-1} e^{-\lambda} \lambda^{y-x_2-\dots-x_n} ((y-x_2-\dots-x_n)!)^{-1}}{e^{-n\lambda} \frac{(n\lambda)^y}{y!}}$$

$$= \frac{(x_2!)^{-1} \dots (x_n!)^{-1} ((y-x_2-\dots-x_n)!)^{-1}}{\frac{(n)^y}{y!}}$$

qui est indépendant de la valeur de λ . La statistique est bien exhaustive.

EXO3

La méthode la plus simple pour calculer une statistique exhaustive passe par la condition nécessaire et suffisante. Il faut pour cela calculer la vraisemblance :

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n (\theta x_i^{\theta-1} 1_{(0 < x_i < 1)}) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} \prod_{i=1}^n 1_{(0 < x_i < 1)}$$

$$g_\theta(T(x_1, \dots, x_n)) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1}$$

$$h(x_1, \dots, x_n) = \prod_{i=1}^n 1_{(0 < x_i < 1)}$$

Celle-ci peut s'écrire $g_\theta(T(x_1, \dots, x_n))h(x_1, \dots, x_n)$ pour la statistique (exhaustive donc) : $T = \prod_{i=1}^n X_i$.

EXO4

La fonction de densité de chacune des variables aléatoires est donnée par $f(x) = \frac{1}{\theta} 1_{[\theta-1/2, \theta+1/2]}$.

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n \left(\frac{1}{\theta} 1_{[\theta-1/2 \leq x_i \leq \theta+1/2]} \right) = \left(\frac{1}{\theta^n} 1_{[\theta-1/2 \leq x_{(1)}] 1_{x_{(n)} \leq \theta+1/2]} \right)$$

$$g_\theta(T(x_1, \dots, x_n)) = \frac{1}{\theta^n} 1_{[\theta-1/2 \leq x_{(1)}] 1_{x_{(n)} \leq \theta+1/2]}$$

$$h(x_1, \dots, x_n) = 1$$

Une statistique exhaustive est donnée par

$$T(X) = (X_{(1)}, X_{(n)}).$$

EXO5

La vraisemblance est donnée par

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i) = \prod_{i=1}^n (\theta e^{\theta-x_i} 1_{x_i > \theta}) = \theta^n \prod_{i=1}^n (e^{\theta-x_i} 1_{x_i > \theta}) = \theta^n e^{-\sum_{i=1}^n x_i} e^{n\theta} 1_{x_{(1)} > \theta}$$

$$\text{on pose } h(x) = e^{-\sum_{i=1}^n x_i} \quad \text{et} \quad g_\theta(T(X)) = \theta^n e^{n\theta} 1_{x_{(1)} > \theta}$$

Une statistique exhaustive est donc donnée par $T(X) = X_{(1)}$.

EXO6

1. Le support de la distribution ne dépendant pas du paramètre inconnu θ , nous supposons que tous les x_i sont strictement positifs. Ecrivons la vraisemblance du modèle :

$$L_\theta(X) = (2^n \prod_{i=1}^n x_i) \theta^n e^{-\theta \sum_{i=1}^n x_i^2}$$

Le critère de factorisation nous dit alors que $\sum_{i=1}^n x_i^2$ est une statistique exhaustive pour θ .

Par ailleurs, la fonction $x \rightarrow \frac{n}{x}$ est une fonction bijective sur \mathbb{R}_0^+ , et $\sum_{i=1}^n x_i^2$ est toujours dans \mathbb{R}_0^+ . Etant en bijection avec une statistique exhaustive, la

statistique $\tilde{T} = n / \sum_{i=1}^n X_i^2$ proposée est également exhaustive.

2. Le changement de variable $y = \theta x^2$, ce qui implique $dy = 2\theta x dx$, et donc en écrivant la fonction de répartition :

$P(Y \leq u) = 0$ si $u \leq 0$ et,

$$P(Y \leq u) = P(X \leq \sqrt{\frac{u}{\theta}}) = \int_0^{\sqrt{\frac{u}{\theta}}} 2\theta x e^{-\theta x^2} dx = \int_0^u e^{-y} dy \text{ si } u \geq 0.$$

On constate ainsi que la densité de Y est

$$f(y) = e^{-y} \text{ si } y > 0 \text{ et } 0 \text{ sinon,}$$

soit la densité d'une loi $\Gamma(1, 1)$. Puisque les X_i sont indépendants, les Y_i le sont aussi et grâce aux propriétés de la loi gamma nous savons donc que

$$Z = \sum_{i=1}^n Y_i \sim \Gamma(1, n).$$

3. Pour étudier la convergence de \tilde{T} il faut calculer la variance de cet estimateur :

$$\begin{aligned} E(\tilde{T}) &= E\left(\frac{n\theta}{Z}\right) = \int_{\mathbb{R}} \frac{n\theta}{z} f(z) dz \\ E(\tilde{T}) &= \int_0^{\infty} \frac{n\theta}{\Gamma(n)} z^{n-2} e^{-z} dz. \end{aligned}$$

La présence de z^{n-2} dans l'expression de l'intégrande, par ailleurs fort proche de la densité d'une loi gamma, nous suggère de faire apparaître la densité d'une $\Gamma(1, n-1)$. En utilisant les propriétés de la fonction Γ :

$$E(\tilde{T}) = \frac{n\theta}{n-1} \int_0^{\infty} \frac{1}{\Gamma(n-1)} z^{n-2} e^{-z} dz$$

l'intégrale ci dessus étant simplement l'intégrale d'une densité $\Gamma(1, n-1)$ sur son domaine, elle vaut exactement 1 et par conséquent $E(\tilde{T}) = \frac{n}{n-1}\theta$. On a

$$E(\tilde{T}^2) = \int_0^{\infty} \left(\frac{n\theta}{z}\right)^2 f(z) dz$$

Le raisonnement est le même que pour l'espérance, mais cette fois la puissance de z dans l'intégrale est abaissée de deux unités, et l'on fait donc apparaître la densité d'une loi $\Gamma(1, n-2)$

$$E(\tilde{T}^2) = \frac{n^2\theta^2}{(n-1)(n-2)} \int_0^\infty \frac{1}{\Gamma(n-2)} z^{n-3} e^{-z} dz = \frac{n^2\theta^2}{(n-1)(n-2)}$$

ce qui implique

$$Var(\tilde{T}) = \frac{n^2\theta^2}{(n-1)(n-2)} - \left(\frac{n}{n-1}\right)^2 \theta^2 = \frac{n^2\theta^2}{(n-1)^2(n-2)}$$

cette quantité tend bien vers 0, ainsi \tilde{T} est convergent.

EXO7

X et Y sont indépendantes $\implies P_{X,Y} = P_X P_Y \implies P_{X,Y} = \mathcal{N}(\theta_1, \theta_2) \times \mathcal{N}(\theta_3, \theta_4)$

$$f_{X,Y}(x, y) = \frac{1}{\sqrt{2\pi}\theta_2} e^{-\frac{1}{2\theta_2}(x-\theta_1)^2} \times \frac{1}{\sqrt{2\pi}\theta_4} e^{-\frac{1}{2\theta_4}(y-\theta_3)^2} = \frac{1}{2\pi\sqrt{\theta_2\theta_4}} e^{-\frac{1}{2}\left[\frac{1}{\theta_2}(x-\theta_1)^2 + \frac{1}{\theta_4}(y-\theta_3)^2\right]} =$$

$$C \exp\left(\sum_{j=1}^4 \alpha_j(\theta_1, \theta_2, \theta_3, \theta_4) a_j(x, y)\right) h(x, y)$$

or

$$-\frac{1}{2} \left(\frac{1}{\theta_2}(x-\theta_1)^2 + \frac{1}{\theta_4}(y-\theta_3)^2 \right) = x \frac{\theta_1}{\theta_2} - \frac{1}{2} \frac{y^2}{\theta_4} - \frac{1}{2} \frac{\theta_1^2}{\theta_2} - \frac{1}{2} \frac{\theta_3^2}{\theta_4} - \frac{1}{2} \frac{x^2}{\theta_2} + y \frac{\theta_3}{\theta_4} =$$

$$-\frac{1}{2} \frac{\theta_1^2}{\theta_2} - \frac{1}{2} \frac{\theta_3^2}{\theta_4} + \left(-\frac{1}{2} \frac{x^2}{\theta_2} - \frac{1}{2} \frac{y^2}{\theta_4} + x \frac{\theta_1}{\theta_2} + y \frac{\theta_3}{\theta_4}\right)$$

\implies

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sqrt{\theta_2\theta_4}} e^{-\frac{1}{2}\frac{\theta_1^2}{\theta_2}} e^{-\frac{1}{2}\frac{\theta_3^2}{\theta_4}} \exp\left(-\frac{1}{2}\frac{x^2}{\theta_2} - \frac{1}{2}\frac{y^2}{\theta_4} + x \frac{\theta_1}{\theta_2} + y \frac{\theta_3}{\theta_4}\right)$$

on pose

$$\alpha_1(\theta_1, \theta_2, \theta_3, \theta_4) = -\frac{1}{2\theta_2}; \alpha_2(\theta_1, \theta_2, \theta_3, \theta_4) = \frac{\theta_1}{\theta_2}; \alpha_3(\theta_1, \theta_2, \theta_3, \theta_4) = \frac{1}{2\theta_4};$$

$$\alpha_4(\theta_1, \theta_2, \theta_3, \theta_4) = \frac{\theta_3}{\theta_4}$$

et

$$a_1(x, y) = x^2; a_2(x, y) = x; a_3(x, y) = y^2; a_4(x, y) = y$$

et

$$h(x, y) = 1$$

$$\implies T = \left(\sum_{i=1}^n X_i^2, \sum_{i=1}^n X_i, \sum_{i=1}^n Y_i^2, \sum_{i=1}^n Y_i\right) \text{ est exhaustive.}$$

$$\# \dim T = \dim \theta = 4 \implies T \text{ est complète.}$$

Exo8 \mapsto mess

les autres \leftarrow polytechnique

EXO (dernier)

$$X \sim U[0, \theta] \text{ de densité } f(x) = \frac{1}{\theta} 1_{[0, \theta]}(x)$$

On a $E(X) = \frac{\theta}{2}$ et donc $T_1 = 2X$ est un estimateur sans biais de θ .

On peut aussi vérifier que $T_2 = \frac{n+1}{n} \max_{1 \leq i \leq n} (X_i)$ est aussi un estimateur sans biais de θ . En effet

$$f_{\max_{1 \leq i \leq n} (X_i)}(x) = \frac{n x^{n-1}}{\theta^n} 1_{[0, \theta]}(x) \Rightarrow E(T) = \frac{n}{n+1} \theta$$

On a :

$$\text{var}(T_1) = \text{var}(2\bar{X}) = \frac{4\text{var}(X)}{n} = \frac{\theta^2}{3n}$$

et

$$\text{var}(T_2) = \left(\frac{n+1}{n}\right)^2 E(\overline{S^2}) - \theta^2 = \frac{(n+1)^2}{n(n+2)}\theta^2 - \theta^2 = \frac{\theta^2}{n(n+2)}.$$

On conclut que $\boxed{\text{var}(T_2) < \text{var}(T_1)}$ dès que $n > 1$, et donc que T_2 est un meilleur estimateur sans biais de que T_1 au sens du risque quadratique.

$$3n - n(n+2) = -n(n-1) < 0 \Rightarrow 3n < n(n+2) \Rightarrow \frac{1}{3n} > \frac{1}{n(n+2)}$$