

Module : Data Mining

Faculté des Sciences Exactes

TD/TP_N°: ■ ■ ■

Exercice 1

Soit l'ensemble D des entiers suivants : D= { 3,7,10,12,15,17}

On veut répartir les données de D en trois (3) clusters, en utilisant l'algorithme Kmeans. La distance d entre deux nombres a et b est calculée ainsi :

d(a, b) = |a - b| (la valeur absolue de a moins b)

- Appliquez Kmeans en choisissant comme centres initiaux des 2 clusters respectivement : 10 et 12.

Solution:

E={3,7,10,12,15,17} K= 2, C1=10, C2=12. (Centroides)

Affecter les points au cluster le plus proche (Centre le plus proche)

	3	7	10	12	15	17
C1=10	7	3	O	2	5	7
C2=12	9	5	2	Ō	3	5

 $G1={3,7,10}$ =>C1=(3+7+10)/3 = 6,66

G2={12,15,17} =>C2=(12+15+17)/3 = 14,66

	3	7	10	12	15	17
C1=6,66	3,66	0,34	3,34	5,34	8,34	10,34
C2=14,66	11,66	7,66	4,66	2,66	0,34	2,34

 $G1={3,7,10}$ =>C1=(3+7+10)/3 = 6,66

G2={12,15,17} =>C2=(12+15+17)/3 =14,66

Exercice 2:

Utilisez l'algorithme k-means et la distance manhatan pour regrouper les 8 exemples suivants en 3 clusters :

A1(2,10,5)

A2(2,5,3)

A3(8,4,1)

A4(5,8,7)

A5(7,5,3)

A6(6,4,7)

A7(1,2,4)

A8(4,9,5).

On considère comme centre de classes à l'initialisation les points A1, A4 et A7.