

Solution du Problème.

- (1) (i) Etant donné X_1, X_2, \dots, X_n une suite de variable aléatoire réelle de même loi que X , l'estimateur de la densité par la méthode du noyau noté $f_n(x)$, défini par:

$$f_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right), \forall x \in \mathbb{R}$$

où K est le noyau de cet estimateur et h est la fenêtre.

- (ii) Commençons par calculer le biais : en faisant le changement de variable suivant

$$y = x + uh, \quad dy = hdu$$

$$\begin{aligned} \mathbb{E}(f_n(x)) &= \frac{1}{nh} \sum_{i=1}^n \mathbb{E}\left[K\left(\frac{X_i - x}{h}\right)\right] \\ &= \frac{1}{nh} \sum_{i=1}^n \int_{\mathbb{R}} K\left(\frac{y - x}{h}\right) f(y) dy \\ &= \frac{1}{h} \int_{\mathbb{R}} K\left(\frac{y - x}{h}\right) f(y) dy \\ &= \int_{\mathbb{R}} K(u) f(x + uh) du. \end{aligned}$$

En effectuant un développement limité à l'ordre 2, avec $\zeta_u \in [x, x + uh]$, il vient

$$\begin{aligned} \mathbb{E}(f_n(x)) &= \int_{\mathbb{R}} K(u) f(x + uh) du \\ &= \int_{\mathbb{R}} K(u) \left[f(x) + (uh) f'(x) + \frac{(uh)^2}{2} f''(\zeta_u) \right] du \\ &= f(x) \underbrace{\int_{\mathbb{R}} K(u) du}_{=1} + h f'(x) \underbrace{\int_{\mathbb{R}} u K(u) du}_{=0} + \frac{h^2}{2} \int_{\mathbb{R}} u^2 K(u) f''(\zeta_u) du. \\ &= f(x) \underbrace{\int_{\mathbb{R}} K(u) du}_{=1} + h f'(x) \underbrace{\int_{\mathbb{R}} u K(u) du}_{=0} + \frac{h^2}{2} \int_{\mathbb{R}} u^2 K(u) f''(x) + O(h^2) du. \\ &= \frac{h^2}{2} f''(x) \int_{\mathbb{R}} u^2 K(u) du + O(h^2). \end{aligned}$$

- (iii) Il en résulte que

$$\begin{aligned} |\text{Biais}(f_n(x))| &= |\mathbb{E}[f_n(x)] - f(x)| \\ &\leq \frac{h^2}{2} \left| \int_{\mathbb{R}} u^2 K(u) f''(\zeta_u) du \right| \\ &\leq \frac{h^2}{2} \int_{\mathbb{R}} u^2 |K(u)| |f''(\zeta_u)| du \\ &\leq h^2 \underbrace{\frac{\max_x |f''(x)|}{2} \int_{\mathbb{R}} u^2 |K(u)| du}_{C_1} \end{aligned}$$

d'où la première partie.

- (iv) Pour prouver la seconde partie, on utilise le fait que les variables aléatoires $Y_i = K((X_i - x)/h)$, $i = 1, \dots, n$ sont i.i.d. et que la variance de la somme de variables

indépendantes coïncide avec la somme des variances :

$$\begin{aligned}
 \text{Var}[f_n(x)] &= \frac{1}{(nh)^2} \text{Var} \left[\sum_{i=1}^n K \left(\frac{X_i - x}{h} \right) \right] \\
 &= \frac{1}{(nh)^2} \sum_{i=1}^n \text{Var} \left[K \left(\frac{X_i - x}{h} \right) \right] \\
 &= \frac{1}{(nh)^2} \times n \times \text{Var} \left[K \left(\frac{X_1 - x}{h} \right) \right] \\
 &\leq \frac{1}{(nh)^2} \mathbb{E} \left[K \left(\frac{X_1 - x}{h} \right)^2 \right] \\
 &= \frac{1}{(nh)^2} \int_{\mathbb{R}} K^2 \left(\frac{y - x}{h} \right) f(y) dy \\
 &= \frac{1}{nh} \int_{\mathbb{R}} K^2(u) f(x - uh) du \\
 &\leq \frac{1}{nh} \underbrace{\sup_{z \in \mathbb{R}} f(z) \int_{\mathbb{R}} K^2(u) du}_{C_2}.
 \end{aligned}$$

C'est exactement ce qu'il fallait démontrer.

- (2) Soit X une variable aléatoire définie sur l'espace de probabilité $(\Omega, \mathcal{A}, \mathbb{P})$, à valeur dans \mathbb{R} . Pour tout $x \in \mathbb{R}$, on désigne par F la fonction de répartition de X , et par f la fonction de densité.

Etant donné X_1, X_2, \dots, X_n une suite de variable aléatoire réelle de même loi que X , l'estimateur de la fonction de répartition par la méthode du noyau noté $F_n(x)$, défini par:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n K \left(\frac{x - X_i}{h_n} \right), \quad \forall x \in \mathbb{R}$$

où K est noyau et λ_n est une suite de réels positifs. On déduit de F_n un estimateur de la fonction de répartition et de la densité, noté f_n , défini par

$$\begin{aligned}
 f_n(x) &= F_n^{(1)}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h_n} K^{(1)} \left(\frac{x - X_i}{h_n} \right) \\
 &= \frac{1}{nh_n} \sum_{i=1}^n K^{(1)} \left(\frac{x - X_i}{h_n} \right)
 \end{aligned}$$

- (i) En vertu de sa définition, l'estimateur naturel de la fonction de hasard, noté $\lambda_n(x)$, est définie par:

$$\lambda_n(x) = \frac{f_n(x)}{1 - F_n(x)} = \frac{\sum_{i=1}^n K^{(1)} \left(\frac{x - X_i}{h_n} \right)}{\sum_{i=1}^n \int_x^{+\infty} K^{(1)} \left(\frac{t - X_i}{h_n} \right) dt}, \quad \forall x \in \mathbb{R}$$

(ii) On considère la décomposition suivante

$$\begin{aligned}
 \lambda_n(x) - \lambda(x) &= \frac{f_n(x)}{1 - F_n(x)} - \frac{f(x)}{1 - F(x)} \\
 &= \frac{f_n(x) - f_n(x)F(x) - f(x) + f(x)F_n(x)}{(1 - F_n(x))(1 - F(x))} \\
 (1) \quad &= \frac{1}{1 - F_n(x)} \left[(f_n(x) - f(x)) + \frac{f(x)}{1 - F(x)} (F_n(x) - F(x)) \right].
 \end{aligned}$$

(iii) Nous avons déjà démontré la convergence presque complète de $F_n(x)$ vers $F(x)$. Autrement dit, nous avons

$$\forall \epsilon > 0 \quad \sum_{n=1}^{\infty} \mathbb{P}\{|F_n(x) - F(x)| > \epsilon\} < \infty.$$

D'autre part, on a par hypothèse $F(x) < 1$, c'est à dire

$$1 - F_n(x) \geq F(x) - F_n(x).$$

Ainsi,

$$\inf_{x \in S} |1 - F_n(x)| \leq (1 - \sup_{x \in S} F(x))/2 \Rightarrow \sup_{x \in S} |F_n(x) - F(x)| \geq (1 - \sup_{x \in S} F(x))/2.$$

En terme de probabilité, on obtient

$$\mathbb{P}\{\inf_{x \in S} |1 - F_n(x)| < \delta\} \leq \mathbb{P}\{\sup_{x \in S} |F_n(x) - F(x)| \geq (1 - \sup_{x \in S} F(x))/2\} < \infty.$$

Finalement, il suffit de prendre $\delta = (1 - \sup_{x \in S} F(x))/2$ pour achever la démonstration.

(iv) On démontre la convergence presque complète uniforme sur un compact réel de $\lambda_n(x)$ vers $\lambda(x)$, autrement dit

$$(2) \quad \sup_{x \in S} |\lambda_n(x) - \lambda(x)| = O(h_n^k) + O\left(\sqrt{\frac{\log n}{nh_n}}\right) \quad p.co.$$

En utilisant la décomposition (1) on peut déduire que,

$$\sup_{x \in S} |\lambda_n(x) - \lambda(x)| \leq \frac{1}{\inf_{x \in S} |1 - F_n(x)|} \left[\sup_{x \in S} |f_n(x) - f(x)| + \frac{\sup_{x \in S} |f(x)|}{\inf_{x \in S} |1 - F(x)|} \sup_{x \in S} |F_n(x) - F(x)| \right]$$

Ainsi, la démonstration de (2) repose sur les résultats suivants

$$(3) \quad \sup_{x \in S} |F_n(x) - F(x)| = O(h_n^k) + O\left(\sqrt{\frac{\log n}{n}}\right), \quad p.co.$$

$$(4) \quad \sup_{x \in S} |f_n(x) - f(x)| = O(h_n^k) + O\left(\sqrt{\frac{\log n}{nh_n}}\right), \quad p.co.$$

$$\exists \delta > 0 \quad \text{telque} \quad \sum_{n=1}^{\infty} \mathbb{P}\left\{\inf_{x \in S} |1 - F_n(x)| < \delta\right\} < \infty.$$

de même la preuve de (3) (resp. (4)) est basée respectivement sur les décompositions suivantes

$$F_n(x) - F(x) = F_n(x) - \mathbb{E}[F_n(x)] + \mathbb{E}[F_n(x)] - F(x)$$

$$f_n(x) - f(x) = f_n(x) - \mathbb{E}[f_n(x)] + \mathbb{E}[f_n(x)] - f(x)$$

La démonstration de (4) repose sur les résultats suivants

$$(5) \quad \mathbb{E}[f_n(x)] - f(x) = O(h_n^k).$$

$$(6) \quad f_n(x) - \mathbb{E}[f_n(x)] = O\left(\sqrt{\frac{\log n}{nh_n}}\right), \quad p.co.$$

Concernant l'équation (5) on a

$$\mathbb{E}[f_n(x)] = \mathbb{E}\left[\frac{1}{nh_n} \sum_{i=1}^n K^{(1)}\left(\frac{x - X_i}{h_n}\right)\right] = \frac{1}{nh_n} \sum_{i=1}^n \mathbb{E}\left[K^{(1)}\left(\frac{x - X_i}{h_n}\right)\right]$$

comme les variables X_i sont i.i.d alors

$$\mathbb{E}\left[K^{(1)}\left(\frac{x - X_1}{h_n}\right)\right] = \mathbb{E}\left[K^{(1)}\left(\frac{x - X_2}{h_n}\right)\right] = \dots = \mathbb{E}\left[K^{(1)}\left(\frac{x - X_i}{h_n}\right)\right]$$

donc

$$\mathbb{E}[f_n(x)] = \frac{1}{h_n} \mathbb{E}\left[K^{(1)}\left(\frac{x - X}{h_n}\right)\right] = \frac{1}{h_n} \int K^{(1)}\left(\frac{x - u}{h_n}\right) f(u) du.$$

Pour calculer cette intégrale on considère le changement des variables on pose $z = (x - u)/h_n \Rightarrow dz = -du/h_n \Rightarrow du = -h_n dz$ et $u = x - zh_n$ pour arriver à:

$$\begin{aligned} \mathbb{E}[f_n(x)] &= - \int_{+\infty}^{-\infty} K^{(1)}(z) f(x - zh_n) dz \\ &= \int_{-\infty}^{+\infty} K^{(1)}(z) f(x - zh_n) dz. \end{aligned}$$

En utilisant l'hypothèse que la densité est de classe C^k , il suffit de développer f au voisinage de x (D.L.T).

Ceci s'écrit, pour θ_z entre x et $x + zh_n$ on a:

$$f(x - zh_n) = f(x) + \sum_{j=1}^{k-1} \frac{(-1)^j (zh_n)^j}{j!} f^{(j)}(x) + \frac{(-1)^k (zh_n)^k}{k!} f^{(k)}(\theta_z).$$

Puisque K est un noyau de densité borné intégrable et d'ordre k on aboutit à

$$\mathbb{E}[f_n(x)] = f(x) + \frac{(-1)^k h_n^k}{k!} \int z^k K'(z) f^{(k)}(\theta_z) dz$$

La continuité de $f^{(k)}$ et la compacité du support compact de K' assurent la convergence uniforme en z de $f^{(k)}(\theta_z)$ vers $f^{(k)}(x)$, ainsi

$$\mathbb{E}[f_n(x)] = f(x) + (-1)^k h_n^k \int z^k K'(z) dz \frac{f^{(k)}(x)}{k!} + O(h_n^k).$$

Concernant l'équation (6), on applique l'inégalité de type Bernstein aux variables:

$$\Delta_i = \frac{1}{h_n} \left[K^{(1)}\left(\frac{x - X_i}{h_n}\right) - \mathbb{E}\left[K^{(1)}\left(\frac{x - X_i}{h_n}\right)\right] \right]$$

pour cela il faut majorer $|\Delta_i|$ ainsi que $\mathbb{E}[\Delta_i^2]$.

Le fait que K est un noyau de densité borné intégrable et d'ordre k , ça nous permet de construire la première borne, ainsi $\exists C$ une constante finie telle que:

$$|\Delta_i| \leq \frac{C}{h_n}.$$

Posons

$$\Gamma_i = \frac{1}{h_n} K^{(1)}\left(\frac{x - X_i}{h_n}\right)$$

calculons le moment d'ordre 2

$$\mathbb{E}[\Gamma_i^2] = \frac{1}{h_n} \mathbb{E} \left(\frac{1}{h_n} K'^2 \left(\frac{x - X_i}{h_n} \right) \right) = \frac{1}{h_n^2} \int K'^2 \left(\frac{x - u}{h_n} \right) f(u) du$$

on pose $z = (x - u)/h_n$ pour aboutir à

$$\mathbb{E}[\Gamma_i^2] = \frac{1}{h_n} \int K'^2(z) f(x - zh_n) dz.$$

Puisque f est bornée car continue sur le support compact de K , on a l'existence d'une constante finie C telle que:

$$\mathbb{E}[\Gamma_i^2] \leq \frac{C}{h_n}$$

d'une manière évidente on a l'existence d'une constante finie C telle que:

$$\mathbb{E}[\Delta_i^2] \leq \frac{C}{h_n}$$

Ainsi, pour ϵ suffisamment petit on a:

$$(7) \quad \mathbb{P}(|f_n(x) - \mathbb{E}[f_n(x)]| > \epsilon) \leq 2 \exp \left(-\frac{n\epsilon^2}{4C} \right)$$

On applique (7) à $\epsilon = \epsilon_0 \sqrt{\frac{\log n}{nh_n}}$, on aura pour tout ϵ_0 , $\exists C > 0$:

$$\mathbb{P} \left(|f_n(x) - \mathbb{E}[f_n(x)]| > \epsilon_0 \sqrt{\frac{\log n}{nh_n}} \right) \leq 2 \exp(-C\epsilon_0^2 \log n).$$

Pour ϵ_0 bien choisi, le terme à droite est celui d'une série convergente.

La preuve (3) repose sur les résultats suivants

$$(8) \quad \mathbb{E}[F_n(x)] - F(x) = O(h_n^k).$$

$$(9) \quad F_n(x) - \mathbb{E}[F_n(x)] = O \left(\sqrt{\frac{\log n}{nh_n}} \right), \quad p.co.$$

Concernant l'équation (8) La preuve est similaire à celle de la preuve de l'équation (5) en remplaçant f par F et $\mathbb{E}[f_n]$ par $\mathbb{E}[F_n]$.

Concernant l'équation (9) la preuve est basée sur les mêmes arguments de la preuve de l'équation (6), tout en posant

$$\Delta_i = K \left(\frac{x - X_i}{h_n} \right) - \mathbb{E} \left[K \left(\frac{x - X_i}{h_n} \right) \right]$$

comme précédemment sous les hypothèses du noyau K on arrive à l'existence d'une constante finie $C_1 > 0$ telle que

$$|\Delta_i| \leq C_1$$

posons

$$Y_i = K \left(\frac{x - X_i}{h_n} \right)$$

et calculons le moment d'ordre 2 de Y_i

$$\mathbb{E}[Y_i^2] = \mathbb{E} \left[K^2 \left(\frac{x - X_i}{h_n} \right) \right] = \int K^2 \left(\frac{x - u}{h_n} \right) f(u) du$$

on effectue le changement de variable suivant $z = (x - u)/h_n$ pour aboutir à:

$$\mathbb{E}[Y_i^2] = \int K^2(z) f(x - zh_n) dz.$$

f est bornée (continue sur le support compact de K), donc il existe une constante finie $C_1 > 0$ telle que:

$$\mathbb{E}[Y_i^2] \leq C_1.$$

par suite

$$\mathbb{E}[\Delta_i^2] \leq C_1.$$

l'application de l'inégalité de type Bernstein, pour ϵ suffisamment petit nous donne

$$\mathbb{P}(|F_n(x) - \mathbb{E}[F_n(x)]| > \epsilon) \leq 2 \exp\left(-\frac{n\epsilon^2}{4C_1}\right)$$

pour $\epsilon = \epsilon_0 \sqrt{\frac{\log n}{n}}$, on aura pour tout ϵ_0 il existe une constante $C_1 > 0$ telle que:

$$\mathbb{P}\left(|F_n(x) - \mathbb{E}[F_n(x)]| > \epsilon_0 \sqrt{\frac{\log n}{n}}\right) \leq 2 \exp(-C\epsilon_0^2 \log n).$$

Ainsi pour ϵ_0 bien choisi, le terme à droite est celui d'une série convergente, et cela achève la preuve.