

# SERIES CHRONOLOGIQUES II

Mouna Merzougui  
Université Badji Mokhtar Annaba

Cours Master 1 : Actuariat & prob-stat. (Semestre 2)

Chapitre 2 : Processus ARCH/GARCH

Cours 3 : Estimation, prévision et simulation d'un ARCH.

## 2.4 Estimation d'un ARCH(q)

On utilisera la méthode du maximum de vraisemblance conditionnelle. Soit le processus  $ARCH(q)$  suivant :  $\varepsilon_t = u_t \sqrt{h_t}$  où  $u_t \sim iidN(0, 1)$  et

$$h_t = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2.$$

Le paramètre d'intérêt est  $\theta = (\alpha_0, \alpha_1, \dots, \alpha_q)'$ . La vraisemblance conditionnelle des données  $\varepsilon_{q+1}, \dots, \varepsilon_n$  sachant  $\varepsilon_1, \dots, \varepsilon_q$  est donnée par

$$L(\theta/\varepsilon_1, \dots, \varepsilon_q) = \prod_{t=q+1}^n f_{\theta}(\varepsilon_t/\varepsilon_{t-1}, \dots, \varepsilon_{t-q}),$$

où la densité conditionnelle de  $\varepsilon_t$  est :  $\varepsilon_t/\varepsilon_{t-1}, \dots, \varepsilon_{t-q} \sim N(0, \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2)$ , avec  $t > q$ .

La fonction critère à maximiser est

$$l(\theta/\varepsilon_1, \dots, \varepsilon_q) = -\frac{n-q}{2} \log(2\pi) - \frac{1}{2} \sum_{t=q+1}^n \log \left( \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 \right) - \frac{1}{2} \sum_{t=q+1}^n \frac{\varepsilon_t^2}{\alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2}.$$

On cherche  $\theta$  qui maximise le log-vraisemblance  $l$  :

$$\hat{\theta} = \arg \max_{\theta} l(\theta/\varepsilon_1, \dots, \varepsilon_q)$$

C'est un problème d'optimisation non linéaire, il faut utiliser les procédures numériques pour trouver la solution.

### Exemple

Soit  $X_t$  un processus  $ARCH(1)$ , donner le log vraisemblance conditionnel d'un échantillon provenant de ce modèle et en déduire le vecteur gradient et la matrice hessienne ?

### Solution

$X_t = u_t \sqrt{\alpha_0 + \alpha_1 X_{t-1}^2}$  avec  $u_t \sim iidN(0, 1)$ , donc le log-vraisemblance conditionnelle de l'échantillon  $X_2, \dots, X_n$  sachant  $X_1$  :

$$l(\theta/X_1) = -\frac{n-1}{2} \log(2\pi) - \frac{1}{2} \sum_{t=2}^n \log(\alpha_0 + \alpha_1 X_{t-1}^2) - \frac{1}{2} \sum_{t=2}^n \frac{X_t^2}{\alpha_0 + \alpha_1 X_{t-1}^2}$$

Le vecteur gradient est

$$\begin{pmatrix} \frac{\partial l}{\partial \alpha_0} \\ \frac{\partial l}{\partial \alpha_1} \end{pmatrix} = -\frac{1}{2} \sum_{t=2}^n \frac{\alpha_0 + \alpha_1 X_{t-1}^2 - X_t^2}{(\alpha_0 + \alpha_1 X_{t-1}^2)^2} \begin{pmatrix} 1 \\ X_{t-1}^2 \end{pmatrix}.$$

Le calcul de la matrice hessienne  $\begin{pmatrix} \frac{\partial^2 l}{\partial \alpha_0^2} & \frac{\partial^2 l}{\partial \alpha_0 \partial \alpha_1} \\ \frac{\partial^2 l}{\partial \alpha_1 \partial \alpha_0} & \frac{\partial^2 l}{\partial \alpha_1^2} \end{pmatrix}$  est laissé comme un exercice.

## 2.5 Prédiction et intervalle de confiance

On va étudier la prédiction d'un processus  $AR(1) + ARCH(1)$ .

Soit  $X_t \sim AR(1) + ARCH(1)$  alors  $X_t = \varphi X_{t-1} + \varepsilon_t$  où  $\varepsilon_t = u_t \sqrt{\alpha_0 + \alpha_1 \varepsilon_{t-1}^2}$  et  $u_t \sim iidN(0, 1)$ .

La prédiction à l'horizon 1 :

$$\begin{aligned} \hat{X}_t(1) &= E(X_{t+1}/I_t) \\ &= \varphi X_t \end{aligned}$$

L'erreur de prédiction est

$$\begin{aligned} e_t(1) &= X_{t+1} - \hat{X}_t(1) \\ &= \varepsilon_{t+1} \end{aligned}$$

Sachant que  $\varepsilon_{t+1}/I_t \sim N(0, \alpha_0 + \alpha_1 \varepsilon_t^2)$ , alors l'intervalle de confiance de  $X_{t+1}$  au seuil 5% est  $\left[ \hat{X}_t(1) \pm 1.96 \sqrt{\alpha_0 + \alpha_1 \varepsilon_t^2} \right]$ .

On remarque que l'intervalle de confiance dépend de  $\varepsilon_t$  contrairement au cas d'un  $AR(1) + BB$  (semestre1).

## 2.6 Simulation d'un ARCH(1)

Nous allons simuler 500 observations du modèle  $ARCH(1)$  suivant :  $\varepsilon_t = u_t \sqrt{h_t}$  avec  $u_t \sim iidN(0, 1)$  et  $h_t = 1 + 0.8 \varepsilon_{t-1}^2$ .

Le programme est écrit en R :

```
#Simulation d'un ARCH(1)

n=500

# Générer les valeurs de ut qui suit N(0,1)

ut=rnorm(n+20)

#Initialisation de ht et de eps

ht=rep(0,n+20)

eps=ht

for (i in 2 :(n+20))

{ht[i]=1+0.8*eps[i-1]^2

eps[i]=ut[i]*ht[i-1]^0.5}

eps=eps[-(1 :20)]


par(mfrow=c(3,1))

plot.ts(eps)

acf(eps)

acf(eps^2)
```

On obtient le graphe de  $\varepsilon_t$  et les corrélogrammes de  $\varepsilon_t$  et de  $\varepsilon_t^2$ . On remarque que le processus ARCH(1) s'apparente à un bruit blanc, d'après le corrélogramme de la série ( pas de pics significatifs), mais on voit bien qu'il y a une corrélation pour la série  $\varepsilon_t^2$ .

FIG. 2.1 – Graphe de la série et corrélogrammes de  $\varepsilon_t$  et de  $\varepsilon_t^2$