

République Algérienne Démocratique et Populaire  
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

UNIVERSITÉ MOHAMED KHIDER BISKRA

Faculté des Sciences Exactes et Sciences de la Nature et de la Vie  
Département de Mathématiques



Première Année Master

Notes de Cours

---

# Analyse de Données

Chapitre 3 : Analyse de la variance  
(Séance 7)

---

Auteur des notes :

Dr. Sana BENAMEUR

Année universitaire : 2021-2022

## Chapitre 3

# ANALYSE DE LA VARIANCE

### 3.1 Analyse de la variance à un facteur AV(1)

L'analyse de la variance est une technique qui sert à tester l'influence d'un (ou de plusieurs) facteur (s) qualitative (s) sur une variable quantitative. Notons  $A$  le facteur et  $A_1, \dots, A_p$  ses  $p$  modalités ou niveaux. Soient  $Y$  la variable étudiée et  $y_1, y_2, \dots, y_n$  ses observations. Pour chaque niveau  $A_j$  du facteur est associée  $n_j$  mesures de  $Y$  :  $y_{1j}, y_{2j}, \dots, y_{n_jj}$ .

$y_{ij}$  :  $i^{\text{ème}}$  observation du  $j^{\text{ème}}$  niveau

$n_j$  : la taille de l'échantillon  $y_{*j}$

$\bar{y}_j$  : la moyenne de la classe  $j$

$n$  : taille de l'échantillon  $y$

$\bar{y}$  : la moyenne totale

$A_1$	$\dots$	$A_j$	$\dots$	$A_p$
$y_{11}$	$\dots$	$y_{1j}$	$\dots$	$y_{1p}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$y_{n_11}$	$\dots$	$y_{n_jj}$	$\dots$	$y_{n_pp}$
$\bar{y}_1$	$\dots$	$\bar{y}_j$	$\dots$	$\bar{y}_p$

On a

$$n = \sum_{j=1}^p n_j, \quad \bar{y}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij}, \quad \bar{y} = \frac{1}{n} \sum_{j=1}^p n_j \bar{y}_j = \frac{1}{n} \sum_{j=1}^p \sum_{i=1}^{n_j} y_{ij}.$$

#### 3.1.1 Modèle d'AV(1)

Soit  $\mu = \frac{1}{n} \sum_{j=1}^p n_j \mu_j$ , ( $\mu_j = \mathbb{E}[y_j]$  : moyenne théorique). En terme d'observation, on a le modèle :

$$\underbrace{(y_{ij} - \bar{y})}_{\text{écart total}} = \underbrace{(y_{ij} - \bar{y}_j)}_{\text{écart résiduel}} + \underbrace{(\bar{y}_j - \bar{y})}_{\text{écart factoriel}}, \quad (1)$$

et théoriquement, on a

$$y_{ij} - \mu = (y_{ij} - \mu_j) + (\mu_j - \mu). \quad (2)$$

Posons  $\mu_j - \mu = \alpha_j$  et  $y_{ij} - \mu_j = \varepsilon_{ij}$ . Nous obtenons le modèle d'AV(1) :

$$\underbrace{y_{ij}}_{\text{modèle}} = \underbrace{\mu}_{\text{moyenne générale}} + \underbrace{\alpha_j}_{\text{effet principale}} + \underbrace{\varepsilon_{ij}}_{\text{effet résiduel}},$$

avec  $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ . Il est clair que  $\bar{\alpha} = 0$ .

### 3.1.2 Equation d'AV(1)

Le modèle observé (1), permet d'obtenir l'équation d'AV(1)

$$\begin{aligned} \sum_{j=1}^p \sum_{i=1}^{n_j} (y_{ij} - \bar{y})^2 &= \sum_{j=1}^p \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_j)^2 + \sum_{j=1}^p \sum_{i=1}^{n_j} (\bar{y}_j - \bar{y})^2 \\ \underbrace{\sum_{j=1}^p \sum_{i=1}^{n_j} y_{ij}^2 - n\bar{y}^2}_{SCT} &= \underbrace{\sum_{j=1}^p \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_j)^2}_{SCR} + \underbrace{\sum_{j=1}^p n_j \bar{y}_j^2 - n\bar{y}^2}_{SCA}. \end{aligned}$$

Variation	ddl	SC	MC	F
Factorielle	$p - 1$	$SCA$	$MCA$	$\frac{MCA}{MCR}$
Résiduelle	$n - p$	$SCR$	$MCR$	
Totale	$n - 1$	$SCT$		

TAB. 3.1. Tableau d'AV(1)

### 3.1.3 Test d'égalité des moyennes

Si le facteur  $A$  n'a pas d'influence sur  $Y$ , alors l'hypothèse à tester est

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_p \Leftrightarrow \alpha_1 = \alpha_2 = \dots = \alpha_p = 0.$$

Sous l'hypothèse de normalité des  $\varepsilon$ , on a

$$MCA = \frac{SCA}{p-1} \sim \chi_{p-1}^2, MCR = \frac{SCR}{n-p} \sim \chi_{n-p}^2 \text{ et } F = \frac{MCA}{MCR} \sim \mathcal{F}(p-1, n-p).$$

Nous acceptons l'hypothèse  $H_0$  d'égalité des moyennes si  $F \leq f_{1-\alpha}(p-1, n-p)$ . Le rejet de  $H_0$  implique qu'au moins deux moyennes sont différentes ( $\exists \mu_k, \mu_j \mid \mu_k \neq \mu_j$ ).

Dans ce cas nous utilisons la méthode de Bonferroni basée sur la comparaison deux à deux des couples  $(\mu_k, \mu_j)$  :

$$\begin{cases} H_0 : \mu_k - \mu_j = 0 \\ H_1 : \mu_k - \mu_j \neq 0 \end{cases}, k \neq j$$

On a donc,  $m = C_p^2$  tests de Student à faire. on accepte  $H_0$  ( $\mu_k = \mu_j$ ) si :

$|T| < t_{1-\frac{\alpha}{2m}}(n-p)$ , où

$$T = \frac{\bar{y}_k - \bar{y}_j}{\sqrt{\left(\frac{1}{n_k} + \frac{1}{n_j}\right) MCR}},$$

$t_*$  est le fractile d'ordre  $*$  de la loi de Student à  $n-p$  degré de liberté.

### 3.1.4 Exemple d'AV(1)

On veut étudier l'influence de trois types d'essence  $A_1, A_2, A_3$  sur les distances parcourues en (km). Le type d'essence influe sur les distances ? Localiser les différences si oui :

$A_1$	240	250	243	255	
$A_2$	253	265	264	270	276
$A_3$	233	240	247		

#### Solution

Le tableau d'AV (1) est donné par

Variation	ddl	SC	MC	$F$	
Factorielle	2	1444.8	722.4	12.38	$p = 3,$
Résiduelle	9	525.2	58.4		$n_1 = 4, n_2 = 5, n_3 = 3, n = 12$
Totale	11	1970			$\bar{y}_1 = 247, \bar{y}_2 = 265.6, \bar{y}_3 = 240,$
					$\bar{y} = 253$

Au niveau de confiance 95%,  $F = 12.38 > f = 4.26$ . Alors il y a une influence (non égalité des moyenne :  $H_0$  est rejeté). Il y'a  $m = C_3^2 = 3$  tests de comparaison ( $\mu_1$  vs  $\mu_2$ ), ( $\mu_1$  vs  $\mu_3$ ) et ( $\mu_2$  vs  $\mu_3$ ) :

1<sup>ier</sup> cas ( $\mu_1$  vs  $\mu_2$ ) : on a

$$T = \frac{\bar{y}_1 - \bar{y}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) MCR}} = \frac{247 - 265.6}{\sqrt{\left(\frac{1}{4} + \frac{1}{5}\right) 58.4}} = -3.63,$$

avec  $t_{1-\frac{\alpha}{2m}}(n-p) = t_{1-\frac{0.05}{6}}(9) = 2.82 < |T| \Rightarrow H_0$  est rejeté ( $\mu_1 \neq \mu_2$ ) à 95%. De même pour les autres cas, on ( $\mu_1 = \mu_3$ ) et ( $\mu_2 \neq \mu_3$ ). On dit dans ce cas que les types  $A_1$  et  $A_3$  ont le même effet qu'est différent de celui de  $A_2$ .