

Exercice 1. Dans une étude de régression multiple comportant quatre variables explicatives, nous avons obtenu le tableau d'AV pour 19 observations, comme suit :

Variation	<i>ddl</i>	<i>SC</i>	<i>MC</i>	<i>F</i>
Expliquée				
Résiduelle		2152.7		
Total		7654		

- 1) Complétez le tableau d'AV et testez la signification globale du modèle au seuil 5%.
- 2) Calculez le coefficient de détermination du modèle.

Exercice 2. On s'intéresse à l'effet du nombre d'années d'études des parents (*M* : mère et *P* : père) sur le nombre d'années d'études de leurs enfants noté *Y*. On dispose du nombre d'années d'études de 26 familles (enfant, mère et père). On décide d'ajuster ces données par le modèle linéaire suivant

$$y_i = aM_i + bP_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma_\varepsilon^2), \quad i = 1, 2, \dots, 26.$$

On vous donne les sommes suivantes :

$$\sum M_i^2 = 288, \quad \sum P_i^2 = 202, \quad \sum M_i P_i = 144, \quad \sum y_i M_i = 184, \quad \sum y_i P_i = 158.$$

- 1) Ecrire ce modèle sous forme matricielle : $Y = XB + \varepsilon$, en précisant *Y*, *X* et *B*.
- 2) Donnez les matrices $(X^t X)$ et $X^t Y$ à l'aide des valeurs numériques des sommes ci-dessus.
- 3) Calculez l'estimateur \hat{B} de *B*.
- 4) Calculez $\hat{\sigma}_\varepsilon^2 = S^2$, sachant que $\sum \hat{\varepsilon}_i^2 = 36$.
- 5) Calculez les variances estimées de chacun des coefficients : $\hat{\sigma}_a^2$ et $\hat{\sigma}_b^2$.
- 6) Tester la signification des paramètres *a* et *b* à 90%.
- 7) Donner un intervalle de confiance à 90% des paramètres *a* et *b*.
- 8) Le nombre d'années d'études des mères à un effet sur celui de leur enfants ?
- 9) Le nombre d'années d'études des pères à un effet sur celui de leur enfants ?
- 10) Quel est le nombre d'années d'études prévu pour un enfant, sachant que le nombre d'années d'études de ces parents a été 17 ans pour le père et 14 ans pour la mère ?

Exercice 3. Considérons la régression linéaire multiple avec constante et deux variables explicatives *U* et *V* :

$$Y_j = a + bU_j + cV_j + \varepsilon_j, \quad j = 1, \dots, n \quad \varepsilon \sim N(0, \sigma_\varepsilon^2)$$

et soient les résultats empiriques :

$$X^t Y = \begin{pmatrix} 11,5 \\ 24,8 \\ 17,3 \end{pmatrix}, \quad X^t X = \begin{pmatrix} 30 & 0 & 0 \\ 0 & 20 & 5 \\ 0 & 5 & 15 \end{pmatrix} \quad \text{et} \quad \sum_{i=1}^n \hat{\varepsilon}_i^2 = 15,7.$$

- 1) Calculer la matrice inverse $(X^t X)^{-1}$. Puis estimer les paramètres du modèle : $B = (a, b, c)^t$.
- 2) Calculer les moyennes empiriques : \bar{U} , \bar{V} .
- 3) Calculer $\hat{\sigma}_\varepsilon^2 = S^2$.
- 4) Calculer les variances estimées de chacun des coefficients : $\hat{\sigma}_a^2, \hat{\sigma}_b^2$ et $\hat{\sigma}_c^2$
- 5) Donner les valeurs des covariances :

$$\text{cov}(\hat{b}, \hat{a}), \quad \text{cov}(\hat{a}, \hat{c}) \quad \text{et} \quad \text{cov}(\hat{b}, \hat{c}).$$

- 6) La variable explicative U est-elle à 90% significativement contributive dans l'explication de Y ?
- 7) Le coefficient c est-il à 90% significativement différent de 1 ?
- 8) Sachant que : $U_h = 13.3$, $V_h = 16.6$. Calculer la prévision \hat{Y}_h et son intervalle de confiance à 90%.