Tests Statistiques

Master 1: 2020-2021

Prof. Abdelhakim Necir

Département de Mathématiques (Univ. Biskra)

Samedi 19 Décembre 2020

Estimation paramétrique

- Estimation paramétrique poncuelle
- Estimation paramétrique par intervalle (intervalle de confiance)

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

- $② \ \, X \leadsto \exp\left(\theta\right) \text{, } \theta \in \Theta = \mathbb{R}_{+}^{*}$

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

- $② \ \, X \leadsto \exp\left(\theta\right) \text{, } \theta \in \Theta = \mathbb{R}_{+}^{*}$
- $lackbox{0} X \leadsto \mathcal{N}\left(\mu, \sigma^2\right), \ \theta = \left(\mu, \sigma^2\right) \in \Theta = \mathbb{R} \times \mathbb{R}_+^*$

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

- $② \ \, X \leadsto \exp\left(\theta\right) \text{, } \theta \in \Theta = \mathbb{R}_{+}^{*}$
- $lacktriangledown X \leadsto \mathsf{Bernoulli}(p)$, $heta = p \in \Theta \in [0,1]$

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

- $② \ \, X \leadsto \exp\left(\theta\right) \text{, } \theta \in \Theta = \mathbb{R}_{+}^{*}$
- $lacktriangledown X \leadsto \mathsf{Bernoulli}(p)$, $heta = p \in \Theta \in [0,1]$
- **③** $X \rightsquigarrow \mathsf{Binomial}(n, p)$, $\theta = (n, p) \in \Theta \in \mathbb{N}^* \times [0, 1]$

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

- $② \ \, X \leadsto \exp\left(\theta\right) \text{, } \theta \in \Theta = \mathbb{R}_{+}^{*}$
- $lack X \leadsto \mathsf{Bernoulli}(p)$, $heta = p \in \Theta \in [0,1]$
- **⑤** $X \rightsquigarrow \mathsf{Binomial}(n, p)$, $\theta = (n, p) \in \Theta \in \mathbb{N}^* \times [0, 1]$
- $\textcircled{0} \ \ X \leadsto \mathsf{Pois}(\lambda) \ , \ \theta = \lambda \in \Theta \in \mathbb{R}_+^*$

Soit X une va ayant une densité de probabilité $f(x;\theta)$, $\theta \in \Theta \subset \mathbb{R}^m$, m=1,2,3,...

- $② \ \, X \leadsto \exp\left(\theta\right) \text{, } \theta \in \Theta = \mathbb{R}_{+}^{*}$
- $lack X \leadsto \mathsf{Bernoulli}(p)$, $\theta = p \in \Theta \in [0,1]$
- **③** $X \rightsquigarrow \mathsf{Binomial}(n, p)$, $\theta = (n, p) \in \Theta \in \mathbb{N}^* \times [0, 1]$
- $oldsymbol{\circ} X \leadsto {\sf Pois}(\lambda)$, $heta = \lambda \in \Theta \in \mathbb{R}_+^*$
- $m{0} \ \ X \leadsto \chi^2(r) \ , \ \theta = r \in \Theta \in \mathbb{N}^*$

Notations: $\mathbf{E}(X,Y) := (\mathbf{E}[X],\mathbf{E}[Y])$ et $\widehat{\theta}_n := \widehat{\theta}$.

Problème: construire un estimateur $\widehat{\theta} = \widehat{\theta}(X_1, ..., X_n)$ pour le paramètre θ .

- ullet Estimateur sans biais: $\mathbf{E}\left[\widehat{ heta}
 ight]= heta.$
- ullet Estimateur asymptotiquement san bias: $\mathbf{E}\left[\widehat{ heta}
 ight] o heta$ quand $n o \infty.$
- Estimateur biaisé: $\mathbf{E}\left[\widehat{\theta}\right] = \theta + b_n\left(\theta\right)$, avec $b_n\left(\theta\right) := \mathbf{E}\left[\widehat{\theta} \theta\right]$ est le biais de l'estimateur.
- Estimateur consistent: $\widehat{\theta} \stackrel{P}{\to} \theta$.
- Estimateur asymptotiquement normal: $\sqrt{n}\left(\widehat{\theta}-\theta\right) \stackrel{\mathcal{D}}{\rightarrow} \mathcal{N}\left(0,\sigma^{2}\left(\theta\right)\right)$.

Estimation paramétrique ponctuelle: critère de comparaison

Un bon critère de comparaison est l'erreur quadratique: Soit $\hat{\theta}$ un estimateur de θ . L'erreur quadratique moyenne (EQM), en anglais mean squared error (MSE), est définie par:

$$\textit{EQM}\left(\widehat{ heta}, heta
ight) = \mathbf{E}\left[\widehat{ heta} - heta
ight]^2.$$

Soit $\widehat{\theta}_1$ et $\widehat{\theta}_2$ deux estimateurs de θ . On dit que $\widehat{\theta}_1$ est meilleur que $\widehat{\theta}_2$ (au sense de **EQM**), si

$$\mathbf{EQM}\left(\widehat{\theta}_{1},\theta\right)<\mathbf{EQM}\left(\widehat{\theta}_{2},\theta\right).$$

L'EQM se décompose en deux termes, le carré du biais et la variance:

$$\begin{array}{lcl} \mathbf{EQM} \left(\widehat{\boldsymbol{\theta}}, \boldsymbol{\theta} \right) & = & \left(\mathbf{E} \left[\widehat{\boldsymbol{\theta}} - \boldsymbol{\theta} \right] \right)^2 + \mathbf{Var} \left[\widehat{\boldsymbol{\theta}} \right] \\ & = & b_{\boldsymbol{\theta}}^2 + \mathbf{Var} \left[\widehat{\boldsymbol{\theta}} \right]. \end{array}$$

Estimation paramétrique: critère de comparaison

Supposons que $\widehat{\theta}_1$ et $\widehat{\theta}_2$ deux estimateurs **sans biais** de θ . On dit que $\widehat{\theta}_1$ est plus éfficace que $\widehat{\theta}_2$ si

$$\operatorname{Var}\left[\widehat{\theta}_{1}\right]<\operatorname{Var}\left[\widehat{\theta}_{2}\right].$$

La fonction de vraisemblance est la densité de probabilité de l'echantillons $(X_1,....,X_n)$:

$$\mathbf{f}_{\theta}\left(X_{1},....,X_{n}\right)=\prod_{i=1}^{n}f_{\theta}\left(X_{i}\right).$$

La fonction de log-vraisemblance est définie par

$$L_{\theta}(X_{1},....,X_{n}) = \log \mathbf{f}_{\theta}(X_{1},....,X_{n})$$
$$= \sum_{i=1}^{n} \ell_{\theta}(X_{i}).$$

où $\ell_{\theta}(x) := \log f_{\theta}(x)$.

L'estimateur de maximum de vraisemblance (**EMV**) de $\theta \in \Theta \subset \mathbb{R}^m$, la statistique définie par:

$$\widehat{ heta}_{EMV} := rg\max_{ heta \in \Theta} \mathbf{f}_{ heta}\left(X_{1},....,X_{n}
ight)$$
 .

En d'autres termes, on cherche $\widehat{\theta}_{EMV}$ est le point tel que

$$\mathbf{f}_{\widehat{\theta}_{EMV}}\left(X_{1},....,X_{n}
ight)$$
 est maximale.

Pour tout $\theta \in \Theta$

$$\mathbf{f}_{\theta}\left(X_{1},...,X_{n}\right)\leq\mathbf{f}_{\widehat{\theta}_{EMV}}\left(X_{1},...,X_{n}\right).$$

Ou de manière équivalente

$$\widehat{ heta}_{ extit{EMV}} := rg\max_{ heta \in \Theta} L_{ heta}\left(X_{1},....,X_{n}
ight)$$
 .

Supposons que: $\theta \to \ell_{\theta}$ admet une derivée continue $\ell'_{\theta} := d\ell_{\theta}/d\theta$, alors $\widehat{\theta}_{EMV}$ est une solution de l'équation

$$L'_{\theta}(X_1,...,X_n) = \sum_{i=1}^n \ell'_{\theta}(X_i) = 0.$$

S'il existe une solution $\theta_n = \theta_n\left(X_1,....,X_n\right)$ de cette equation telle que

$$L_{\theta}^{\prime\prime}\left(X_{1},....,X_{n}
ight)\leq0$$
, pour tout $\theta\in\Theta$,

alors $\theta_n \equiv \widehat{\theta}_{EMV}$.

L'existence et l'unicité de l'EMV seront discutés par la suite.

Exemple 1. $X \leadsto \textit{Exp} (\theta)$: une va qui suit la loi exponentielle de paramétre $\theta > 0$:

$$f_{ heta}\left(x
ight)=rac{1}{ heta}\exp\left(-rac{1}{ heta}x
ight)$$
 , $x\geq0$.

La fonction $\theta \to f_{\theta}\left(x\right)$ admet une dérivée (par rapport à θ) continue. Nous avons

$$\ell_{\theta}(x) = \log f_{\theta}(x) = -\log \theta - \frac{1}{\theta}x$$

et

$$\ell_{\theta}'(x) = -\frac{1}{\theta} + \frac{1}{\theta^2}x$$

et

$$\ell_{\theta}^{\prime\prime}\left(x
ight)=rac{1}{ heta^{2}}-rac{2}{ heta^{3}}x=rac{1}{ heta^{2}}\left(1-rac{2}{ heta}x
ight).$$

Donc $\widehat{\theta}_{EMV}$ est une solution de l'équation

$$\sum_{i=1}^{n} \ell_{\theta}'\left(X_{i}\right) = \sum_{i=1}^{n} \left(-\frac{1}{\theta} + \frac{1}{\theta^{2}}X_{i}\right) = 0.$$

Cece implique que

$$-n+\frac{1}{\theta}\sum_{i=1}^n X_i=0.$$

Ce qui donne $\theta_n = \overline{X}$.

D'autre part:

$$L_{\theta}^{"}(X_1,...,X_n) = \sum_{i=1}^n \ell_{\theta}^{"}(X_i) = \frac{1}{\theta^2} \sum_{i=1}^n \left(1 - \frac{2}{\theta} X_i\right)$$
$$= \frac{1}{\theta^2} \left(n - \frac{2}{\theta} \sum_{i=1}^n X_i\right) = \frac{n}{\theta^2} \left(1 - \frac{2\overline{X}_n}{\theta}\right).$$

Cece implique que

$$L_{\theta_n}''(X_1,...,X_n) = -\frac{n}{\overline{X}^2} < 0.$$

La solution de cette équation est $\theta_n = \widehat{\theta}_{EMV}$.

Exemple 2. $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$: une va qui suit la loi de Gauss de paramètre

$$\theta = (\mu, \sigma^2) := (\theta_1, \theta_2) \in \mathbb{R} \times \mathbb{R}_+^* = \Theta.$$

La densité de X est

$$f_{\theta}\left(x
ight)=rac{1}{\sqrt{2\pi\sigma^{2}}}\exp\left\{-rac{1}{2}\left(rac{x-\mu}{\sigma}
ight)^{2}
ight\},\;x\in\mathbb{R}$$

Il est claire que $\theta \to f_{\theta}(x)$ admet $\partial f_{\theta}(x)/\partial \theta_{i}$, i=1,2 continues et

$$\ell_{\theta}\left(x\right) = \log f_{\theta}\left(x\right) = -\frac{1}{2}\log 2\pi - \frac{1}{2}\log \sigma^{2} - \frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^{2}.$$

Alors

$$\frac{\partial \ell_{\theta}\left(x\right)}{\partial \theta_{1}} = \frac{\partial \ell_{\left(\mu,\sigma^{2}\right)}\left(x\right)}{\partial \mu} = \frac{x - \mu}{\sigma^{2}}$$

et

$$\frac{\partial \ell_{\theta}\left(x\right)}{\partial \theta_{2}} = \frac{\partial \ell_{\left(\mu,\sigma^{2}\right)}\left(x\right)}{\partial \sigma^{2}} = -\frac{1}{2\sigma^{2}} + \frac{1}{2}\left(x - \mu\right)^{2} \frac{1}{\sigma^{2}}.$$

Donc $\widehat{\theta}_{EMV}$ est une solution de l'équation

$$\sum_{i=1}^{n} \frac{\partial \ell_{(\mu,\sigma^2)}\left(X_i\right)}{\partial \mu} = \sum_{i=1}^{n} \frac{X_i - \mu}{\sigma^2} = 0.$$

$$\sum_{i=1}^{n} \frac{\partial \ell_{(\mu,\sigma^2)}(X_i)}{\partial \sigma^2} = \left(\sum_{i=1}^{n} -\frac{1}{2\sigma^2} + \frac{1}{2} \left(X_i - \mu\right)^2 \frac{1}{\sigma^2}\right) = 0.$$

Cece implique que

$$\mu_n = \overline{X} \text{ et } \sigma_n^2 = \frac{1}{n} \sum_{i=1}^n \left(X_i - \overline{X} \right)^2 = \widetilde{S}_n^2.$$

On démontre que

$$\sum_{i=1}^{n} \frac{\partial^{2} \ell_{\left(\mu_{n}, \sigma_{2}^{2}\right)}\left(X_{i}\right)}{\partial \mu^{2}} \leq 0$$

et

$$\sum_{i=1}^{n} \frac{\partial^{2} \ell_{\left(\mu_{n}, \sigma_{n}^{2}\right)}\left(X_{i}\right)}{\partial \left(\sigma_{n}^{2}\right)^{2}} \leq 0.$$

Donc

$$\widehat{\mu}_{EMV} = \overline{X} \text{ et } \widehat{\sigma}_{EMV}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2.$$