

Correction des exercices du Chapitre 01

Correction de l'exercice 01

a) Soit A un événement tel qu'il y ait au moins deux coïncidences entre

$$X_1, X_2, \dots, X_n : A_{ij} = \{X_i = X_j\}.$$

$$P\{A_{ij}\} = 0 \text{ if } i \neq j.$$

$$1 - P\{X_{1,n} < X_{2,n} < \dots < X_{n,n}\} = P\{A\} \leq \sum_{i \neq j} P\{A_{ij}\} = 0.$$

b)

$$p_n = n!P\{X_1 < X_2 < \dots < X_n\} = n! \sum_{k_1=0}^{\infty} (1-p)p^{k_1} \sum_{k_2=k_1+1}^{\infty} (1-p)p^{k_2} \dots \sum_{k_n=k_{n-1}+1}^{\infty} (1-p)p^{k_n}.$$

$$p_n = \frac{n!(1-p)^n p^{n(n-1)/2}}{\prod_{k=1}^n (1-p)^k} = \frac{n!p^{n(n-1)/2}}{(1+p)(1+p+p^2)\dots(1+p+\dots+p^{n-1})}.$$

En particulier,

$$p_2 = \frac{2p}{1+p} \quad \text{and} \quad p_3 = \frac{6p^3}{(1+p)(1+p+p^2)}.$$

c) Les espérances et les variances de R(k)

$$ER(k) = \frac{n+1}{2}, \quad \text{Var} R(k) = \frac{(n-1)^2}{12}, \quad 1 \leq k \leq n.$$

Correction de l'exercice 02

1. Comme les X_i ont des densités par rapport à Lebesgues, on a $X_i \neq X_j$ λ -p.p.. Alors p.p.

$$f(X_{(1)}, \dots, X_{(n)}) = \sum_{\sigma \in \mathcal{P}(n)} f(X_{\sigma(1)}, \dots, X_{\sigma(n)}) I(X_{\sigma(1)} < \dots < X_{\sigma(n)}).$$

Soit $\sigma \in \mathcal{P}(n)$. Comme les X_i sont i.i.d., on voit que $(X_{\sigma(1)}, \dots, X_{\sigma(n)})^\top \sim (X_1, \dots, X_n)^\top$. Alors, pour tout $f \in \mathcal{C}_b(\mathbb{R}^n)$,

$$\begin{aligned} \mathbb{E}f(X_{\sigma(1)}, \dots, X_{\sigma(n)}) I(X_{\sigma(1)} < \dots < X_{\sigma(n)}) &= \mathbb{E}f(X_1, \dots, X_n) I(X_1 < \dots < X_n) \\ &= \int_{\mathcal{R}^n} f(x_1, \dots, x_n) \left(\prod_{i=1}^n f(x_i) \right) I(x_1 < \dots < x_n) dx_1 \dots dx_n. \end{aligned}$$

On en déduit que la loi de $(X_{(1)}, \dots, X_{(n)})$ admet une densité par rapport à Lebesgue donnée par

$$f(x_1, \dots, x_n) = n! \left(\prod_{i=1}^n f(x_i) \right) I(x_1 < \dots < x_n).$$

2. On calcul la fonction de répartition de $X_{(k)}$. Soit $t \in \mathcal{R}$,

$$\mathbb{P}[X_{(k)} \leq t] = \mathbb{P}[\exists I \subset \{1, \dots, n\} : |I| \geq k, \forall i \in I, X_i \leq t] = \mathbb{P}[M \geq k]$$

où $M = \sum_{i=1}^n I(X_i \leq t)$ est une multinomiale de paramètre n et $\mathbb{P}[X_1 \leq t] = F(t)$. On a donc

$$\mathbb{P}[X_{(k)} \leq t] = \sum_{j=k}^n \binom{n}{j} F(t)^j (1 - F(t))^{n-j}.$$

Comme F est absolument continue la cdf de $X_{(k)}$ l'est aussi. Donc $X_{(k)}$ admet une densité par rapport à Lebesgues donnée par :

$$\begin{aligned} f(t) &= \sum_{j=k}^n \binom{n}{j} (j f(t) F(t)^{j-1} (1 - F(t))^{n-j} + (n - j) F(t)^j (-f(t)) (1 - F(t))^{n-j-1}) \\ &= \frac{n!}{(k-1)!(n-k)!} F(t)^{k-1} (1 - F(t))^{n-k}. \end{aligned}$$

3. La fonction de répartition de $X_{(1)}$ vérifie :

$$1 - F_{X_{(1)}}(t) = \mathbb{P}[X_{(1)} > t] = \mathbb{P}[X_1 > t, \dots, X_n > t] = \left(\mathbb{P}[X_1 > t] \right)^n = (1 - F(t))^n.$$

La fonction de répartition de $X_{(n)}$ est donnée par :

$$F_{X_{(n)}}(t) = \mathbb{P}[X_{(n)} \leq t] = \mathbb{P}[X_1 \leq t, \dots, X_n \leq t] = \left(\mathbb{P}[X_1 \leq t] \right)^n = (F(t))^n.$$

Pour la fonction de répartition du couple $(X_{(1)}, X_{(n)})$, on calcul la répartition du couple $(X_{(1)}, X_{(n)})$ dans le quadrant inférieur droit. On a pour tout x, y réels :

$$\begin{aligned} \mathbb{P}[X_{(1)} > x, X_{(n)} \leq y] &= \mathbb{P}[x < X_1 \leq y, \dots, x < X_n \leq y] \\ &= \left(\mathbb{P}[x < X_1 \leq y] \right)^n = I(x \leq y) (F(y) - F(x))^n. \end{aligned}$$

On a :

$$\mathbb{P}[X_{(1)} > x, X_{(n)} \leq y] + \mathbb{P}[X_{(1)} \leq x, X_{(n)} \leq y] = \mathbb{P}[X_{(n)} \leq y] = F(y)^n.$$

Alors,

$$F(x, y) = \mathbb{P}[X_{(1)} \leq x, X_{(n)} \leq y] = F(y)^n - I(x \leq y)(F(y) - F(x))^n.$$

La densité de $(X_{(1)}, X_{(n)})$ est donnée par

$$f(x, y) = \frac{\partial^2 F}{\partial x \partial y}(x, y) = n(n-1)I(x \leq y)f(x)f(y)(F(y) - F(x))^{n-2}.$$

La loi de la statistique $W = X_{(n)} - X_{(1)}$ est donnée par ce qui suit. Soit $f \in \mathcal{C}_b(\mathcal{R})$, on a

$$\begin{aligned} \mathbb{E}f(W) &= \int_{\mathcal{R}^2} f(y-x) d\mathbb{P}^{(X_{(1)}, X_{(n)})}(x, y) \\ &= n(n-1) \int_{\mathcal{R}^2} f(y-x) I(x \leq y) (F(y) - F(x))^{n-2} dx dy \\ &= \int_0^\infty f(u) \left(n(n-1) \int_{\mathcal{R}} (F(u+x) - F(x))^{n-2} dx \right) du. \end{aligned}$$

Alors W a pour densité

$$u \mapsto I(u \geq 0) n(n-1) \int_{\mathcal{R}} (F(u+x) - F(x))^{n-2} dx.$$

Les variables $X_{(1)}$ et $X_{(n)}$ sont indépendantes si et seulement si pour tout x et y , on a

$$\begin{aligned} F(y)^n - I(x \leq y)(F(y) - F(x))^n &= \mathbb{P}[X_{(1)} \leq x, X_{(n)} \leq y] \\ &= \mathbb{P}[X_{(1)} \leq x] \mathbb{P}[X_{(n)} \leq y] = \left(1 - (1 - F(x))^n \right) F(y)^n. \end{aligned}$$

Il faut donc $I(x \leq y)(F(y) - F(x))^n = (F(y) - F(x))F(x))^n$ pour tout x, y . Ce qui n'est pas vrai en générale.

Correction de l'exercice 03

1) On a

$$F_{X_{(n)}}(x) = P(X_{(n)} \leq x) = P(\cap_{i=1}^n \{X_i \leq x\}) = \prod_{i=1}^n P(X_i \leq x) = F^n(x),$$

où l'avant dernière égalité est justifiée par l'indépendance entre les v.a.r. X_1, \dots, X_n . Cette fonction étant dérivable (puisque F l'est) sur \mathbb{R}^+ , la densité de X_n est :

$$f_{X_{(n)}}(x) = nF^{n-1}(x)f(x).$$

2) On a

$$P(X_{(1)} > x) = P(\cap_{i=1}^n \{X_i > x\}) = \prod_{i=1}^n P(X_i > x) = (1 - F(x))^n,$$

où l'avant dernière égalité est ici aussi justifiée par l'indépendance entre les v.a.r. X_1, \dots, X_n . D'où

$$F_{X_{(1)}}(x) = 1 - (1 - F(x))^n$$

et

$$f_{X_{(1)}}(x) = -n(1 - F(x))^{n-1}(-f(x)) = n(1 - F(x))^{n-1}f(x).$$

3) Supposons dans un premier temps que $x_1 \leq x_n$. On peut écrire :

$$\begin{aligned} P(X_{(1)} \leq x_1, X_{(n)} \leq x_n) &= P(X_{(n)} \leq x_n) - P(X_{(1)} > x_1, X_{(n)} \leq x_n) \\ &= F^n(x_n) - P(\cap_{i=1}^n \{X_i \in]x_1, x_n]\}) = F^n(x_n) - (F(x_n) - F(x_1))^n. \end{aligned}$$

En dérivant deux fois, on obtient

$$\begin{aligned} \frac{\partial F_{X_{(1)}, X_{(n)}}}{\partial x_1}(x_1, x_n) &= n(F(x_n) - F(x_1))^{n-1}f(x_1) \\ \text{et} \quad \frac{\partial^2 F_{X_{(1)}, X_{(n)}}}{\partial x_1 \partial x_n}(x_1, x_n) &= n(n-1)(F(x_n) - F(x_1))^{n-2}f(x_1)f(x_n). \end{aligned}$$

Maintenant si $x_1 > x_n$, on a

$$P(X_{(1)} \leq x_1, X_{(n)} \leq x_n) = P(X_{(n)} \leq x_n) = F^n(x_n)$$

qui en dérivant par rapport à x_1 et x_n s'annule. On a donc la densité du couple $(X_{(1)}, X_{(n)})$:

$$f_{(X_{(1)}, X_{(n)})}(x_1, x_n) = n(n-1)(F(x_n) - F(x_1))^{n-2}f(x_1)f(x_n)\mathbb{1}_{\{x_1 \leq x_n\}}.$$

Disposant de la densité du couple $(X_{(1)}, X_{(n)})$, pour trouver la densité de la v.a.r. $R = X_{(n)} - X_{(1)}$, on peut dans un premier calculer la densité du couple (Q, R) , où $Q = X_{(1)}$, et ensuite calculer la loi marginale de la seconde coordonnée de ce couple.

Le calcul de la loi du couple (Q, R) s'effectue facilement grâce à la formule du changement de variable. Prenons la fonction $\varphi(u, v) = (u, v - u)$ qui est évidemment

un \mathcal{C}^1 -difféomorphisme de fonction réciproque $\varphi^{-1}(y_1, y_2) = (y_1, y_1 + y_2)$. Le Jacobien de φ^{-1} est égal à 1. Ainsi la formule du changement de variable nous donne :

$$\begin{aligned} f_{Q,R}(q, r) &= f_{X_{(1)}, X_{(n)}}(\varphi^{-1}(q, r)) |J_{\varphi^{-1}}(q, r)| \mathbb{1}_{Im\varphi}(q, r) \\ &= n(n-1) (F(q+r) - F(q))^{n-2} f(q) f(q+r) \mathbb{1}_{\mathbb{R} \times \mathbb{R}^+}(q, r). \end{aligned}$$

La densité marginale de R est donc :

$$f_R(r) = \int_{\mathbb{R}^+} n(n-1) (F(q+r) - F(q))^{n-2} f(q) f(q+r) dq.$$

Sa f.d.r. est alors :

$$F_R(r) = \int_0^r f_R(x) dx.$$

4) On a

$$N_y = \sum_{i=1}^n \mathbb{1}_{X_i \leq y}.$$

Les v.a.r. $\mathbb{1}_{X_i \leq y}$, pour $i = 1, \dots, n$, étant i.i.d. de loi de Bernoulli de paramètre $F(y)$, la loi de N_y est une Binomiale de paramètres n et $F(y)$, i.e.

$$N_y \sim B(n, F(y)).$$

Par ailleurs, on a l'égalité entre les événements :

$$\{N_y \geq k\} = \{\text{Il y a un nombre supérieur ou égal à } k \text{ de } X_i \text{ inférieurs à } y\} = \{X_{(k)} \leq y\}.$$

Ainsi, il vient :

$$F_{X_{(k)}}(x) = P(X_{(k)} \leq x) = P(N_x \geq k) = \sum_{i=k}^n C_n^i (F(x))^i (1 - F(x))^{n-i}.$$

5) Calculons la probabilité $P(X_{(k)} \in]x, x + dx])$. Différents événements disjoints peuvent donner l'événement dont on veut calculer la probabilité :

- $k-1$ variables "tombent" dans l'intervalle $] -\infty, x]$, 1 variable dans l'intervalle $]x, x + dx]$ et $n-k$ dans l'intervalle $]x + dx, +\infty[$;
- $k-2$ variables "tombent" dans l'intervalle $] -\infty, x]$, 2 variables dans l'intervalle $]x, x + dx]$ et $n-k$ dans l'intervalle $]x + dx, +\infty[$;
- $k-1$ variables "tombent" dans l'intervalle $] -\infty, x]$, 2 variables dans l'intervalle $]x, x + dx]$ et $n-k-1$ dans l'intervalle $]x + dx, +\infty[$;
- $k-3$ variables "tombent" dans l'intervalle $] -\infty, x]$, 3 variables dans l'intervalle $]x, x + dx]$ et $n-k$ dans l'intervalle $]x + dx, +\infty[$;
- etc...

Le premier événement s'écrit :

$$\begin{aligned} &\{X_{(1)}, \dots, X_{(k-1)} \text{ sont inférieurs à } x, \\ &X_{(k)} \text{ est dans l'intervalle }]x, x + dx] \\ &\text{et } X_{(k+1)}, \dots, X_{(n)} \text{ sont supérieurs à } x + dx\} \end{aligned}$$

La probabilité $P_1(dx)$ de cet événement s'obtient aisément en remarquant que l'on est dans la situation d'un tirage d'une loi multinomiale à trois résultats possibles. Ainsi :

$$P_1(dx) = \frac{n!}{(k-1)!1!(n-k)!} (F(x))^{k-1} (F(x+dx) - F(x)) (1 - F(x+dx))^{n-k}.$$

D'où on tire :

$$\lim_{dx \rightarrow 0} \frac{P_1(dx)}{dx} = \frac{n!}{(k-1)!(n-k)!} (F(x))^{k-1} f(x) (1 - F(x))^{n-k}.$$

Regardons maintenant les probabilités des autres événements ci-dessus. Pour chacun d'entre eux, il y a au moins deux variables X_i qui se trouvent dans l'intervalle $]x, x+dx]$. La probabilité de ces événements contiendra donc un terme de la forme $(F(x+dx) - F(x))^m$ avec $2 \leq m \leq n$. Ces termes divisés par dx tendront alors vers 0 quand dx tend vers 0. Ainsi toutes les probabilités des événements autres que le premier de la liste précédente divisées par dx ont une limite qui tend vers 0 quand dx tend vers 0. On a donc :

$$f_{X_{(k)}}(x) = \lim_{dx \rightarrow 0} \frac{P(X_{(k)} \in]x, x+dx])}{dx} = \frac{n!}{(k-1)!(n-k)!} (F(x))^{k-1} f(x) (1 - F(x))^{n-k}.$$

6) Comme $F(x)$ et $1 - F(x)$ sont dans $[0, 1]$, on peut écrire :

$$\mathbb{E}|X_{(k)}| = \int_{\mathbb{R}} |x| f_{X_{(k)}}(x) dx \leq \frac{n!}{(k-1)!(n-k)!} \int_{\mathbb{R}} |x| f(x) dx = \frac{n!}{(k-1)!(n-k)!} \mathbb{E}|X|$$

dont on tire aisément le résultat voulu.

7) Notons Σ_n l'ensemble des permutations sur l'ensemble $\{1, 2, \dots, n\}$. Soit B un borélien de \mathbb{R}^n . On a :

$$\begin{aligned} P((X_{(1)}, \dots, X_{(n)}) \in B) &= \sum_{\sigma \in \Sigma_n} P(\{(X_{\sigma(1)}, \dots, X_{\sigma(n)}) \in B\} \cap \{X_{\sigma(1)} < \dots < X_{\sigma(n)}\}) \\ &= \sum_{\sigma \in \Sigma_n} \int_B \mathbb{1}_{u_1 < u_2 < \dots < u_n} \left(\prod_{i=1}^n f(u_i) \right) du_1 \dots du_n \\ &= \int_B n! \left(\prod_{i=1}^n f(u_i) \right) \mathbb{1}_{u_1 < u_2 < \dots < u_n} du_1 \dots du_n. \end{aligned}$$

Cette égalité étant vraie pour tout borélien B de \mathbb{R}^n , on en déduit que

$$f_{X_{(1)}, \dots, X_{(n)}}(u_1, \dots, u_n) = n! \left(\prod_{i=1}^n f(u_i) \right) \mathbb{1}_{u_1 < u_2 < \dots < u_n}.$$

Correction de l'exercice 04

Dans ce qui suit, X_1, \dots, X_n est un échantillon aléatoire simple et $Y_1 \leq \dots \leq Y_n$ sont les statistiques d'ordre.

1 Soit X_1, \dots, X_n un échantillon aléatoire simple d'une population exponentielle de paramètre β .

a) Montrer que Y_1 est de loi exponentielle de paramètre β/n .

$$G(y) = P(Y_1 \leq y) = 1 - P(Y_1 > y) = 1 - P(X_1 > y, \dots, X_n > y) = 1 - \left[e^{-y/\beta} \right]^n =$$

$1 - e^{-ny/\beta}$, ce qui est bien la fonction de répartition d'une exponentielle de paramètre β/n .

b) Montrer que la densité de Y_n est

$$g(y_n) = \frac{n}{\beta} e^{-y_n/\beta} [1 - e^{-y_n/\beta}]^{n-1}$$

$$G(y) = P(Y_n \leq y) = P(X_1 \leq y, \dots, X_n \leq y) = \left[1 - e^{-y/\beta} \right]^n. \text{ La fonction de densité}$$

$$\text{est } g(y) = G'(y) = \frac{n}{\beta} e^{-y/\beta} [1 - e^{-y/\beta}]^{n-1}$$

2 Soit X_1, \dots, X_n un échantillon aléatoire simple d'une population uniforme sur $(0 ; 1)$.

a) Déterminer les distributions de Y_1 et de Y_n .

La fonction de répartition de X est $F(x) = x$ sur $(0 ; 1)$.

$$G_1(y) = P(Y_1 \leq y) = 1 - P(Y_1 > y) = 1 - P(X_1 > y, \dots, X_n > y) = 1 - [1 - F(y)]^n = 1 - [1 - y]^n$$

$$G_n(y) = P(Y_n \leq y) = P(X_1 \leq y, \dots, X_n \leq y) = [F(y)]^n = y^n.$$

Pour trouver les fonctions de densité il suffit de dériver.

b) Déterminer la distribution de la médiane \tilde{x}

Nous supposons que $n = 2m+1$. Donc la médiane est la donnée de rang $m+1$. La fonction de densité est donc

$$h(\tilde{x}) = \frac{n!}{m!m!} [F(\tilde{x})]^m f(\tilde{x}) [1 - F(\tilde{x})]^m = \frac{n!}{m!m!} [\tilde{x}]^m [1 - \tilde{x}]^m$$

c) Déterminer l'espérance et la variance de Y_1

La fonction de densité de Y_1 est $g(y) = n(1-y)^{n-1}$ sur $(0,1)$. L'espérance de Y_1

$$\text{est } \int_0^1 x [n(1-x)^{n-1}] dx = \frac{1}{(n+1)}.$$