

Chapitre II : Générations d'échantillon suivant les différentes lois de probabilité

1. Introduction

Il y a 3 méthodes pour générer des variables aléatoires qui obéissent à une distribution donnée.

- Méthode d'inversion (cas continue et discret)
- Méthode de Rejet.
- Méthode de composition

2. Quelques résultats de probabilité

Soit U une V.a uniforme sur $[0, 1]$.

- i) si X une V.a de fonction de rep F_X alors $X = F_X^{-1}(u)$
- ii) $1-U = U'$ est une V.a uniforme sur $[0, 1]$
 $\Rightarrow Z_X = F_X^{-1}(1-u)$ a pour fonction de Rep F_X

Démonstration :

- i) Soit Y une V.a telle que $Y = F_X^{-1}(u)$ et on cherche la loi de Y ?
on suppose que X est continue, donc F_X est strictement croissante donc F_X^{-1} existe.

$$\forall y \in [0, 1]$$

$$\begin{aligned}
 F_Y(y) &= P(Y \leq y) = P(F_X^{-1}(u) \leq y) = P(u \leq F_X(y)) \\
 &= F_u(F_X(y)) = F_X(y) = y = x = F_X^{-1}(u) \\
 &= F_X(y) \text{ car } u \sim U(0,1)
 \end{aligned}$$

Donc la v.a Y a pour fonction de répartition F_X (même fonction que X).

$$\Rightarrow X = Y = F_X^{-1}(u)$$

(ii). $F_T(x) = P(T \leq t)$ avec $T = F_X^{-1}(1-u)$

$$\begin{aligned}
 F_T(x) &= P(T \leq t) = P(F_X^{-1}(1-u) \leq t) = P(1-u \leq F_X(t)) \\
 &= F_u(F_X(t)) = F_X(t) \Rightarrow X = T = F_X^{-1}(1-u)
 \end{aligned}$$

2-2 Application à la génération d'échantillon

Soyent (u_1, \dots, u_n) n réalisations iid issues d'une v.a $U[0,1]$ alors :

$x_1 = F_X^{-1}(u_1), x_2 = F_X^{-1}(u_2), \dots, x_n = F_X^{-1}(u_n)$ sont considérées comme n réalisations indépendante de la v.a X de fonction de répartition F_X .

2-2-1 Application aux lois de probabilité

Méthode d'inversion (cas continu)

La méthode d'inversion est aussi appelée la méthode de transformation, elle n'est utilisée que si la fonction de densité est connue. Analytiquement est peut être intégrée facilement.

- Cas de la loi Uniforme:

Soit $X \sim U[a, b]$ sa densité est donnée

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in [a, b] \\ 0 & \text{sinon} \end{cases}$$

$$F_X(x) = \begin{cases} 0 & \text{si } x \leq a \\ \frac{x-a}{b-a} & \text{si } x \in [a, b] \\ 1 & \text{si } x \geq b. \end{cases}$$

Comme $X = F_X^{-1}(u) \Leftrightarrow F_X(u) = u \quad \forall x \in [a, b]$

$$\Rightarrow \frac{x-a}{b-a} = u \Rightarrow x = (b-a)u + a.$$

$$x = (b-a)u + a \quad u \sim U[0, 1].$$

Conclusion:

Pour simuler une v.a uniforme sur $[a, b]$ il suffit de générer des nombres aléatoires U_i de v.a uniforme sur $[0, 1]$ et puis on déduira les réalisations x_i :

$$x_i = (b-a)U_i + a$$

- Cas de la loi exponentielle :

Soit X une v.a qui suit la loi exponentielle de paramètre λ , sa fonction de densité est :

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{sinon.} \end{cases}$$

Calcul de la fonction de répartition.

$$F_X(x) = \begin{cases} 1 - e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{sinon.} \end{cases}$$

Comme $X = F_X^{-1}(u) \Leftrightarrow F_X(x) = u$

$$= 1 - e^{-\lambda x} \quad \forall x \geq 0.$$

$$\Rightarrow e^{-\lambda x} = 1 - u \Rightarrow x = -\frac{1}{\lambda} \log(1-u)$$

Comme $U \sim U[0,1]$ alors $1-U \sim U[0,1]$

$$\Rightarrow x = -\frac{1}{\lambda} \log(u) \quad \text{où } U \sim U[0,1]$$

Conclusion.

Pour simuler une v.a $\exp(\lambda)$, il suffit de générer des nombres aléatoires U_i de v.a. Uniforme sur $[0,1]$ et puis on déduira la réalisation x_i t.q

$$x_i = -\frac{1}{\lambda} \log(U_i)$$

Méthode d'inversion "Cas discret" méthode "tophat"

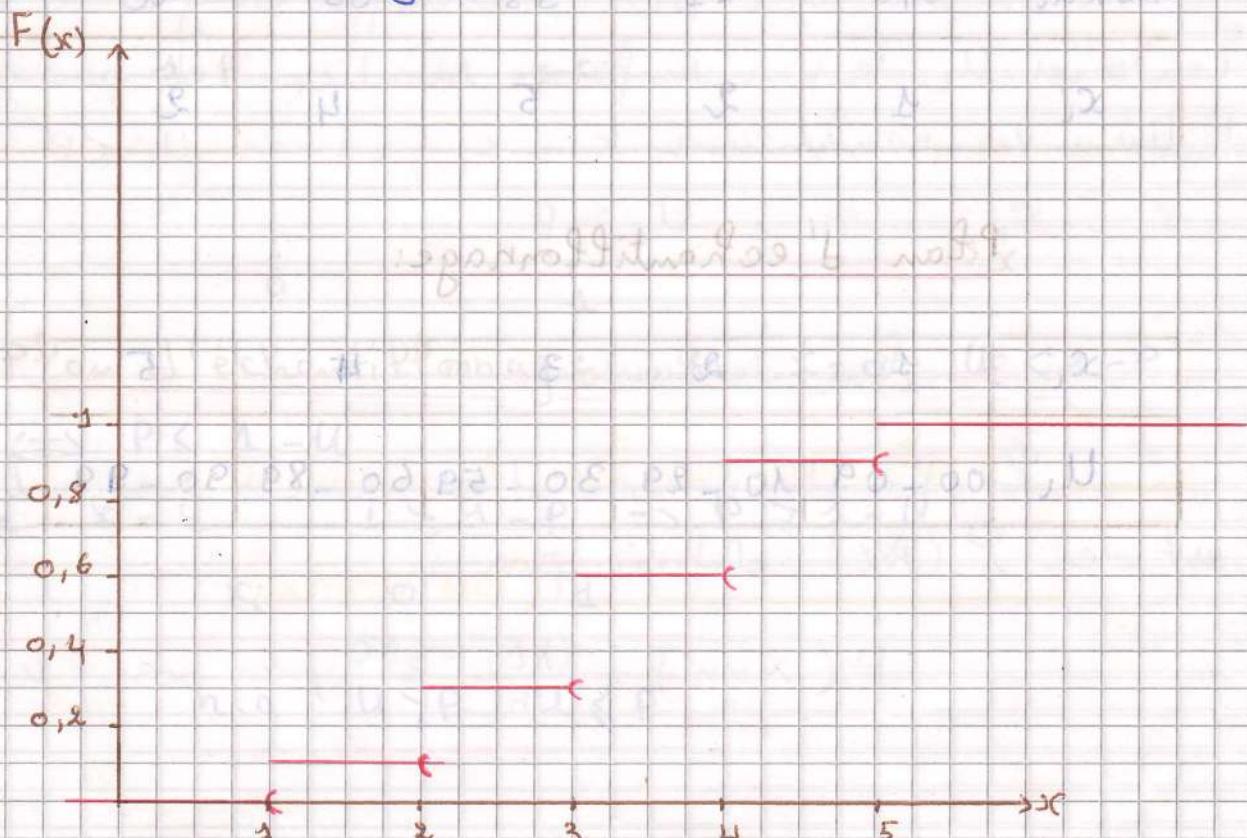
Que l'on ait une distribution de probabilité théorique ou une distribution empirique la méthode de génération est la même supposons que l'on veut générer un échantillon de la loi de probabilité suivante:

x_i	1	2	3	4	5	Total
n_i	10	20	30	30	10	$n = 100$
$f_i = \frac{n_i}{n}$	0,1	0,2	0,3	0,3	0,1	1

Calculer la fonction de Répartition de cette distribution

x	$x < 1$	$1 \leq x < 2$	$2 \leq x < 3$	$3 \leq x < 4$	$4 \leq x < 5$	$x \geq 5$
$F(x)$	0	0,1	0,3	0,6	0,9	1

on trace le graphe de la fonction de Répartition



Plan d'échantillonnage.

a -

x	1	2	3	4	5
n.a	$0 \leq U_i < 0,1$	$0,1 \leq U_i < 0,3$	$0,3 \leq U_i < 0,6$	$0,6 \leq U_i < 0,9$	$0,9 \leq U_i < 1$

On utilisant les n.a données :

$$\text{Soient } U_i \quad i=1,5 \quad U_1 = 0,02 ; U_2 = 0,05$$

$$U_3 = 0,98 ; U_4 = 0,50 ; U_5 = 0,41$$

L'échantillon de la V.a x est donnée par :

U_i	0,02	0,05	0,98	0,50	0,41
x_i	1	1	5	3	3

Supposons que j'ai la suite de n.a suivante:

$100 \times U_i$	0,9	11	98	68	20
x_i	1	2	5	4	2

Plan d'échantillonnage:

x_i	1	2	3	4	5
U_i	00 - 09	10 - 29	30 - 59	60 - 89	90 - 99

4- Génération d'échantillon de v.a discrets

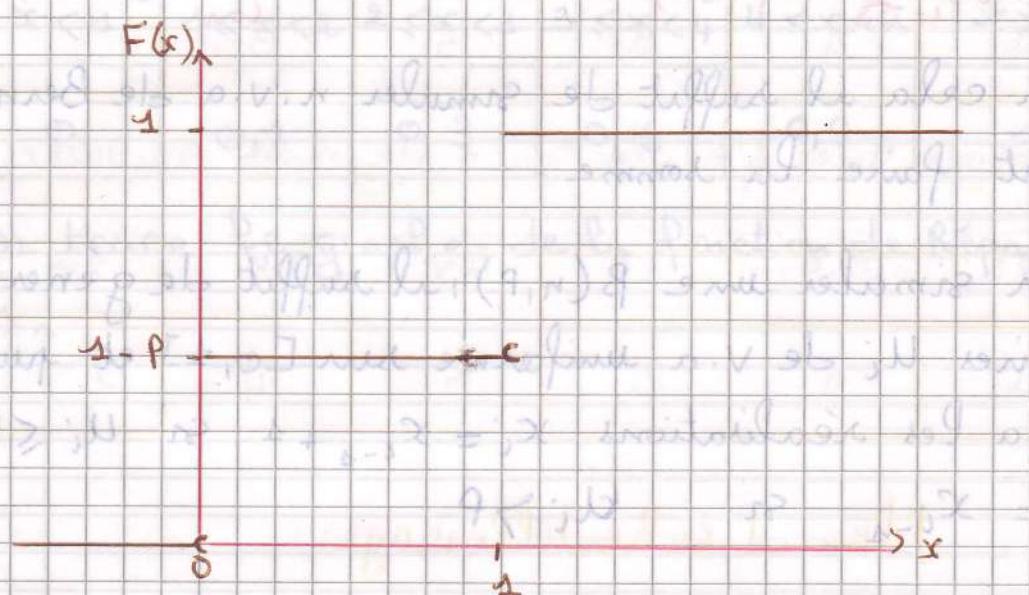
4-1- loi de Bernoulli de paramètre 'P'

Soit X une v.a \sim Bernoulli de paramètre P .

La loi de probabilité de X est :

$$\begin{cases} \text{P}(X=1) = P \\ \text{P}(X=0) = 1-P \end{cases}$$

x	$-\infty, 0 \subset [0, 1] \subset [1, +\infty]$
$F_X(x)$	0 $1-P$ 1



Plan d'échantillonnage : si $x=0$, $U_i < 1-P$

$$\Leftrightarrow P < 1-U$$

• si $x=1$ $U \geq 1-P \Rightarrow P \geq 1-U$

x_i	0	1
n.a.	$U > P$	$U \leq P$

Pour simuler les v.a de la loi de Bernoulli, il suffit de générer des v.a U_i de v.a uniforme sur $[0,1]$ puis on déduit les réalisations de x_i tellesque:

$$\begin{cases} x_i = 0 & \text{si } U_i > p \\ x_i = 1 & \text{si } U_i \leq p \end{cases}$$

4-2- Loi Binomiale:

On utilise le fait que la somme de n.v.a de loi de Bernoulli de paramètre p suit la loi Binomiale de paramètre n, p .

$$(x_i)_{i=1}^n \xrightarrow{\sim} B(p) \text{ alors } X = \sum_{i=1}^n x_i \xrightarrow{\sim} B(n, p)$$

Pour cela il suffit de simuler n.v.a de Bernoulli et dont faire la somme.

Pour simuler une $B(n, p)$, il suffit de générer des nombres aléatoires U_i de v.a uniforme sur $[0, 1]$ et puis on déduira les réalisations $x_i = x_{i-1} + 1$ si $U_i \leq p$ ou $x_i = x_{i-1}$ si $U_i > p$

4-3- Loi de Poisson:

La loi du nombre d'occurrences pendant $[0, t]$ est de $P(\Delta t)$, définie par :

$$P(X=n) = \frac{(\lambda t)^n}{n!} e^{-\lambda t}, \text{ on pose } \mu = \lambda t$$

on a

$$\prod_{i=1}^{n+1} u_i < e^{-\mu} < \prod_{i=1}^n u_i$$

Pour simuler une V.a de $P(\mu)$ il suffit de générer de nombre aléatoire de V.a Uniforme $[0,1]$ et puis on multiplie entre elles, les observations obtenus. On arrête le processus dès que le produit obtenu devient inférieur à $e^{-\mu}$. et on déduit alors une réalisation n et on recommence pour une autre réalisation.

4.3 - La loi de Erlang :

Soit X une V.a qui suit une loi $Erg(k, \lambda)$ ($\text{Gamma}(k, \frac{\lambda}{k})$)

Fq:

$$F_X(x) = \begin{cases} 1 - \sum_{m=0}^{k-1} \frac{(\lambda x)^m}{m!} e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{sinon.} \end{cases}$$

$X_i \sim Exp(\lambda)$

$$X = \sum_{i=1}^k X_i \left(-\frac{1}{\lambda} \right) \ln(u_i)$$

$$= -\frac{1}{\lambda} \sum_{i=1}^k \ln(u_i)$$

$$x = -\frac{1}{\lambda} \ln \left(\prod_{i=1}^k u_i \right)$$

Pour simuler une V.a Erg (κ, λ) il suffit de générer κ nombres aléatoires et calculer :

$$x = -\frac{1}{\lambda} \ln \prod_{i=1}^{\kappa} u_i$$

5- Génération d'échantillons de la loi normale:

Dans le cas de la loi normale, la méthode d'inversion n'est pas utilisable à cause de l'expression de la fonction de répartition.

5.1. Méthode approximation.

Cette méthode est basé sur le théorème central limite.

Théorème central limite:

Soient Z_1, Z_2, \dots, Z_k , k v.a $\perp \! \! \! \perp$ ($\perp \! \! \! \perp$ indépendante) et de même loi tq:

$$\begin{cases} E(Z_i) = 0 \\ \text{Var}(Z_i) = \sigma^2 \end{cases}$$

Parce que $k \rightarrow +\infty$, la v.a $y = \frac{\sum_{i=1}^k Z_i - k\bar{\theta}}{\sigma \sqrt{k}} \sim N(0, 1)$

* Alors y_i sont des réalisations aléatoires générées approximativement suivant une loi $N(0, 1)$

$$y_i = \frac{\sum_{i=1}^k Z_i - k\bar{\theta}}{\sigma \sqrt{k}}$$

**) Supposons que les k.v.a z_i sont uniformes sur $[a, b]$

$$z_i \sim U[a, b]$$

$$E(z_i) = \theta = \frac{a+b}{2}, \quad \text{Var}(z_i) = \sigma^2 = \frac{(b-a)^2}{12}$$

$$\Rightarrow \sigma^2 = \frac{b-a}{12} \quad \text{on remplace dans (*)} \text{ on obtient}$$

$$y_i = \frac{\left(\sum_{i=1}^k z_i - k \left(\frac{a+b}{2} \right) \sqrt{\frac{1}{12}} \right)}{(b-a) \sqrt{k}} \text{ sont des n.a générés}$$

approximativement de la loi $N(0, 1)$

***) Supposons que les k.v.a z_i sont \mathcal{U} et $\text{unif}[0, 1]$ qu'on note u_1, \dots, u_k on a :

$$\theta = \frac{1}{2}, \quad \sigma^2 = \frac{1}{12} \quad \text{et on remplaçant dans (**)}$$

On obtient :

$$y_i = \frac{\sum_{i=1}^k z_i - \frac{k}{2}}{\sqrt{\frac{k}{12}}} \text{ qui sont des n.a générés approx de la loi } N(0, 1)$$

Remarque:

À partir de $k = 12$, on obtient une bonne approximation

$$y_i = \sum_{i=1}^{12} u_i - 6 \text{ sont des n.a générés approx de}$$

$$N(0, 1).$$

Pour obtenir un échantillon de v.a $X \sim N(\mu, \sigma^2)$ on obtient le changement de variable suivant :

$$Y = \frac{X + \mu}{\sigma} \Rightarrow X = \sigma Y + \mu.$$

Donc $X_i = \sigma \left(\sum_{i=1}^{12} U_i - 6 \right) + \mu$ sont des n.a générés approximativement de la loi $N(\mu, \sigma^2)$.

5-2. Méthode de Box Muller:

Cette méthode est plus rapide que les précédentes et produit des couples de réalisations aléatoires exactes,

Saient X et Y deux variables aléatoires \mathbb{U} qui suivent la même loi $N(0, 1)$ et soit $f(x, y)$ la densité conjointe du couple (X, Y) définie par :

$$f(x, y) = \frac{1}{2\pi} e^{-\frac{(x^2+y^2)}{2}} \quad \text{où } (x, y) \in \mathbb{R}^2$$

On transforme x et y en coordonnée polaire et on obtient :

$$\begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases} \Rightarrow \begin{cases} r^2 = x^2 + y^2 \\ \theta = \operatorname{arctg} \left(\frac{y}{x} \right) \end{cases}$$

Montrer que les v.a. θ et $\frac{r^2}{2}$ sont \mathbb{U} ?

La densité conjointe du couple (R, θ)

$$f(r, \theta) dr d\theta = \frac{1}{2\pi} e^{-\frac{r^2}{2}} r dr d\theta$$

$$\text{Comme } \frac{d\left(\frac{r^2}{2}\right)}{dr} = r \Rightarrow r dr = d\left(\frac{r^2}{2}\right)$$

$$\Rightarrow f(r, \theta) dr d\theta = \frac{1}{2\pi} e^{-\frac{r^2}{2}} d\left(\frac{r^2}{2}\right) d\theta = f\left(\frac{r^2}{2}, \theta\right) d\left(\frac{r^2}{2}\right) d\theta$$

on pose : $f\left(\frac{r^2}{2}\right) = e^{-\frac{r^2}{2}}$ donc $\frac{R^2}{2} \sim \text{Exp}(1)$

et $f(\theta) = \frac{1}{2\pi}$ donc $\theta \sim U[0, 2\pi]$

on déduit $f\left(\frac{r^2}{2}, \theta\right) = f\left(\frac{r^2}{2}\right) \times f(\theta) \Rightarrow \frac{R^2}{2}$ et θ sont $\perp\!\!\!\perp$.

Supposons que l'on génère 2 fois uniforme U_1 et U_2 et il sui $[0,1]$ en posant :

$$U_1 = e^{-\frac{R^2}{2}}, U_2 = \frac{\theta}{2\pi}.$$

$$\begin{cases} r = \sqrt{-2 \ln U_1} \\ \theta = 2\pi U_2 \end{cases}$$

on produira un couple de n.a. (x, y) $\perp\!\!\!\perp$ de loi $N(0, 1)$

Eq :

$$\begin{cases} x = r(\sqrt{-2 \ln(U_1)} \cos(2\pi U_2)) + m \\ y = r(\sqrt{-2 \ln(U_1)} \sin(2\pi U_2)) + m. \end{cases}$$

Montrons que U_1 et U_2 sont $\perp\!\!\!\perp$ et suivent la loi $unif(0,1)$

* $\perp\!\!\!\perp$ de U_1 et U_2 : car $\frac{R^2}{2}$ et θ sont $\perp\!\!\!\perp$.

* $U_1 \sim U[0, 1] ?$

$t > 0$

$$F_{U_1}(t) = P(U_1 < t) = P\left(e^{-\frac{R^2}{2}} < t\right) = P\left(-\frac{R^2}{2} < -\log t\right)$$

$$= P\left(\frac{R^2}{2} \geq -\log t\right) = 1 - (1 - e^{-(-\log t)}) = t$$

* $U_2 \sim U[0, 1]$

$$\begin{aligned} P_{U_2}(u_2) &= P(U_2 < u_2) = P\left(\frac{\theta}{2\pi} < u_2\right) = P(\theta < 2\pi u_2) \\ &= F_\theta(2\pi u_2) = u_2 \end{aligned}$$

5-3- Méthode de BoxMuller (Méthode PoLaine)

Cette méthode n'utilise pas les fonctions trigonométriques elle est donc plus rapide que la précédente.

on considère deux V.a V_1 et $V_2 \sim U[-1, 1]$ et $W \sim U[0, 1]$ tel que :

$$w = V_1^2 + V_2^2 \text{ et } W \leq 1.$$

on déroule l'algorithme suivant :

1. Tirer deux nombres aléatoires V_1 et V_2 suivant $U[-1, 1]$
2. Si $w = (V_1^2 + V_2^2) \geq 1$, Alors retourner vers ①
3. Sinon

$$x = \sigma(V_2 \sqrt{-2 \ln(w)/w}) + m$$

$$y = \sigma(V_1 \sqrt{-2 \ln(w)/w}) + m.$$

6- Méthode de Rejet:

Soit X une V.a de fonction de densité $f(x)$, si $f(x)$ est bornée et x appartient aux domaines bornés aussi $a \leq x \leq b$ alors la méthode de rejet peut être utilisée, elle se résume en 4 étapes :

1. normaliser le domaine de f à l'aide d'une échelle "C" de telle sorte que :

$$g(x) = C [f(x)] \leq 1 \quad \text{si } a \leq x \leq b$$

2. Définir x comme fonction linéaire de u .

$$x = a + (b-a)u$$

3. Engendrer (générer) une paire de nombres aléatoires (u_1, u_2)

4- Chaque fois que l'on rencontre une paire de n.a satisfaisants $x_2 \leq c [f(x_1)] = c [f(a + (b-a)U_1)]$ on accepte $x = a + (b-a)U_1$ comme valeur de la v.a X de densité f(x)

Exemple:

Sait X une v.a $\sim \text{Beta}(\alpha=0, \beta=1)$

$$f(x) = 2x \quad \text{si } 0 \leq x \leq 1$$

On est dans le cas où $a=0$ et $b=1$.

$$1. \text{ On } C = \frac{1}{2}, \text{ on a } g(x) = \frac{1}{2} f(x) = x \leq 1.$$

$$2. x = a + (b-a)u \Rightarrow g(u) = \frac{1}{2} f(u)$$

3. on génère un n.a U_1 et on calcule $g(U_1) = \frac{1}{2} f(U_1)$
on génère un autre n.a U_2 et on le compare à $g(U_1)$

4- Si $U_2 \leq g(U_1)$ on accepte U_1 comme réalisation x de la v.a X possédant comme fonction densité f(x).

Si $U_2 > g(U_1)$ on rejette U_1 et on retourne à l'étape 3

Soient $0,09 - 0,65$

$$g(U_1) = U_1 = 0,09$$

$$g(U_2) = U_2 = 0,65$$

Comme $U_2 > 0,09$ on rejette $U_1 = 0,09$

$$U_1 = 0,69, \quad U_2 = 0,66$$

$$g(U_1) = U_1 = 0,69$$

Comme $U_2 < 0,69$, on accepte $U_1 = 0,69$

Donc $x = u_1 = 0,69$ est une réalisation de X de fonction de densité Beta.

Méthode de décomposition

Cette méthode a remplacer $f(x)$ par un mélange probabiliste de fonct de densité $g_n(x)$ judicieusement choisis. Autrement dit elle exploite une relation du type $\sum_n g_n(x) \times p_n$.

Exemple:

Soit la v.a. X de densité de probabilité :

$$f(x) = \begin{cases} \frac{\alpha}{2} e^{-x} + \frac{1-\alpha}{2} e^{-\frac{x}{2}} + \frac{\alpha}{6} e^{-\frac{x}{3}} & \text{si } x \geq 0 \\ 0 & \text{sinon.} \end{cases}$$

$$\text{On a : } f(x) = \frac{\alpha}{2} e^{-x} + (1-\alpha)\left(\frac{1}{2} e^{-\frac{x}{2}}\right) + \frac{\alpha}{6}\left(\frac{1}{3} e^{-\frac{x}{3}}\right)$$

Alors on définit la v.a. discrète Y tq :

$Y=y$	1	2	3
$P(Y=y)$	$\frac{\alpha}{2}$	$1-\alpha$	$\frac{\alpha}{2}$

Et on définit aussi les variables aléatoires :

$$X_1 \sim \text{Exp}(1); X_2 \sim \text{Exp}\left(\frac{1}{2}\right)$$

$$X_3 \sim \text{Exp}\left(\frac{1}{3}\right)$$