

Théorie de l'estimation

Université Hassiba Benbouali de Chlef

Définition d'un estimateur

Définition 1.1

Un **estimateur** d'une grandeur θ est une **statistique** $\hat{\theta}_n$ à valeurs dans l'ensemble des valeurs possibles de θ . Une estimation de θ est une réalisation de l'estimateur $\hat{\theta}_n$.

Exemple

Le nombre moyen de guérisons est un estimateur "naturel" de la probabilité p :

$$\hat{p}_n := \frac{1}{n} \sum_{i=1}^n X_i$$

Estimateur

On ne dispose que de la valeur de l'estimateur prise en les observations : $\hat{\theta}_n = \varphi(x_1, \dots, x_n)$

Exemples

- ▶ Efficacité d'un médicament : $\hat{p}_n := \frac{1}{n} \sum_{i=1}^n x_i = 0.81$
- ▶ Durées de vie d'ampoules : $\hat{\lambda}_n := \frac{n}{\sum_{i=1}^n x_i} = 0.033$

- ▶ On souhaite que cette estimation soit proche du paramètre inconnu
- ▶ Quelle confiance avoir en cette estimation ?

Pour le savoir, on étudie les propriétés théoriques de l'estimateur

- ▶ Propriétés à n fixé : biais, variance, risque quadratique
- ▶ Propriétés asymptotiques ($n \rightarrow +\infty$) : convergence, vitesse

Qualité d'un estimateur

Définition 1.2

On appelle **biais** de l'estimateur $\hat{\theta}_n$ la fonction $\mathbb{B}_n(\theta) = \mathbb{E}[\hat{\theta}_n] - \theta$.

- ▶ Un estimateur $\hat{\theta}_n$ de θ est **sans biais** si et seulement si $\mathbb{B}_n(\theta) = 0$.
- ▶ $\hat{\theta}_n$ est un estimateur **asymptotiquement sans biais** pour le paramètre θ , si pour tout $\theta \in \Theta$

$$\lim_{n \rightarrow +\infty} \mathbb{B}_n(\theta) = 0$$

Qualité d'un estimateur (suite)

Exemples

Qualité d'un estimateur (suite)

- ▶ \bar{X}_n est un estimateur sans biais de la moyenne de la population m car $\mathbb{E}[\bar{X}_n] = m$.
- ▶ S_n^2 est un estimateur biaisé de la variance de la population σ^2 , son biais est égale à :

$$\mathbb{B}_n(\sigma^2) = \mathbb{E}[S_n^2] - \sigma^2 = \frac{n-1}{n}\sigma^2 - \sigma^2 = \frac{-\sigma^2}{n}.$$

- ▶ S_n^2 est un estimateur asymptotiquement sans biais pour σ^2 ,

$$\lim_{n \rightarrow +\infty} \mathbb{B}_n(\sigma^2) = \lim_{n \rightarrow +\infty} \frac{-\sigma^2}{n} = 0.$$

Qualité d'un estimateur (suite)

Définition 1.3

Le **risque quadratique** ou **erreur quadratique moyenne** est :

$$EQM(\hat{\theta}_n) = \mathbb{E} \left[(\hat{\theta}_n - \theta)^2 \right]$$

Définition 1.4

L'estimateur $\hat{\theta}_n$ converge en moyenne quadratique vers θ si et seulement si son erreur quadratique moyenne tend vers 0 quand n tend vers l'infini :

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{MQ} \theta \Leftrightarrow \lim_{n \rightarrow +\infty} \mathbb{E} \left[(\hat{\theta}_n - \theta)^2 \right] = 0.$$

Qualité d'un estimateur (suite)

L'erreur quadratique moyenne s'écrit :

$$\begin{aligned}
 EQM(\hat{\theta}_n) &= \mathbb{E} \left[(\hat{\theta}_n - \theta)^2 \right] = \mathbb{E} \left[\left(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n] + \mathbb{E}[\hat{\theta}_n] - \theta \right)^2 \right] \\
 &= \mathbb{E} \left[\left(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n] \right)^2 \right] + 2\mathbb{E} \left[\left(\hat{\theta}_n - \mathbb{E}[\hat{\theta}_n] \right) \right] \mathbb{E} \left[\left(\mathbb{E}[\hat{\theta}_n] - \theta \right) \right] \\
 &\quad + \mathbb{E} \left[\left(\mathbb{E}[\hat{\theta}_n] - \theta \right)^2 \right] \\
 &= \text{Var}[\hat{\theta}_n] + \left(\mathbb{E}[\hat{\theta}_n] - \theta \right)^2 \\
 &= \text{Variance de l'estimateur} + \text{carré de son biais}
 \end{aligned}$$

Qualité d'un estimateur (suite)

Remarque

Si $\hat{\theta}_n$ est un estimateur sans biais, $EQM(\hat{\theta}_n) = \text{Var}[\hat{\theta}_n]$.

La moyenne empirique

La moyenne empirique \bar{X}_n est un estimateur sans biais et convergent en moyenne quadratique de $\mathbb{E}[X]$.

Qualité d'un estimateur (suite)

Définition 1.5

Soient T_1 et T_2 deux estimateurs de θ , si $EQM(T_1) \leq EQM(T_2)$, $\forall \theta \in \Theta$, on dit alors que T_1 est préférable à T_2 , si l'inégalité est stricte, on dira que T_1 est strictement préférable à T_2 .

Le meilleur estimateur possible de θ est un estimateur sans biais et de variance minimale (**ESBVM**).

Théorème de Rao-Blackwell

Théorème 1.6

S'il existe une statistique exhaustive T et un estimateur sans biais $\hat{\theta}_n$ de θ , alors $Z = \mathbb{E}[\hat{\theta}_n|T]$ est un estimateur sans biais de θ , de variance inférieure à celle de $\hat{\theta}_n$.

Théorème de Lehmann-Scheffé

Théorème 1.7

Si $\hat{\theta}_n$ est un estimateur sans biais de θ et T est une statistique exhaustive et complète, alors $Z = \mathbb{E}[\hat{\theta}_n|T]$ est l'unique estimateur sans biais de θ , de variance minimale parmi tous les estimateurs sans biais de θ .

Corollaire

Pour trouver un estimateur optimal, il suffit de trouver un estimateur **sans biais** fonction d'une statistique **exhaustive** et **complète**.

Modèle de Bernoulli

La moyenne empirique $\hat{p}_n = \bar{X}_n$ fonction de la statistique exhaustive et complète $\sum_{i=1}^n X_i$ c'est l'**ESBVM** de p .

Exemple

Information de Fisher

Définition 1.8

Pour $\theta \in \mathbb{R}$, si la loi des observations vérifie les conditions de régularité, on appelle **quantité d'information** (de Fisher) sur θ apportée par l'échantillon X_1, \dots, X_n , la quantité :

$$\mathcal{I}_n(\theta) = \text{Var} \left[\frac{\partial \ln \mathcal{L}(\theta, X_1, \dots, X_n)}{\partial \theta} \right]$$

Information de Fisher (suite)

On peut montrer que $\mathbb{E} \left[\frac{\partial \ln \mathcal{L}(\theta, X_1, \dots, X_n)}{\partial \theta} \right] = 0$. Par conséquent, la quantité d'information peut aussi s'écrire sous la forme :

$$\mathcal{I}_n(\theta) = \mathbb{E} \left[\left(\frac{\partial \ln \mathcal{L}(\theta, X_1, \dots, X_n)}{\partial \theta} \right)^2 \right]$$

On montre que l'on a également :

$$\mathcal{I}_n(\theta) = -\mathbb{E} \left[\frac{\partial^2 \ln \mathcal{L}(\theta, X_1, \dots, X_n)}{\partial \theta^2} \right]$$

Cette écriture peut s'avérer pratique pour les calculs.

Information de Fisher (suite)

Échantillon de loi Bernoulli

$$\begin{aligned} \mathcal{I}_n(p) &= \text{Var} \left[\frac{\partial \ln \mathcal{L}(p, X_1, \dots, X_n)}{\partial p} \right] = \text{Var} \left[\frac{\sum_{i=1}^n X_i - np}{p(1-p)} \right] \\ &= \frac{\text{Var} \left[\sum_{i=1}^n X_i \right]}{p^2(1-p)^2} = \frac{np(1-p)}{p^2(1-p)^2} = \frac{n}{p(1-p)}. \end{aligned}$$

Inégalité de Fréchet-Darmois-Cramer-Rao (FDCR)

Si la loi des observations vérifie les conditions de régularité, alors pour tout estimateur $\hat{\theta}_n$ de θ , on a :

$$\text{Var}[\hat{\theta}_n] \geq \frac{\left[\frac{\partial}{\partial \theta} \mathbb{E}[\hat{\theta}_n] \right]^2}{\mathcal{I}_n(\theta)}.$$

Remarque

- ▶ Si $\hat{\theta}_n$ est un estimateur sans biais de θ , alors $\mathbb{E}[\hat{\theta}_n] = \theta$, donc
$$\text{Var}[\hat{\theta}_n] \geq \frac{1}{\mathcal{I}_n(\theta)}.$$
- ▶ La quantité $\frac{1}{\mathcal{I}_n(\theta)}$ est appelée la **borne de Cramer-Rao**.

Estimateur efficace

- ▶ Un estimateur **efficace** est un estimateur pour lequel l'inégalité FDCR est une égalité.
- ▶ Si un estimateur sans biais est efficace, alors il est forcément de variance minimale et sa variance est égale à la borne de Cramer-Rao.

Exemple

La moyenne empirique $\hat{p}_n = \bar{X}_n$ est un estimateur efficace. En effet,

$$\text{Var}[\bar{X}_n] = \frac{\text{Var}[X]}{n} = \frac{p(1-p)}{n} = \frac{1}{\mathcal{I}_n(p)}$$

Méthodes d'estimation

- ▶ Méthode des moments
- ▶ Maximum de vraisemblance

Méthode des moments

Soit $\varphi = (\varphi_1, \dots, \varphi_k)$ une application de \mathcal{X} dans \mathbb{R}^k , telle que l'application :

$$\begin{aligned}\Phi : \Theta &\longrightarrow \mathbb{R}^k \\ \theta &\longmapsto \mathbb{E}[\varphi(x)] = \Phi(\theta).\end{aligned}$$

soit injective.

On définit l'estimateur $\hat{\theta}_n$ comme solution dans Θ (quand elle existe) de l'équation :

$$\Phi(\theta) = \frac{1}{n} \sum_{i=1}^n \varphi(X_i).$$

Méthode des moments (suite)

Souvent lorsque $\mathcal{X} \subset \mathbb{R}$, la fonction qu'on prend est $\varphi_i(x) = x^i$ et Φ correspond donc au $i^{\text{ème}}$ moment de la variable X . On résout le système d'équation suivant :

$$\left\{ \begin{array}{lcl} \mathbb{E}[X] & = & \frac{1}{n} \sum_{i=1}^n X_i \\ \mathbb{E}[X^2] & = & \frac{1}{n} \sum_{i=1}^n X_i^2 \\ \vdots & & \vdots \\ \mathbb{E}[X^k] & = & \frac{1}{n} \sum_{i=1}^n X_i^k \end{array} \right.$$

Le modèle de Bernoulli

L'estimation par la méthode des moments consiste à résoudre l'équation :

$$\mathbb{E}[X] = \frac{1}{n} \sum_{i=1}^n X_i \Leftrightarrow p = \bar{X}_n,$$

alors

$$\hat{p}_n = \bar{X}_n.$$

Loi exponentielle

On a

$$\mathbb{E}[X] = \frac{1}{\lambda},$$

l'estimateur par moment associé s'écrit

$$\hat{\lambda}_n = \frac{1}{\overline{X}_n}.$$

Le modèle Uniforme $\mathcal{U}[0, \theta]$

On résout l'équation :

$$\begin{aligned}\mathbb{E}[X] &= \bar{X}_n \\ \Rightarrow \frac{\theta}{2} &= \bar{X}_n \\ \Rightarrow \hat{\theta}_n &= 2\bar{X}_n\end{aligned}$$

Le modèle Normal $\mathcal{N}(m, \sigma^2)$

On résout le système d'équations :

$$\begin{cases} \mathbb{E}[X] = \bar{X}_n \\ \mathbb{E}[X^2] = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases} \Rightarrow \begin{cases} m = \bar{X}_n \\ m^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

on obtient :

$$\begin{cases} \hat{m} = \bar{X}_n \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X}_n)^2 \end{cases}$$

Estimateur du maximum de vraisemblance

Soit X_1, \dots, X_n i.i.d. de loi \mathbb{P}_θ , $\{\mathbb{P}_\theta, \theta \in \Theta\}$ dominée, $\Theta \subset \mathbb{R}^d$, $\theta \mapsto \mathcal{L}(\theta, X_1, \dots, X_n)$ vraisemblance associée.

Définition 2.1

On appelle **estimateur du maximum de vraisemblance** tout estimateur $\hat{\theta}_n$ satisfaisant

$$\mathcal{L}(\hat{\theta}_n, X_1, \dots, X_n) = \sup_{\theta \in \Theta} \mathcal{L}(\theta, X_1, \dots, X_n).$$

Exemple introductif

On considère n tirages successifs à pile ou face, avec ses n variables de Bernoulli prenant la valeur 1 avec la probabilité p quand face sort et la valeur 0 avec la probabilité $1 - p$ quand c'est pile. La valeur du paramètre p nous est inconnue. Par exemple pour $n = 10$, on obtient comme résultat

0, 1, 1, 1, 0, 1, 0, 1, 0, 1

On écrit la vraisemblance :

Exemple introductif (suite)

$$\begin{aligned}\mathcal{L}(p, x_1, \dots, x_n) &= \prod_{i=1}^n \mathbb{P}(X = x_i) \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} \\ &= p^6 (1-p)^4.\end{aligned}$$

Voici quelques valeurs numériques :

Exemple introductif (suite)

p	0.3	0.4	0.5	0.6	0.7	0.8
$p^6(1-p)^4$	0.00018	0.00053	0.00097	0.0012	0.00095	0.00036

On s'aperçoit que la quantité $p^6(1-p)^4$ admet un maximum au voisinage de $p = 0.6$, voir Figure 1

Exemple introductif (suite)




FIGURE – Vraisemblance pour un échantillon de taille 10 de la loi de Bernoulli, pour $p = 0.6$.

Remarques

- ▶ Log-vraisemblance :

$$\begin{aligned}\theta \mapsto \ell_n(\theta, X_1, \dots, X_n) &= n^{-1} \log \mathcal{L}(\theta, X_1, \dots, X_n) \\ &= n^{-1} \sum_{i=1}^n \log f_\theta(X_i).\end{aligned}$$

Bien défini si $f_\theta(\cdot) > 0$ μ -pp.

Max. vraisemblance = max. log-vraisemblance.

- ▶ L'estimateur du maximum de vraisemblance ne dépend pas du choix de la mesure dominante μ .
- ▶ Racine de l'équation de vraisemblance : tout estimateur $\hat{\theta}_n$ vérifiant

$$\nabla_{\theta} \ell_n(\hat{\theta}_n, X_1, \dots, X_n) = 0.$$




FIGURE – La log-vraisemblance pour un échantillon de taille 10 de la loi de Bernoulli, pour $p = 0.6$.

Exemple : modèle normal

L'expérience statistique est engendrée par un n -échantillon de loi $\mathcal{N}(m, \sigma^2)$, le paramètre est $\theta = (m, \sigma^2) \in \Theta = \mathbb{R} \times \mathbb{R}_+ \setminus \{0\}$.

► Vraisemblance

$$\mathcal{L}((m, \sigma^2), X_1, \dots, X_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - m)^2 \right).$$

► Log-vraisemblance

$$\log \mathcal{L}((m, \sigma^2), X_1, \dots, X_n) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - m)^2.$$

Exemple : modèle normal

Equation(s) de vraisemblance

$$\begin{cases} \partial_m \ell_n((m, \sigma^2), X_1, \dots, X_n) &= \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - m) \\ \partial_{\sigma^2} \ell_n((m, \sigma^2), X_1, \dots, X_n) &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - m)^2. \end{cases}$$

Solution de ces équations (pour $n \geq 2$) :

$$\hat{\theta}_n = \left(\bar{X}_n, \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right)$$

et on vérifie que $\hat{\theta}_n = \hat{\theta}_n$.




FIGURE – La log-Vraisemblance pour un échantillon de taille 100 de la loi Normale $\mathcal{N}(0, 1)$.

Exemple : modèle de Poisson

► Vraisemblance

$$\mathcal{L}(\theta, X_1, \dots, X_n) = \frac{1}{\prod_{i=1}^n X_i!} e^{-n\theta} \theta^{\sum_{i=1}^n X_i}.$$

► Log-vraisemblance

$$\ell_n(\theta, X_1, \dots, X_n) = c(X_1, \dots, X_n) - n\theta + \sum_{i=1}^n X_i \log \theta.$$

► Equation de vraisemblance

$$-n + \sum_{i=1}^n X_i \frac{1}{\theta} = 0, \quad \text{soit} \quad \boxed{\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}_n}$$

Exemple : modèle de Laplace

L'expérience statistique est engendrée par un n -échantillon de loi de Laplace de paramètre $\theta \in \Theta = \mathbb{R}$. La densité par rapport à la mesure de Lebesgue :

$$f_{\theta}(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x - \theta|}{\sigma}\right),$$

où $\sigma > 0$ est **connu**.

► **Vraisemblance**

$$\mathcal{L}(\theta, X_1, \dots, X_n) = (2\sigma)^{-n} \exp\left(-\frac{1}{\sigma} \sum_{i=1}^n |X_i - \theta|\right)$$

► **Log-vraisemblance**

$$\ell_n(\theta, X_1, \dots, X_n) = -n \log(2\sigma) - \frac{1}{\sigma} \sum_{i=1}^n |X_i - \theta|.$$

Exemple : modèle de Laplace

Maximiser $\mathcal{L}_n(\theta, X_1, \dots, X_n)$ revient à minimiser la fonction $\theta \mapsto \sum_{i=1}^n |X_i - \theta|$, dérivable presque partout de dérivée constante par morceaux. **Equation de vraisemblance :**

$$\sum_{i=1}^n \text{sign}(X_i - \theta) = 0.$$

Soit $X_{(1)} \leq \dots \leq X_{(n)}$ la statistique d'ordre.

- ▶ n pair : $\hat{\theta}_n$ **n'est pas unique** ; tout point de l'intervalle $\left[X_{(\frac{n}{2})}, X_{(\frac{n}{2}+1)} \right]$ est un EMV.
- ▶ n impair : $\hat{\theta}_n = X_{(\frac{n+1}{2})}$, l'EMV est unique.
- ▶ **pour tout** n , la médiane empirique est un EMV.

Exemple : modèle de Cauchy

► Vraisemblance

$$\mathcal{L}(\theta, X_1, \dots, X_n) = \pi^{-n} \prod_{i=1}^n \frac{1}{1 + (X_i - \theta)^2}.$$

► Log-vraisemblance

$$\ell_n(\theta, X_1, \dots, X_n) = -n \log \pi - \sum_{i=1}^n \log \left(1 + (X_i - \theta)^2 \right)$$

► Equation de vraisemblance

$$\boxed{\sum_{i=1}^n \frac{X_i - \theta}{1 + (X_i - \theta)^2} = 0}$$

pas de solution explicite et admet en général plusieurs solutions.

Exemple : modèle de Cauchy (suite)




FIGURE – Dérivée de log-vraisemblance de la loi de Cauchy

Exemple : modèle uniforme

► On a

$$\begin{aligned}\mathcal{L}(\theta, X_1, \dots, X_n) &= \theta^{-n} \prod_{i=1}^n \mathbb{1}_{[0, \theta]}(X_i) \\ &= \theta^{-n} \mathbb{1}_{\{\max_{1 \leq i \leq n} X_i \leq \theta\}}\end{aligned}$$

► La fonction de vraisemblance n'est pas régulière.

► L'estimateur du maximum de vraisemblance est

$$\hat{\theta}_n = \max_{1 \leq i \leq n} X_i.$$

Exemple : modèle uniforme (suite)




FIGURE – La vraisemblance pour la loi uniforme $\mathcal{U}[0, \theta]$.

Estimation des paramètres de la loi Gamma

- Soit (X_1, X_2, \dots, X_n) n observations i.i.d. de loi $\text{Gamma}(\theta = (\alpha, \beta) \in \Theta = (\mathbb{R}_+^* \times \mathbb{R}_+^*))$

$$f_\theta(x) = \Gamma(\alpha)^{-1} \beta^\alpha x^{\alpha-1} e^{-\beta x}.$$

- log-vraisemblance

$$\log \mathcal{L}((\alpha, \beta), X_1, \dots, X_n) = -n \log \Gamma(\alpha) + n\alpha \log(\beta) + (\alpha - 1) \sum_{i=1}^n \log$$

- Le maximum ne se calcule pas explicitement.
- La minimisation par rapport à β pour α fixée est explicite : $\hat{\beta}_n(\alpha) = \alpha / \bar{X}_n$. L'estimateur du MV est obtenu en maximisant par rapport à α la fonction $\alpha \mapsto \log \mathcal{L}((\alpha, \hat{\beta}_n(\alpha)), X_1, \dots, X_n)$.

Estimation par intervalle de confiance

Définition 3.1

Un **intervalle de confiance** de **seuil** (ou **niveau de signification**) $\alpha \in [0, 1]$ pour un paramètre θ , est un intervalle aléatoire **IC** tel que $\mathbb{P}(\mathbf{IC} \ni \theta) = 1 - \alpha$.

- ▶ Les bornes de l'intervalle de confiance **IC** dépendent de l'échantillon, elles sont donc aléatoires.
- ▶ Par abus de langage, on note souvent $\mathbb{P}(\mathbf{IC} \in \theta) = 1 - \alpha$.

Construction

Pour construire un intervalle de confiance, on utilise une variable aléatoire dont on connaît la distribution de probabilité.

Définition 3.2

Une fonction pivotale pour le paramètre θ est une fonction des observations (X_1, \dots, X_n) et du paramètre θ dont la loi ne dépend pas du paramètre θ .

On recherche dans la suite des fonctions pivotales particulières adaptées aux cas étudiés.

On envisage deux cas :

- ▶ La variable aléatoire mesurée est normale et le nombre de réalisations est quelconque,
- ▶ La variable aléatoire mesurée n'est pas normale et le nombre de réalisations est important. On parlera d'intervalle de confiance asymptotique.

Échantillons gaussiens

Théorème 3.3

Si (X_1, \dots, X_n) est un échantillon de la loi $\mathcal{N}(m, \sigma^2)$, alors :

- ▶ $\sqrt{\frac{n}{\sigma^2}} (\bar{X}_n - m)$ suit la loi normale $\mathcal{N}(0, 1)$.
- ▶ $\sqrt{\frac{n-1}{S_n^2}} (\bar{X}_n - m)$ suit la loi de Student $\mathcal{T}_{(n-1)}$.
- ▶ $\frac{nS_n^2}{\sigma^2}$ suit la loi du chi-deux $\chi_{(n-1)}^2$.

Intervalle de confiance pour la moyenne d'un échantillon gaussien

Quand la variance est connue, après centrage et réduction de la moyenne empirique, d'après le Théorème 3.3, on obtient :

$$\mathbb{P} \left[\sqrt{\frac{n}{\sigma^2}} (\bar{X}_n - m) \in \left[-z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}} \right] \right] = 1 - \alpha$$

où $z_{1-\frac{\alpha}{2}}$ est le quantile d'ordre $1 - \frac{\alpha}{2}$ de la loi $\mathcal{N}(0, 1)$.




FIGURE – Quantile de la loi normale $\mathcal{N}(0, 1)$.

Or :

$$\begin{aligned} \sqrt{\frac{n}{\sigma^2}} (\bar{X}_n - m) &\in \left[-z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}} \right] \\ \Leftrightarrow \bar{X}_n - m &\in \left[-z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}, z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}} \right] \\ \Leftrightarrow m &\in \left[\bar{X}_n - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]. \end{aligned}$$

L'intervalle de confiance bilatéral symétrique pour l'espérance d'une loi normale s'écrit donc au niveau $1 - \alpha$ sous la forme suivante :

$$\mathbf{IC}(m) = \left[\bar{x}_n - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{x}_n + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]$$

\bar{x}_n est la réalisation de \bar{X}_n sur l'échantillon.

Une application numérique

On prend $n = 100$ et $\sigma = 1$. $\bar{x}_{100} = 0.174$.

► Pour $\alpha = 0.1$, $z_{1-\frac{\alpha}{2}} = 1.65$

$$\begin{aligned}\mathbf{IC}(m) &= \left[0.174 - 1.65 \frac{1}{\sqrt{100}}, 0.174 + 1.65 \frac{1}{\sqrt{100}} \right] \\ &= [0.009, 0.339]\end{aligned}$$

► Pour $\alpha = 0.05$, $z_{1-\frac{\alpha}{2}} = 1.96$

$$\begin{aligned}\mathbf{IC}(m) &= \left[0.174 - 1.96 \frac{1}{\sqrt{100}}, 0.174 + 1.96 \frac{1}{\sqrt{100}} \right] \\ &= [-0.022, 0.37]\end{aligned}$$

Remarque

- ▶ Remarquons que si α augmente (ou que si n augmente), l'amplitude de l'intervalle de confiance diminue.
- ▶ Pour $\alpha = 0.05$, si on répète 100 fois l'expérience, on aura 100 intervalles de confiance différents. En moyenne, θ sera dans 95 de ces intervalles.

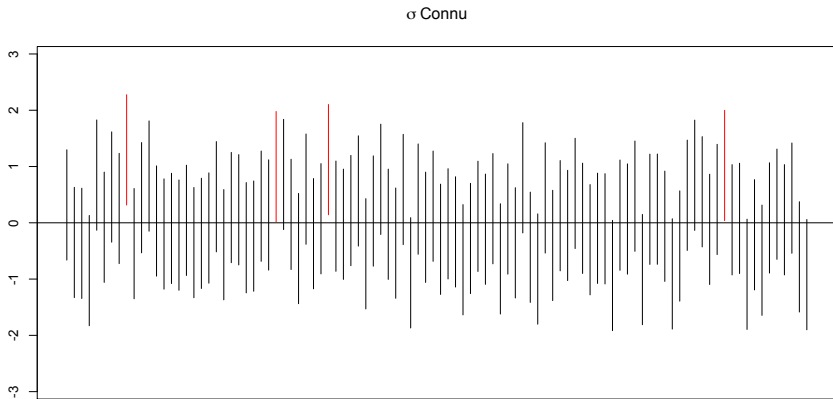


FIGURE – Intervalles de confiances

Quand la variance est inconnue, d'après le Théorème 3.3,

$\sqrt{\frac{n-1}{S_n^2}} (\bar{X}_n - m)$ suit la loi de Student $\mathcal{T}_{(n-1)}$. On obtient :

$$\mathbb{P} \left[\sqrt{\frac{n-1}{S_n^2}} (\bar{X}_n - m) \in \left[-t_{n-1, 1-\frac{\alpha}{2}}, t_{n-1, 1-\frac{\alpha}{2}} \right] \right] = 1 - \alpha$$

où $t_{n-1, 1-\frac{\alpha}{2}}$ est le quantile d'ordre $1 - \frac{\alpha}{2}$ de la loi de Student $\mathcal{T}_{(n-1)}$. L'intervalle de confiance bilatéral symétrique pour l'espérance d'une loi normale s'écrit donc au niveau $1 - \alpha$ sous la forme suivante :

$$\mathbf{IC}(m) = \left[\bar{x}_n - t_{n-1, 1-\frac{\alpha}{2}} \frac{s_n}{\sqrt{n}}, \bar{x}_n + t_{n-1, 1-\frac{\alpha}{2}} \frac{s_n}{\sqrt{n}} \right]$$

\bar{x}_n et s_n sont les réalisations de \bar{X}_n et S_n sur l'échantillon.




FIGURE – Intervalles de confiance basés sur la loi de Student (noir) et la loi normale (bleu).

Intervalle de confiance pour variance d'un échantillon gaussien

On considère la variance empirique $S_n^2 := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

comme fonction pivotale pour σ^2 . D'après le Théorème 3.3, $\frac{nS_n^2}{\sigma^2}$ suit la loi du chi-deux $\chi_{(n-1)}^2$. On a donc

$$\mathbb{P} \left[\frac{nS_n^2}{\sigma^2} \in \left[\chi_{(n-1), \frac{\alpha}{2}}^2, \chi_{(n-1), 1-\frac{\alpha}{2}}^2 \right] \right] = 1 - \alpha$$

où $\chi_{(n-1), \frac{\alpha}{2}}^2$ est le quantile d'ordre $\frac{\alpha}{2}$ de la loi du chi-deux $\chi_{(n-1)}^2$
et $\chi_{(n-1), 1-\frac{\alpha}{2}}^2$ est le quantile d'ordre $1 - \frac{\alpha}{2}$ de la loi du chi-deux $\chi_{(n-1)}^2$.

Quand l'espérance est inconnue, l'intervalle de confiance bilatéral pour la variance d'une loi normale s'écrit donc au niveau $1 - \alpha$ sous la forme suivante :

$$\mathbf{IC}(\sigma^2) = \left[\frac{ns_n^2}{\chi_{(n-1), 1-\frac{\alpha}{2}}^2}, \frac{ns_n^2}{\chi_{(n-1), \frac{\alpha}{2}}^2} \right]$$

s_n^2 est la réalisation de S_n^2 sur l'échantillon.

Intervalles de confiance asymptotiques

Définition 3.4

Soit $\alpha \in [0, 1]$. On appelle **intervalle de confiance asymptotique** pour θ tout intervalle de la forme $[L_n, U_n]$, où L_n et U_n sont des fonctions telles que :

$$\lim_{n \rightarrow +\infty} \mathbb{P}([L_n, U_n] \ni \theta) \rightarrow 1 - \alpha.$$

Intervalle de confiance pour une proportion

Soit X_1, \dots, X_n i.i.d. de loi $\mathcal{B}(p)$. On cherche un intervalle de confiance asymptotique pour p . Un estimateur de p est $\hat{p}_n = \bar{X}_n$. Par le TCL :

$$\sqrt{n}(\hat{p}_n - p) \xrightarrow{d} \mathcal{N}(0, p(1-p)).$$

Un intervalle de confiance asymptotique de niveau $1 - \alpha$ est donc donné par

$$\mathbf{IC}(p) = \left[\bar{x}_n - z_{1-\frac{\alpha}{2}} \frac{\sqrt{p(1-p)}}{\sqrt{n}}, \bar{x}_n + z_{1-\frac{\alpha}{2}} \frac{\sqrt{p(1-p)}}{\sqrt{n}} \right]$$

Le problème est que cet intervalle de confiance dépend de p qui est inconnu.

Intervalle de confiance pour une proportion (suite)

On a d'après la loi des grands nombres

$$\bar{X}_n \xrightarrow{P} p.$$

Par continuité, on a

$$\sqrt{\bar{X}_n(1 - \bar{X}_n)} \xrightarrow{P} \sqrt{p(1 - p)},$$

et donc

$$\frac{\sqrt{p(1 - p)}}{\sqrt{\bar{X}_n(1 - \bar{X}_n)}} \xrightarrow{P} 1.$$

On obtient donc d'après Slutsky

$$\sqrt{n} \frac{\bar{X}_n - p}{\sqrt{\bar{X}_n(1 - \bar{X}_n)}} = \sqrt{n} \frac{\bar{X}_n - p}{\sqrt{p(1 - p)}} \times \frac{\sqrt{p(1 - p)}}{\sqrt{\bar{X}_n(1 - \bar{X}_n)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

Intervalle de confiance pour une proportion (suite)

Un intervalle de confiance asymptotique de niveau $1 - \alpha$ est donné par

$$\mathbf{IC}(p) = \left[\hat{p}_n - z_{1-\frac{\alpha}{2}} \frac{\sqrt{\hat{p}_n(1-\hat{p}_n)}}{\sqrt{n}}, \hat{p}_n + z_{1-\frac{\alpha}{2}} \frac{\sqrt{\hat{p}_n(1-\hat{p}_n)}}{\sqrt{n}} \right]$$