

Statistique Asymptotique


Université Hassiba Benbouali de Chlef

Plan du Cours

- ▶ Modes de convergence
- ▶ Méthode Delta
- ▶ M et Z -estimateurs
- ▶ Méthode Delta fonctionnelle
- ▶ U -statistiques
- ▶ Processus empirique

Références

- ▶ Van der Vaart, A. W. (2000). Asymptotic statistics. Cambridge university press.
- ▶ DasGupta, A. (2008). Asymptotic theory of statistics and probability. Springer.



Méthode Delta

Si au lieu d'estimer directement θ , on veut estimer une fonction de θ , on sait que $\phi(\hat{\theta}_n)$ est l'estimateur de maximum de vraisemblance de $\phi(\theta)$.

- ▶ On souhaite déduire la normalité asymptotique pour un estimateur $\phi(\hat{\theta}_n)$ fonction d'un estimateur $\hat{\theta}_n$ de θ asymptotiquement normal.
- ▶ Pour cela, si ϕ est une fonction suffisamment régulière, une idée naturelle est d'exploiter un développement de Taylor pour ramener l'étude du comportement de $\phi(\hat{\theta}_n)$ à celle de $\hat{\theta}_n$.

Méthode Delta (suite)

Les propriétés de cet estimateur sont données par le théorème suivant. Il porte le nom de méthode Delta.

Théorème 1.1

Si :

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \sigma^2(\theta))$$

alors

$$\sqrt{n}(\phi(\hat{\theta}_n) - \phi(\theta)) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, [\phi'(\theta)]^2 \sigma^2(\theta))$$

pourvu que la dérivée $\phi'(\theta)$ existe et soit non nulle.

Preuve

On sait que,

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{P} \theta.$$

Dire que ϕ est dérivable en θ signifie qu'on peut écrire

$$\phi(\hat{\theta}_n) = \phi(\theta) + (\hat{\theta}_n - \theta) (\phi'(\theta) + o_P(1)).$$

C'est-à-dire,

$$\sqrt{n} (\phi(\hat{\theta}_n) - \phi(\theta)) = \sqrt{n} (\hat{\theta}_n - \theta) (\phi'(\theta) + o_P(1)).$$

Finalement, on applique le Théorème de Slutsky.

Exemple

Le modèle de Poisson

L'estimateur du maximum de vraisemblance est $\hat{\theta}_n = \bar{X}_n$, par le TCL

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \theta)$$

L'estimateur de $e^{-\theta}$ est $e^{-\hat{\theta}_n}$. La méthode Delta permet d'écrire que

$$\sqrt{n}(\phi(\hat{\theta}_n) - \phi(\theta)) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \theta e^{-2\theta})$$

Développements à l'ordre supérieur

Le résultat présenté par le Théorème 1.1 repose sur un développement de Taylor à l'ordre 1. Cependant, lorsque $\phi'(\theta)$ est nulle, la loi limite est dégénérée en 0. Il est alors intéressant de pousser le développement à un ordre supérieur.

Développements à l'ordre supérieur (suite)

Théorème 1.2

Soit $\hat{\theta}_n$ un estimateur tel que

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \sigma^2(\theta)).$$

Soit ϕ une application k -différentiable en θ ($k \geq 1$) avec $\phi^{(k)}(\theta) \neq 0$ et $\phi^{(j)}(\theta) = 0$ pour $j < k$. Alors

$$(\sqrt{n})^k \left(\phi(\hat{\theta}_n) - \phi(\theta) \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \frac{1}{k!} \phi^{(k)}(\theta) \left[\mathcal{N}(0, \sigma^2(\theta)) \right]^k.$$

Exemple

Soit X_1, \dots, X_n n copies indépendantes de la loi $\mathcal{B}(p)$ ($0 < p < 1$). Par le TCL

$$\sqrt{n}(\overline{X}_n - p) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, p(1-p)).$$

Un estimateur de la variance $p(1-p)$ est $\overline{X}_n(1 - \overline{X}_n)$. Il s'écrit comme $\phi(\overline{X}_n)$ avec $\phi(x) = x(1-x)$.

On a $\phi'(x) = 1 - 2x$. Si $p \neq \frac{1}{2}$, alors $\phi'(p) \neq 0$. D'après le Théorème 1.1, la distribution asymptotique de cet estimateur est

$$\sqrt{n}(\phi(\overline{X}_n) - \phi(p)) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, p(1-p)(1-2p)^2)$$

Exemple (suite)

En revanche $\phi' \left(\frac{1}{2} \right) = 0$. Cependant $\phi'' \left(\frac{1}{2} \right) = -2$, d'où d'après le Théorème 1.2

$$n \left(\phi(\overline{X}_n) - \left(\frac{1}{2} \right) \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \frac{1}{2!}(-2) \left[\mathcal{N} \left(0, \frac{1}{4} \right) \right]^2$$

$$\xrightarrow[n \rightarrow +\infty]{\mathcal{L}} -\frac{1}{4} \chi_1^2$$

Stabilisation de la variance

- ▶ Un choix judicieux de ϕ nous donnera pour la loi Normale limite une variance qui ne dépendra plus d'un paramètre.
- ▶ Il suffit de trouver ϕ telle que $[\phi'(\theta)]^2 \sigma^2(\theta) \equiv 1$. C'est-à-dire

$$\phi = \int \frac{1}{\sigma}.$$

Remarque

Remarque

Puisque $\sigma(\theta) > 0$, ceci implique que ϕ , en plus d'être continue, est strictement croissante, donc inversible. Il vient

$$\begin{aligned} \mathbb{P} \left(\left| \phi(\hat{\theta}_n) - \phi(\theta) \right| \leq \frac{z_{1-\alpha/2}}{\sqrt{n}} \right) = \\ \mathbb{P} \left(\phi^{-1} \left(\phi(\hat{\theta}_n) - \frac{z_{1-\alpha/2}}{\sqrt{n}} \right) \leq \theta \leq \phi^{-1} \left(\phi(\hat{\theta}_n) + \frac{z_{1-\alpha/2}}{\sqrt{n}} \right) \right). \end{aligned}$$

qui correspond donc à un intervalle de confiance asymptotique de niveau $(1 - \alpha)$.

Le modèle de Poisson

L'estimateur du maximum de vraisemblance est $\hat{\theta}_n = \bar{X}_n$, par le TCL

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, \theta)$$

Le principe du plug-in donne l'intervalle de confiance suivant :

$$\left[\bar{X}_n - \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{1-\alpha/2} ; \bar{X}_n + \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{1-\alpha/2} \right]$$

Appliquons la méthode de stabilisation de la variance : on cherche ϕ telle que

$$\phi'(\theta) = \frac{1}{\theta} \iff \phi(\theta) = 2\sqrt{\theta}$$

Le modèle de Poisson (suite)

ce qui donne donc

$$\sqrt{n} \left(2\sqrt{\bar{X}_n} - 2\sqrt{\theta} \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Ainsi la variance de la loi Normale limite ne dépend plus du paramètre inconnu θ .

D'où les intervalles de confiance asymptotiques :

$$\mathbb{P} \left(\left| \sqrt{n} \left(2\sqrt{\bar{X}_n} - 2\sqrt{\theta} \right) \right| \leq z_{1-\alpha/2} \right) \xrightarrow[n \rightarrow \infty]{} 1 - \alpha$$

$$\mathbb{P} \left(2\sqrt{\bar{X}_n} - \frac{z_{1-\alpha/2}}{\sqrt{n}} \leq 2\sqrt{\theta} \leq 2\sqrt{\bar{X}_n} + \frac{z_{1-\alpha/2}}{\sqrt{n}} \right) \xrightarrow[n \rightarrow \infty]{} 1 - \alpha$$

Le modèle de Poisson (suite)

$$\mathbb{P} \left(\left(\sqrt{\bar{X}_n} - \frac{z_{1-\alpha/2}}{2\sqrt{n}} \right)^2 \leq \theta \leq \left(\sqrt{\bar{X}_n} + \frac{z_{1-\alpha/2}}{2\sqrt{n}} \right)^2 \right) \xrightarrow{n \rightarrow \infty} 1 - \alpha$$

C'est-à-dire :

$$\left[\bar{X}_n - \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{1-\alpha/2} + \frac{z_{1-\alpha/2}^2}{4n} ; \bar{X}_n + \frac{\sqrt{\bar{X}_n}}{\sqrt{n}} z_{1-\alpha/2} + \frac{z_{1-\alpha/2}^2}{4n} \right]$$

La méthode de stabilisation de la variance a donc eu pour effet de traduire les intervalles de confiance de $\frac{z_{1-\alpha/2}^2}{4n}$.

Vecteurs aléatoires

Soit $X = \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix} \in \mathbb{R}^d$ un vecteur aléatoire dont les composantes sont de carré intégrable.

- Le vecteur moyenne de X est défini par : $\mathbb{E}[X] = \begin{pmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_d] \end{pmatrix}$
- et sa matrice de covariance par :

$$\begin{aligned} \text{Var}[X] &= \mathbb{E} \left[(X - \mathbb{E}[X])(X - \mathbb{E}[X])^\top \right] \\ &= \begin{pmatrix} \text{Var}[X_1] & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_d) \\ \text{Cov}(X_2, X_1) & \text{Var}[X_2] & \cdots & \text{Cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \text{Cov}(X_d, X_2) & \cdots & \text{Var}[X_d] \end{pmatrix} \end{aligned}$$

Remarque

Remarque

- Pour tout $1 \leq i, j \leq d$, la covariance entre X_i et X_j est donnée par

$$\begin{aligned}\text{Cov}(X_i, X_j) &= \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])] \\ &= \mathbb{E}[X_i X_j] - \mathbb{E}[X_i] \mathbb{E}[X_j]\end{aligned}$$

- Il est facile de voir que l'on a $\text{Cov}(X_i, X_i) = \text{Var}[X_i]$.
- De plus, si les variables X_i et X_j sont indépendantes on a $\text{Cov}(X_i, X_j) = 0$.
- En général, la réciproque est fausse, sauf pour des vecteurs gaussiens, comme nous le verrons plus loin.

Théorème 1.3

Si X est un vecteur (colonne) aléatoire de \mathbb{R}^d de vecteur moyenne m et de matrice de covariance Σ Alors si A est une matrice réelle $k \times d$, le vecteur aléatoire AX de \mathbb{R}^k a pour vecteur moyenne Am et pour matrice de covariance $A\Sigma A^\top$.

Preuve

C'est une simple conséquence de la linéarité de l'espérance. Pour la moyenne on a :

$$\mathbb{E}[AX] = A\mathbb{E}[X] = Am$$

et pour la matrice de covariance

$$\begin{aligned} \text{Var}[AX] &= \mathbb{E} [(AX - \mathbb{E}[AX])(AX - \mathbb{E}[AX])^\top] \\ &= \mathbb{E} \left[A(X - \mathbb{E}[X]) (A(X - \mathbb{E}[X]))^\top \right] \\ &= A\mathbb{E} [(X - \mathbb{E}[X])(X - \mathbb{E}[X])^\top] A^\top = A\Sigma A^\top \end{aligned}$$

Densité gaussienne en dimension d

Définition 1.4

Un vecteur aléatoire de \mathbb{R}^d est un vecteur aléatoire gaussien si et seulement si toute combinaison linéaire de ses composantes est une variable aléatoire réelle gaussienne, i.e. :

$$\forall a \in \mathbb{R}^d \quad a^\top X \sim \mathcal{N}(m, \sigma^2).$$

Soit $X \sim \mathcal{N}_d(\mathbf{m}, \Sigma)$ un vecteur gaussien en dimension d . Si Σ est inversible, la densité de X est donc donnée par

$$f(\mathbf{x}) = \frac{1}{|\Sigma|^{\frac{1}{2}} (2\pi)^{\frac{d}{2}}} \exp \left(-\frac{1}{2} (\mathbf{x} - \mathbf{m})^\top \Sigma^{-1} (\mathbf{x} - \mathbf{m}) \right),$$

Théorème 1.5

Pour tout vecteur gaussien X de \mathbb{R}^d , les trois propriétés suivantes sont équivalentes :

- 1** *Les composantes X_1, \dots, X_d sont mutuellement indépendantes.*
- 2** *Les composantes X_1, \dots, X_d sont deux à deux indépendantes.*
- 3** *La matrice de covariance Σ de X est diagonale.*

Théorème central limite multidimensionnel

Théorème 1.6

Soient $\mathbf{X}_1, \dots, \mathbf{X}_n$ des vecteurs aléatoires i.i.d. de \mathbb{R}^d d'espérance \mathbf{m} et de matrice de covariance $\Sigma = \mathbb{E} \left[(\mathbf{X} - \mathbf{m}) (\mathbf{X} - \mathbf{m})^\top \right]$.

Alors

$$\sqrt{n} \left(\bar{\mathbf{X}}_n - \mathbf{m} \right) \xrightarrow{\mathcal{L}} \mathcal{N}_d(\mathbf{0}, \Sigma)$$

Méthode Delta multivariée

La matrice de gradient

$$\nabla\phi(\mathbf{a}) = \left(\begin{array}{ccc} \frac{\partial\phi_1(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial\phi_k(\mathbf{x})}{\partial x_1} \\ \vdots & & \vdots \\ \frac{\partial\phi_1(\mathbf{x})}{\partial x_d} & \dots & \frac{\partial\phi_k(\mathbf{x})}{\partial x_d} \end{array} \right) \bigg|_{\mathbf{x}=\mathbf{a}}$$

Par définition, la matrice de gradient satisfait la formule de Taylor du premier ordre

$$\phi(\mathbf{x}) = \phi(\mathbf{a}) + \nabla\phi(\mathbf{a})^\top (\mathbf{x} - \mathbf{a}) + \mathbf{r}(\mathbf{x}, \mathbf{a})$$

avec $\frac{\mathbf{r}(\mathbf{x}, \mathbf{a})}{\|\mathbf{x} - \mathbf{a}\|} \longrightarrow 0$ quand $\mathbf{x} \longrightarrow \mathbf{a}$.

Méthode Delta multivariée

Théorème 1.7

Soit $\hat{\theta}_n$ une suite de vecteurs aléatoires dans \mathbb{R}^d satisfaisant $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}_d(\mathbf{0}, \Sigma(\theta))$. Soit $\phi : \mathbb{R}^d \rightarrow \mathbb{R}^k$ différentiable en θ . Alors

$$\sqrt{n}(\phi(\hat{\theta}_n) - \phi(\theta)) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}_k(0, [\nabla \phi(\theta)]^\top \Sigma(\theta) \nabla \phi(\theta))$$

Exemple : La variance empirique

Soit $\hat{\theta}_n = \begin{pmatrix} \overline{X}_n \\ \overline{X^2}_n \end{pmatrix}$ et $\theta = \begin{pmatrix} \mathbb{E}[X] \\ \mathbb{E}[X^2] \end{pmatrix}$. Par le TCL multivarié, on a

$$\sqrt{n} (\hat{\theta}_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}_2(\mathbf{0}, \Sigma(\theta))$$

avec

$$\Sigma(\theta) = \begin{pmatrix} \text{Var}[X] & \text{Cov}(X, X^2) \\ \text{Cov}(X^2, X) & \text{Var}[X^2] \end{pmatrix}.$$

La variance empirique $S_n^2 = \overline{X^2}_n - \overline{X}_n^2$ s'écrit comme $\phi(\hat{\theta}_n)$ avec $\phi(x) = x_2 - x_1^2$.

On a $\nabla \phi(x) = \begin{pmatrix} -2x_1 \\ 1 \end{pmatrix}$. Donc

$$[\nabla \phi(\theta)]^\top \Sigma(\theta) \nabla \phi(\theta) = (-2\mathbb{E}[X] \quad 1) \begin{pmatrix} \text{Var}[X] & \text{Cov}(X, X^2) \\ \text{Cov}(X^2, X) & \text{Var}[X^2] \end{pmatrix} \begin{pmatrix} -2\mathbb{E}[X] \\ 1 \end{pmatrix}$$

Exemple : La variance empirique (suite)

Si on suppose que $\mathbb{E}[X] = 0$ et $\text{Var}[X] = \sigma^2$, alors

$$\sqrt{n} \left(S_n^2 - \sigma^2 \right) \xrightarrow{\mathcal{L}} \mathcal{N} \left(0, \mathbb{E}[X^4] - \sigma^4 \right).$$

Méthode des moments

Soit (X_1, \dots, X_n) un échantillon de variables aléatoires i.i.d. de loi \mathbb{P}_θ , avec $\theta \in \Theta$ intervalle de \mathbb{R} , et ϕ un \mathcal{C}^1 -difféomorphisme de Θ dans $\phi(\Theta)$. Si $\hat{\phi}_n = \hat{\phi}_n(X_1, \dots, X_n)$ est un estimateur convergent de $\phi(\theta)$ et θ un point intérieur à Θ , alors $\hat{\theta}_n = \phi^{-1}(\hat{\phi}_n)$ est défini avec une probabilité qui tend vers 1 lorsque $n \rightarrow \infty$ et

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{P} \theta$$

De plus, si

$$\sqrt{n} \left(\hat{\phi}_n - \phi(\theta) \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N} \left(0, \sigma^2(\theta) \right),$$

Méthode des moments (suite)

alors

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{L}} \mathcal{N}\left(0, \frac{\sigma^2(\theta)}{[\phi'(\theta)]^2}\right).$$

Exemple