TP 1 : Fonction de répartition empirique avec R.

Hamel Elhadj

Departement de Mathematiques

Université Hassiba Benbouali-Chlef

Ce TP est distiné aux étudiants Master2 mathématiques
Option :Mathématique Apliquées et statistique

2021/2022

6 novembre 2021



Introduction

Le but de ce TP est de fournir les éléments de base permettant une prise en main rapide du logiciel R afin de faciliter le déroulement de certains TD mais aussi de vous aider de faire le patique.

Un point fort de logiciel R réside dans le fait que ce logiciel est distribué librement. Son installation peut être mise en œuvre à partir du site internet du *Comprehensive R Archive Network* (CRAN) qui d'une part met à disposition les exécutables et d'autres part donne des informations relatives à la procédure d'installation.

Création de données.

Il existe différentes manière de créer des données quelles soient régulières ou aléatoires

- **1 a** :**b** \Longrightarrow qui crée, à partir de la valeur a et par pas de 1, une suite de nombres inférieurs ou égaux à b.
- **9** seq(a,b,p) \Longrightarrow où a est la valeur de départ, b la valeur maximale à ne pas dépasser et p le pas.
- ① $c(n_1, n_2, n_3) \Longrightarrow$ qui produit le vecteur contenant les valeurs n_1 ; n_2 ; n_3 .
- O'autres fonctions sont également disponibles telles :
 - **-rep** qui permet de répéter un objet un certain nombre de fois
 - sequence qui crée une suie de séquences de nombres entiers se terminant chacune par les valeurs spécifiées en argument

-gl(k,n) qui génère une série régulière dans un facteup comprenant kritveau

Création de données.

Il existe différentes manière de créer des données quelles soient régulières ou aléatoires

- a :b

 qui crée, à partir de la valeur a et par pas de 1, une suite de nombres inférieurs ou égaux à b.
- seq(a,b,p) => où a est la valeur de départ, b la valeur maximale à ne pas dépasser et p le pas.
- $c(n_1, n_2, n_3) \Longrightarrow$ qui produit le vecteur contenant les valeurs n_1 ; n_2 ; n_3 .
- D'autres fonctions sont également disponibles telles :
 - **-rep** qui permet de répéter un objet un certain nombre de fois
 - sequence qui crée une suie de séquences de nombres entiers se terminant chacune par les valeurs spécifiées en argument

-gl(k,n) qui génère une série régulière dans un facteup comprenant kritveau

Hamel Elhadi

Création de données.

Il existe différentes manière de créer des données quelles soient régulières ou aléatoires

- a:b

 qui crée, à partir de la valeur a et par pas de 1, une suite de nombres inférieurs ou égaux à b.
- seq(a,b,p) => où a est la valeur de départ, b la valeur maximale à ne pas dépasser et p le pas.
- **3** $c(n_1, n_2, n_3) \Longrightarrow$ qui produit le vecteur contenant les valeurs n_1 ; n_2 ; n_3 .
- O'autres fonctions sont également disponibles telles :
 - -rep qui permet de répéter un objet un certain nombre de fois
 - sequence qui crée une suie de séquences de nombres entiers se terminant chacune par les valeurs spécifiées en argument

-gl(k,n) qui génère une série régulière dans un facteup comprenant kritveau

Création de données.

Il existe différentes manière de créer des données quelles soient régulières ou aléatoires

- **1** $a:b \Longrightarrow qui crée, à partir de la valeur <math>a$ et par pas de 1, une suite de nombres inférieurs ou égaux à b.
- **2** $seq(a,b,p) \implies où a$ est la valeur de départ, b la valeur maximale à ne pas dépasser et p le pas.
- $(n_1, n_2, n_3) \Longrightarrow$ qui produit le vecteur contenant les valeurs $n_1; n_2; n_3$.
- D'autres fonctions sont également disponibles telles :
 - -rep qui permet de répéter un objet un certain nombre de fois;
 - sequence qui crée une suie de séquences de nombres entiers se terminant chacune par les valeurs spécifiées en argument
 - -gl(k,n) qui génère une série régulière dans un facteur comprenant k niveaux Hamel Elhadi

Données aléatoires

Voici un tableau qui fait apparaître la dénomination et les paramètres de certaines lois.

nom de la loi	fonction dans R
Gauss(normale)	rnorm(n,mean= μ ,sd= σ)
exponentielle	$rexp(n, rate=\lambda)$
gamma	rgamma(n, shape = a, scale = s)
poisson	rpois(n, λ)
weibull	rweibull(n, shape = a, scale = s)
cauchy	rcauchy(n, location = a, scale = s)
student	rt(n, df)
fisher	rf(n,df1,df2)
binomiale	rbinom(n,size,prob)
géométrique	rgeom(n,prob)
uniforme	runif(n, min=a, max=b)

fonctions graphiques

Dans ce tableau ne sera mentionné que les fonctions qui pourront être utiles en statistique. Cependant, nous n'en donnerons qu'un petit aperçu, les détails et options figurant dans l'aide.

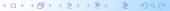
plot(x)	graphe des valeurs de x (sur l'axe des y) ordonnées sur l'axe x
plot(x,y)	graphe de y en fonction de x
boxplot(x)	boîte à moustaches
hist(x)	histogramme des fréquences de x
barplot(x)	histogramme des valeurs de x
qqnorm(x)	quantiles de x en fonction des valeurs attendues selon une loi normale
qqplot(x,y)	quantiles de y en fonction de ceux de x

- Simuler un échantillon de taille 1000 suivant une loi normale N(0,1).
- Sur un même graphique, superposer la répartition empirique (histogramme)
 et la densité de la loi N(0,1).
- Sur un même graphique, superposer la fonction de répartition empirique et la fonction de répartition de la loi N(0,1).
- Reprendre les questions précédentes avec d'autres lois de votre choix.

- O Simuler un échantillon de taille 1000 suivant une loi normale N(0,1).
- Sur un même graphique, superposer la répartition empirique (histogramme) et la densité de la loi N(0,1).
- Sur un même graphique, superposer la fonction de répartition empirique et la fonction de répartition de la loi N(0,1).
- Reprendre les questions précédentes avec d'autres lois de votre choix.

- O Simuler un échantillon de taille 1000 suivant une loi normale N(0,1).
- Sur un même graphique, superposer la répartition empirique (histogramme) et la densité de la loi N(0,1).
- Sur un même graphique, superposer la fonction de répartition empirique et la fonction de répartition de la loi N(0,1).
- Reprendre les questions précédentes avec d'autres lois de votre choix.

- O Simuler un échantillon de taille 1000 suivant une loi normale N(0,1).
- Sur un même graphique, superposer la répartition empirique (histogramme) et la densité de la loi N(0,1).
- Sur un même graphique, superposer la fonction de répartition empirique et la fonction de répartition de la loi N(0,1).
- Reprendre les questions précédentes avec d'autres lois de votre choix.

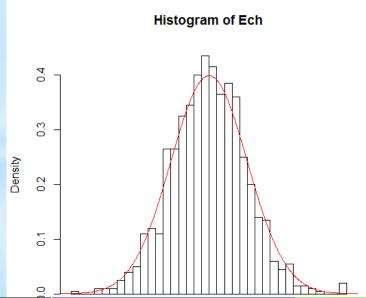


```
Question 1
```

```
Ech = rnorm(1000, 0, 1)
```

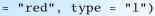
Question 2

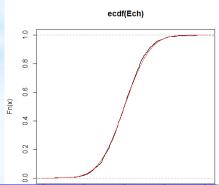
```
hist(Ech, breaks = 50, freq = F)
points(seq(-4, 4, 0.01), dnorm(seq(-4, 4, 0.01)),
```



Question 3

?ecdf

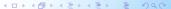




- Tracer la densité d'une loi normale centrée réduite sur [-5, 5]. Pour cela :
 - i- Créer un vecteur x qui varie doucement de -5 a 5.
 - ii- Créer un vecteur y qui donne la densité de la loi normale centrée réduite pour tous les points de x.
 - ii- Tracer le graphique. Attention, il faut tracer une courbe, pas des points côte à côte.
- Superposer la densité d'une loi normale centrée de variance 0.5. Attention : on veut voir entiérement les deux densités.
- Superposer la densité d'une loi normale centrée de variance 2



- Tracer la densité d'une loi normale centrée réduite sur [-5, 5]. Pour cela :
 - i- Créer un vecteur x qui varie doucement de -5 a 5.
 - ii- Créer un vecteur y qui donne la densité de la loi normale centrée réduite pour tous les points de x.
 - Tracer le graphique. Attention, il faut tracer une courbe, pas des points côte à côte.
- Superposer la densité d'une loi normale centrée de variance 0.5. Attention : on veut voir entiérement les deux densités.
- 3 Superposer la densité d'une loi normale centrée de variance 2



- Tracer la densité d'une loi normale centrée réduite sur [-5, 5]. Pour cela :
 - i- Créer un vecteur x qui varie doucement de -5 a 5.
 - ii- Créer un vecteur y qui donne la densité de la loi normale centrée réduite pour tous les points de x.
 - iii- Tracer le graphique. Attention, il faut tracer une courbe, pas des points côte à côte.
- Superposer la densité d'une loi normale centrée de variance 0.5. Attention : on veut voir entiérement les deux densités.
- 3 Superposer la densité d'une loi normale centrée de variance 2.



- O Tracer la densité d'une loi normale centrée réduite sur [-5, 5]. Pour cela :
 - i- Créer un vecteur x qui varie doucement de -5 a 5.
 - ii- Créer un vecteur y qui donne la densité de la loi normale centrée réduite pour tous les points de x.
 - iii- Tracer le graphique. Attention, il faut tracer une courbe, pas des points côte à côte.
- Superposer la densité d'une loi normale centrée de variance 0.5. Attention : on veut voir entiérement les deux densités.
- Superposer la densité d'une loi normale centrée de variance 2



- O Tracer la densité d'une loi normale centrée réduite sur [-5, 5]. Pour cela :
 - i- Créer un vecteur x qui varie doucement de -5 a 5.
 - ii- Créer un vecteur y qui donne la densité de la loi normale centrée réduite pour tous les points de x.
 - iii- Tracer le graphique. Attention, il faut tracer une courbe, pas des points côte à côte.
- Superposer la densité d'une loi normale centrée de variance 0.5. Attention : on veut voir entiérement les deux densités.
- Superposer la densité d'une loi normale centrée de variance 2



- Tracer la densité d'une loi normale centrée réduite sur [-5, 5]. Pour cela :
 - i- Créer un vecteur x qui varie doucement de -5 a 5.
 - ii- Créer un vecteur y qui donne la densité de la loi normale centrée réduite pour tous les points de x.
 - iii- Tracer le graphique. Attention, il faut tracer une courbe, pas des points côte à côte.
- Superposer la densité d'une loi normale centrée de variance 0.5. Attention : on veut voir entiérement les deux densités.
- Superposer la densité d'une loi normale centrée de variance 2.



```
x = runif(20)
xseq = seq(0,1,length=100)
Fhat = ecdf(x)
plot(Fhat)
lines(xseq,punif(xseq), col="blue",lwd=2)
```

TP : fonction de répartition .

- General in echantilion de tallie n = 100 de variables aleat
- A constitution of the parameter was the constitution of the consti
- a solution de repartition de la loi C. Estimer P a parti
 - de répartition empirique F_n en décomposant le domaine de définition
- sur une grille de points régulièrement espacés.
- **Représent**er graphiquement F et \overline{F}_n .
- lacksquare Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).

TP : fonction de répartition .

- Générer un échantillon de taille n = 100 de variables aléatoires i.i.d. selon une loi exponentielle \mathcal{E} de paramètre λ à choisir.
- ② Soit F la fonction de répartition de la loi \mathcal{E} . Estimer F à partir de la fonction de répartition empirique \widehat{F}_n en décomposant le domaine de définition de F sur une grille de points régulièrement espacés.
- lacksquare Représenter graphiquement F et \widehat{F}_n
- 1 Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).

TP : fonction de répartition .

- Générer un échantillon de taille n = 100 de variables aléatoires i.i.d. selon une loi exponentielle ε de paramètre λ à choisir.
- ullet Soit F la fonction de répartition de la loi \mathcal{E} . Estimer F à partir de la fonction de répartition empirique \widehat{F}_n en décomposant le domaine de définition de F sur une grille de points régulièrement espacés.
- ullet Représenter graphiquement F et \widehat{F}_n .
- Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).

TP: fonction de répartition.

- Générer un échantillon de taille n = 100 de variables aléatoires i.i.d. selon une loi exponentielle ε de paramètre λ à choisir.
- Soit F la fonction de répartition de la loi E. Estimer F à partir de la fonction de répartition empirique Fn en décomposant le domaine de définition de F sur une grille de points régulièrement espacés.
- **3** Représenter graphiquement F et \widehat{F}_n .
- Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).

TP: fonction de répartition.

- Générer un échantillon de taille n = 100 de variables aléatoires i.i.d. selon une loi exponentielle ε de paramètre λ à choisir.
- Soit F la fonction de répartition de la loi E. Estimer F à partir de la fonction de répartition empirique Fn en décomposant le domaine de définition de F sur une grille de points régulièrement espacés.
- **3** Représenter graphiquement F et \widehat{F}_n .
- Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).

TP: fonction de répartition.

- Générer un échantillon de taille n = 100 de variables aléatoires i.i.d. selon une loi exponentielle \mathcal{E} de paramètre λ à choisir.
- Soit F la fonction de répartition de la loi E. Estimer F à partir de la fonction de répartition empirique Fn en décomposant le domaine de définition de F sur une grille de points régulièrement espacés.
- **3** Représenter graphiquement F et \widehat{F}_n .
- Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).
 - Illustrer également la normalité asymptotique associée à \widehat{F}_{n} \longrightarrow

TP: fonction de répartition.

- Générer un échantillon de taille n = 100 de variables aléatoires i.i.d. selon une loi exponentielle \mathcal{E} de paramètre λ à choisir.
- Soit F la fonction de répartition de la loi E. Estimer F à partir de la fonction de répartition empirique Fn en décomposant le domaine de définition de F sur une grille de points régulièrement espacés.
- **3** Représenter graphiquement F et \widehat{F}_n .
- Illustrer la convergence presque sûre de \widehat{F}_n vers F(x).
 - Illustrer également la normalité asymptotique associée à $\widehat{F}_{\overline{\eta}}$.

• Question 1:

• Question 1:

Question 1: n=100; lambda=2; X=rexp(n,lambda); plot(X)

Question 2 :

```
on découpe l'intervalle [0,3] en une grille de 3000 points (sequence)
xmin=0; xmax=3;nbpoints=3000
x = seq(xmin, xmax, length.out=nbpoints)
Fn = rep(0, nbpoints) for (i in 1:nbpoints) Fn[i]
= length(X[X <= x[i]])/n plot(Fn)
plot(ecdf(X))</pre>
```

```
Question 1:
  n=100; lambda=2; X=rexp(n, lambda); plot(X)
Question 2 :
```

```
Question 1:
  n=100; lambda=2; X=rexp(n, lambda); plot(X)
Question 2 :
  on découpe l'intervalle [0,3] en une grille de 3000 points (sequence)
  xmin=0; xmax=3;nbpoints=3000
  x = seq(xmin, xmax, length.out=nbpoints)
  Fn = rep(0, nbpoints) for (i in 1:nbpoints) Fn[i]
  = length(X[X \le x[i]])/n plot(Fn)
  plot(ecdf(X))
```

• Question 3:

on calcule F fonction de répartition de la loi expo en chaque point de la grille

```
F = pexp(x, lambda)
plot(x, Fn, type="s", col="blue")
lines(x, F, type="l", col="red")
comparer avec plot(ecdf(X))????
```

Question 3:

on calcule F fonction de répartition de la loi expo en chaque point de la grille

```
F = pexp(x, lambda)
plot(x, Fn, type="s", col="blue")
lines(x, F, type="l", col="red")
comparer avec plot(ecdf(X))????
```

• Question 3:

on calcule F fonction de répartition de la loi expo en chaque point de la grille et on trace F et Fn

```
F = pexp(x, lambda)
plot(x, Fn, type="s", col="blue")
lines(x, F, type="l", col="red")
comparer avec plot(ecdf(X))????
```

• Question 4: on fait varier n entre 1 et N mais on se fixe un x0

```
x0=0.2
N=3000
X2=rexp(N,lambda);Fchap = rep(0, N)
for (n in 1:N) Xcoupe = X2[1:n]
Fchap[n] = length(Xcoupe[Xcoupe <= x0])/n
plot(1:N, Fchap, type="l", col="blue")
abline(h=pexp(x0, lambda), lty=2, col="red") %
F(x0)</pre>
```

Question 5 : On fixe n assez grand, on fixe x0, et on simule N réalisations de $sqrt(n)*[Fchapeau_n(x0)-F(x0)]$ lambda=2;n = 100; x0 = 0.6; N = 1000;Dn = rep(0, N) for (i in 1:N) X = rexp(n, lambda) Dn[i] = sqrt(n)*(length(X[X <= x0])/n - pexp(x0, 2)) on trace l'histogramme de ces réalisations et on superpose la densité de la loi

on trace l'histogramme de ces réalisations et on superpose la densité de la loi normale attendue centrée de variance F(x0)(1-F(x0))

 $IntTLC = seq(-2, 2, 0.1); variance = pexp(x0, lambda)^*(1-pexp(x0, lambda)) \\ hist(Dn, col='light blue', xlim=c(-3,3), breaks=seq(min(Dn)-0.5, max(Dn)+0.5, 0.2), freq=FALSE)$

plot(function(IntTLC) dnorm(IntTLC, 0, sqrt(variance)), xlim=c(-2,2), col=2, add=TRUE, lwd=2)



• Question 6 : on fait varier n et on prend aă chaque fois le sup de

$$|\hat{F}_n(x) - F(x)|$$
 sur tous les points de la grille
N = 300; supCumul = rep(0, N); X = rexp(N, lambda);F = pexp(x, lambda)
for (n in 1:N) Xcoupe = X[1:n] Fnx = rep(0, nbpoints) for (j in 1:nbpoints)
Fnx[j] = length(Xcoupe[Xcoupe <= x[j]])/n supCumul[n] = max(abs(Fnx-F))
plot(1:N, supCumul, type="l", col="blue")

