

# Chapitre 1

## Généralités-Maximum de Vraisemblance

### Familles Exponentielles

#### I.1. Hypothèses sur le modèle

Soient  $\mathcal{E}$  une expérience aléatoire,  
 $(\Omega, \mathcal{A}, P)$  l'espace de probabilité associé à  $\mathcal{E}$ ,  
 $X$  une variable aléatoire (v.a.) associée définie sur  $(\Omega, \mathcal{A})$  à valeurs dans  $\mathcal{X} = \mathbb{R}$  ou  $\mathbb{R}^d$ ,  
 $(X, \mathfrak{B})$  l'espace des observations,  
 $P_\theta$  la loi de probabilité de  $X$ , caractérisée par un paramètre  $\theta \in \Theta$ ,  
 $\Theta$  l'espace des paramètres (sous-ensemble mesurable de  $\mathbb{R}^p$ ),  
 $(X, \mathfrak{B}, P^X)$  le modèle image par  $X$  du modèle  $(\Omega, \mathcal{A}, P)$ .

#### Définition 1 Modèle d'échantillonnage

On appelle modèle d'échantillonnage de taille  $n$ , le produit  $(\mathcal{X}, P_\theta)^{\otimes n}$  associé à  $n$  expériences aléatoires indépendantes et de même loi  $P$ .

On suppose que  $P$  appartient à une famille de probabilités  $\mathcal{P} = \{P_\theta \text{ (ou } f_\theta), \theta \in \Theta\}$ . (On dit que le modèle est paramétrique).

**Notations :**

- $X_i$  est la v.a. de même loi que  $X$  associée à l'expérience numéro «  $i$  ».
- $x_i$  est la réalisation de  $X_i$ .
- Au modèle  $(\mathcal{X}, P_\theta)^{\otimes n}$  correspondent  $n$  v.a.i.i.d.  $X_1, \dots, X_n$  de loi  $P_\theta$ .

#### Définition 2 Echantillon (aléatoire)

- On appelle échantillon de taille  $n$  ou  $n$ -échantillon, le  $n$ -uplet  $(X_1, \dots, X_n)$  où les  $X_i$  sont  $n$  v.a.i.i.d.
- Le  $n$ -uplet  $(x_1, \dots, x_n)$  est appelé échantillon d'observations (ce sont  $n$  réalisations indépendantes d'une v.a.  $X$ ).

#### Définition 3 Modèle paramétrique

**a-** Un modèle statistique  $(\Omega, \mathcal{A}, P)_{P \in \mathcal{P}}$ , est une famille de lois de probabilités sur un espace mesuré d'observations.

**b-** Un modèle (statistique) paramétrique  $(\Omega, \mathcal{A}, P_\theta)_{\theta \in \Theta}$ , consiste en l'observation d'une v.a.  $X$  de loi  $P_\theta(x)$  (ou  $f_\theta(x)$ ), où seul le paramètre  $\theta$  est inconnu.

**Exemples**  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{N}(0, \sigma^2)\}_{\sigma \in \mathbb{R}^{+*}})$ ,  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{U}[a, b]\}_{(a, b) \in \mathbb{R}^2})$ .

Le but de l'estimation paramétrique est d'identifier la probabilité inconnue  $P_\theta$  (ou  $f_\theta$ ), ou bien le paramètre inconnu  $\theta$  à partir de la réalisation d'un échantillon. On étudie essentiellement des modèles d'échantillonnage où la famille de probabilités  $\mathcal{P}$  est constituée de lois possédant une densité ( $P(x, \theta) = f_\theta(x)$ ), ou de lois discrètes ( $P(x, \theta) = P_\theta(X=x)$ ).

**Notation**  $E_\theta(f(X_1, \dots, X_n))$  désigne l'espérance de  $f(X_1, \dots, X_n)$  où le vecteur  $(X_1, \dots, X_n)$  a pour loi  $P_\theta^{\otimes n}$ .

## I.2. Statistique, Estimateur

**Définition 4** Une **statistique**  $S$  est une v.a. fonction de  $(X_1, \dots, X_n)$ , indépendante de la loi  $P$  de  $X$ . ( $S : (\Omega, \mathcal{A}) \rightarrow (\mathcal{X}, \mathcal{B})$ )

(Si cette fonction est utilisée pour évaluer un ou plusieurs paramètres inconnus de la loi de  $X$ , elle est appelée **estimateur**, et ses réalisations sont des **estimations**.)

**Exemples** Les fonctions  $S_1(X) = \sum_{i=1}^n X_i$ ,  $S_2(X) = \max_{1 \leq i \leq n} X_i$ ,  $S_3(X) = X_1$  et  $S_4(X) = (h(X_3 - X_1), X_2)$ , sont des statistiques de l'échantillon  $X = (X_1, \dots, X_n)$ .

Le premier objectif est d'estimer le paramètre  $\theta$ . Plus généralement, on peut chercher à estimer une fonction  $g(\theta) \in \mathbb{R}^p$  de ce paramètre.

### Définition 5

**a- Un estimateur**  $\delta$  de  $g(\theta)$  est une fonction de l'échantillon  $X$  (indépendante de  $P \in \mathcal{P}$ ) à valeurs dans  $g(\Theta)$  (c'est une fonction des v.a. observables ne dépendant pas des paramètres inconnus).

**b- Estimation** : c'est la valeur prise par l'estimateur sur l'échantillon observé  $(x_1, \dots, x_n)$ .

**Exemple** La moyenne empirique  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  est un estimateur de  $E(X)$ .

### Définition 6 Convergences

**a- Convergence forte** : Une suite d'estimateurs  $(\hat{g}_n)_{n \in \mathbb{N}^*}$  de  $g(\theta)$  (où  $\hat{g}_n$  est une fonction de l'échantillon de taille  $n$   $(X_1, \dots, X_n)$ ) est fortement convergente si

$$\forall \theta \in \Theta, \lim_n \hat{g}_n = g(\theta), \text{ } P_\theta\text{-presque sûrement.}$$

**Remarque** Pour simplifier, on confondra estimateur et suite d'estimateurs.

### Exemples

**E1.** Si  $X$  est intégrable ( $E(|X|) < +\infty$ ) alors  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{ps} E(X)$  c'est la loi forte des grands nombres

**E2.** Dans le modèle d'échantillonnage exponentiel  $\mathcal{P} = \{\mathcal{E}(\lambda), \lambda > 0\}$  les estimateurs

$\hat{\lambda}_1 = \frac{n}{\sum_{i=1}^n X_i}$  et  $\hat{\lambda}_2 = \frac{1}{\sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}}$  sont 2 estimateurs convergents (presque sûrement) de  $\lambda$ .

Ceci découle de la loi forte des grands nombres et le théorème de la continuité pour la convergence presque sûre suivant :

**Lemme : Théorème de continuité pour la convergence presque sûre**

Soit  $(X_n)_{n \in \mathbb{N}^*}$  une suite de v.a. qui converge presque sûrement (PS) vers  $X$ .

Soit  $g$  une fonction mesurable et  $\mathcal{C}$  l'ensemble des points de continuité de  $g$ .

Si  $P(X \in \mathcal{C}) = 1$ , alors  $g(X_n) \xrightarrow{PS} g(X)$ .

## I.3. Construction d'estimateurs convergents

### I.3.3. Le maximum de vraisemblance

Soit  $x = (x_1, x_2, \dots, x_n)$  une réalisation de l'échantillon  $(X_1, X_2, \dots, X_n)$  d'une v.a.  $X$ . On suppose que  $X$  suit une loi de probabilité dépendant d'un paramètre  $\theta$ . On note

$$L(\theta, x_1, \dots, x_n) = \begin{cases} \prod_{i=1}^n f_{\theta}(x_i) & \text{si } X \text{ est absolument continue} \\ \prod_{i=1}^n P_{\theta}(X = x_i) & \text{si } X \text{ est discrète} \end{cases}$$

**Définition 8 a-** L'application  $x = (x_1, x_2, \dots, x_n) \mapsto L(\theta, x)$  est appelée **loi conjointe** de  $x$ .

**b-** L'application  $\theta \mapsto L(\theta, x)$  est appelée **vraisemblance** de  $\theta$ .

#### Remarques

1. De la fonction  $L(\theta, x_1, x_2, \dots, x_n)$  on peut définir la variable aléatoire  $L(\theta, X_1, X_2, \dots, X_n)$ .
2. Les observations  $x_i$  jouent le rôle de paramètre de la vraisemblance, c'est-à-dire que la vraisemblance n'est définie qu'après l'observation des réalisations de la variable  $X$  ; La vraisemblance est donc une notion statistique, alors que la loi conjointe est une notion probabiliste.

#### Définition 9 Estimateur du Maximum de Vraisemblance

Si pour tout  $x \in \mathcal{X}^n$ , il existe une et une seule valeur de  $\theta \in \Theta$  (notée  $\hat{\theta}_{MV}$ ) telle que la vraisemblance soit maximale, alors la v.a.  $\hat{\theta}_{MV} = \hat{\theta}_{MV}(X_1, \dots, X_n)$  est appelée estimateur du maximum de vraisemblance (en abrégé EMV) de  $\theta$ .

**Principe** Si  $L$  est deux fois dérivable par rapport à  $\theta$ , on peut obtenir  $\hat{\theta}_{MV}$  en résolvant le système :

$$\begin{cases} \frac{\partial L}{\partial \theta} = 0 & (\text{équation de vraisemblance}) \\ \frac{\partial^2 L}{\partial \theta^2} < 0 \end{cases}$$

**Définition 10** La Log - Vraisemblance est le logarithme de la vraisemblance  $L(\theta, x)$ , c'est-à-dire la fonction :

$$\theta \rightarrow \text{Log}(L(\theta, x)) = \sum_{i=1}^n \text{Log}(f_{\theta}(x_i)) \left( = \sum_{i=1}^n \text{Log}(P_{\theta}(X = x_i)) \right).$$

**Remarque** Maximiser la Log-vraisemblance revient à maximiser la vraisemblance. Les calculs sont parfois plus simples pour la Log-vraisemblance.

**Proposition** (Propriété d'invariance de l'EMV)

Soit  $\hat{\theta}_{MV}$  l'EMV de  $\theta$  associé à la famille de lois  $\mathcal{P} = \{P_{\theta}(f_{\theta}), \theta \in \Theta\}$ .

Soit  $g : \Theta \rightarrow g(\Theta)$  mesurable bijective. Alors  $g(\hat{\theta}_{MV})$  est l'EMV de  $g(\theta)$  associé à la famille  $\mathcal{P}_g = \{P_{g^{-1}(\beta)}, \beta \in g(\Theta)\}$

**Remarque** On dit que  $g(\hat{\theta}_{MV})$  est l'EMV de  $g(\theta)$  même si  $g$  n'est pas bijective.

**Exemple** Pour le modèle de lois exponentielles  $\mathcal{P} = \{\mathcal{E}(\lambda), \lambda > 0\}$ , la Log-vraisemblance

est :  $\text{Log } L(\lambda, x) = -\lambda \sum_{i=1}^n x_i + n \text{Log } \lambda \Rightarrow$

L'EMV de  $\lambda$  est  $\hat{\lambda}_n = \frac{n}{\sum_{i=1}^n X_i}$ , et l'EMV de  $\theta = \frac{1}{\lambda}$  est  $\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i$ .

## I.4. Choix d'un estimateur

### I.4.1. Comparaison d'estimateurs

Soit une famille paramétrique de lois  $\mathcal{P} = \{P_{\theta}, \theta \in \Theta\}$ , et  $X_1, \dots, X_n$  n v.a.i.i.d. de loi  $P_{\theta} \in \mathcal{P}$ .

Soit  $\delta$  un estimateur de  $g(\theta)$ . Il est naturel de minimiser le risque d'erreur, qui est une mesure de la qualité des estimations envisagées.

#### Définition 12

- L'estimateur  $\delta$  ( de  $g(\theta)$  ) est dit sans biais, s'il est intégrable et si  $E_{\theta}(\delta) = g(\theta)$ ,  $\forall \theta \in \Theta$ .

- Le biais d'un estimateur intégrable  $\delta$  de  $g(\theta)$  est défini par :  $b(\delta) = E_{\theta}(\delta) - g(\theta)$ ,  $\forall \theta \in \Theta$ .

**Exemples** La moyenne empirique  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  est un estimateur sans biais de  $E(X)$ .

La variance empirique  $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  n'est pas un estimateur sans biais de  $\text{Var}(X)$ .

**Définition 13** Pour un estimateur  $\delta$  ( de  $g(\theta)$  ), on définit le risque quadratique ou écart (erreur) quadratique moyen (Mean Square Error ou MSE, en anglais) par :  $R(\delta, \theta)$  ou

$$R_{\theta}(\delta) = E_{\theta}(\delta - g(\theta))^2.$$

**Propriété** L'erreur quadratique moyenne de  $\delta$  se décompose en deux termes, le carré du biais et la variance de  $\delta$  :

$$\mathbf{R}_{\theta}(\delta) = [E_{\theta}(\delta) - g(\theta)]^2 + E_{\theta}[\delta - E_{\theta}(\delta)]^2 = [\mathbf{b}(\delta)]^2 + \mathbf{Var}_{\theta}(\delta).$$

## I.5. Amélioration d'estimateurs

On considère un modèle régulier de taille  $n$ .

### I.5.3. Familles exponentielles (ou modèles exponentiels)

#### I.5.3.1. Famille exponentielle d'ordre 1

**Définition 26** Une famille de lois  $\mathcal{P}=\{P_\theta, \theta \in \Theta\}$  est une famille exponentielle d'ordre 1 si :

a- Le support  $\Delta$  de  $X$  ne dépend pas de  $\theta$ ,

b- La loi de  $X$  sur  $\Delta$  est de la forme

$$f_\theta(x) = \exp\{a(x)\alpha(\theta) + b(x) + \beta(\theta)\} = h(x).c(\theta)\exp\{a(x)\alpha(\theta)\} \quad (\text{I})$$

où  $\alpha(\cdot)$ ,  $\beta(\cdot)$  et  $c(\cdot)$  ne dépendent que de  $\theta$ ,

$a(\cdot)$ ,  $b(\cdot)$  et  $h(\cdot)$  ne dépendent que de  $x$ .

#### Exemples

**E3.** Les familles des lois de Bernoulli  $\mathcal{B}(p)$ , gaussiennes  $\mathcal{N}(0, \sigma^2)$ ,  $\sigma > 0$ , gamma  $(\alpha, \lambda_0)$ ,  $\lambda_0$  connu, correspondent à des familles exponentielles :

a-  $X \sim \mathcal{B}(p) \Rightarrow P(X=x) = p^x (1-p)^{1-x} = \exp\left\{x \cdot \text{Ln}\left(\frac{p}{1-p}\right) + \text{Ln}(1-p)\right\}, x=0,1$

ici  $a(x) = x$ ,  $\alpha(p) = \text{Ln}(p) - \text{Ln}(1-p)$ ,  $b(x) = 0$ ,  $\beta(p) = \text{Ln}(1-p)$ .

b-  $X \sim (0, \sigma^2) \Rightarrow$

c-  $X \sim \text{Gamma}(\alpha, \lambda_0) \Rightarrow$

**E4.** La famille de loi de Cauchy  $(\theta, 1)$  n'est pas exponentielle, en effet

$$f_\theta(x) = \frac{1}{\pi} \frac{1}{1+(x-\theta)^2} = \frac{1}{\pi} \exp\{-\text{Ln}[1+(x-\theta)^2]\}$$

avec  $-\text{Ln}[1+(x-\theta)^2] \neq a(x).\alpha(\theta)$  car la fonction logarithme n'est pas linéaire.

#### I.5.3.1. Généralisation

Soient **i** /  $Y \in \mathbb{R}^p$  un vecteur aléatoire,  $X=(X_1, \dots, X_n) \in \mathbb{R}^{np}$  un  $n$ -échantillon de  $Y$ , et  $\theta \in \mathbb{R}^k$ ,

**ii** / le support  $\Delta$  de  $Y$  ne dépend pas de  $\theta$ .

**Définition 27** (Définition exacte d'une famille exponentielle)

La famille des lois  $P_\theta$  caractérisée par une densité de la forme (II),

$$f_\theta(y) = \exp\left\{\sum_{i=1}^k a_i(y)\alpha_i(\theta) + b(y) + \beta(\theta)\right\} = h(y).c(\theta)\exp\left\{\sum_{i=1}^k a_i(y)\alpha_i(\theta)\right\} \quad (\text{II})$$

sur un ensemble  $\Delta$  indépendant de  $\theta$  (et nulle en dehors de  $\Delta$ ), est appelée famille exponentielle.

**Remarque** On peut réécrire une famille exponentielle comme suit :

$$f_\theta(x) = h(x).c(\theta)\exp\{T(x)Q(\theta)\}$$

$T$  et  $Q$  sont des fonctions respectivement de  $\mathcal{X}$  et  $\Theta$  dans  $\mathbb{R}^k$ .

**Définition 29** Dans le cas particulier où  $\mathcal{X} \subset \mathbb{R}^k$  et  $\Theta \subset \mathbb{R}^k$ , et

$$f_{\theta}(x) = h(x).c(\theta) \exp\{\theta \cdot x\} \quad (\text{III})$$

la famille est dite (exponentielle) naturelle.

### Remarque

**R10.** Un changement de variable de  $X$  en  $T(X)$  et une re-paramétrisation de  $\theta$  en  $\eta = Q(\theta)$  nous permettent de considérer principalement la forme naturelle (III), bien que les espaces  $T(\mathcal{X})$  et  $Q(\Theta)$  soient difficiles à décrire et à utiliser.

### Définition 30 (Famille régulière)

Soit une famille exponentielle naturelle. Elle est dite régulière si l'espace naturel des paramètres  $\mathcal{N}$  est un ensemble ouvert ( $\mathcal{N} = \{\theta / \int_{\mathcal{X}} e^{\theta \cdot x} h(x) dP_X(x) < \infty\}$ ).

**Propriété** Les familles exponentielles naturelles peuvent être réécrites

$$f_{\theta}(x) = h(x).c(\theta) e^{\theta \cdot x} = h(x) e^{\theta \cdot x - \varphi(\theta)}$$

où  $\varphi(\theta) = -\ln c(\theta)$  est dite fonction cumulée des moments.

**Lemme** Si  $\theta$  appartient à l'intérieur de  $\mathcal{N}$ , alors la fonction  $\varphi$  est  $\mathcal{C}^{\infty}$  et :

$$E_{\theta}(X) = \nabla \varphi(\theta) \left( = \frac{\partial}{\partial \theta_i} \varphi(\theta) \right) \quad (\nabla \text{ est l'opérateur gradient}),$$

$$\text{et } \text{Cov}(X_i, X_j) = \frac{\partial^2 \varphi(\theta)}{\partial \theta_i \partial \theta_j}.$$

### Exemples

$$\text{E5. } X \sim \mathcal{P}(\lambda) \Rightarrow P_{\lambda}(X = x) = e^{-\lambda} \frac{\lambda^x}{x!} =$$

$$\text{E6. } X \sim \mathcal{B}(n, \theta) \Rightarrow P_{\theta}(X = x) = C_n^x \theta^x (1 - \theta)^{n-x} =$$

**Proposition** On considère une famille exponentielle définie par :

$$f_{\theta}(x) = h(x).c(\theta) e^{\theta T(x)} = h(x) e^{\theta T(x) - \varphi(\theta)}$$

Si  $\theta$  appartient à l'intérieur de  $\mathcal{N}$ , alors  $E_{\theta}(T(X)) = \varphi'(\theta)$

$$\text{et } \text{Var}_{\theta}(T(X)) = \varphi''(\theta).$$

De plus  $T(X)$  est un estimateur efficace de  $E_{\theta}(T(X)) = g(\theta)$ , c'est-à-dire que

$$\text{Var}_{\theta}(T(X)) = \varphi''(\theta) \text{ est la borne de Cramer-Rao de } g(\theta) \text{ (égale à } \frac{(g'(\theta))^2}{I(\theta)}).$$