

1. Modèle Statistique.

Soit une population dont on veut étudier un caractère.

a. Calcul des probabilités

permet d'organiser le modèle

a) espace de probabilité (Ω, \mathcal{A}, P)

b) une v.a $(\Omega, \mathcal{A}, P) \xrightarrow{X} \mathcal{K}$

c) le type de distribution de X .

Exemple: Répartition des garçons et filles dans les familles de 7 enfants.

X v.a qui compte le nbre de filles

$X: (\Omega, \mathcal{G}(\Omega), P) \rightarrow \{0, 1, 2, \dots, 7\}, \mathcal{G}(\Omega), B(7, p) \quad P_X = P(X=k)$

$\Omega = \{G, F\}$

b. Soit le calcul des statistiques donne p un % de chances.

1. les calculs statistiques ont pour objet d'informer sur la valeur du paramètre de 2 manières.

* En indiquant un nombre (probable) (estimation ponctuelle)

* " " " " intervalle de confiance (est. ensemble)

c) Soit $X: (\Omega, \mathcal{A}, P) \rightarrow \mathcal{K} \quad \mathcal{H} = X(\Omega)$.

Définition 1: Un modèle statistique est un système $(\mathcal{X}, \mathcal{b}, f(x, p), \text{et } S \subset \mathbb{R}^d)$

où $f(x, p)$ est la densité de la loi de probabilité de la v.a X .

$S \subset \mathbb{R}^d$ ensemble des paramètres.

(2)

$(X, p \in S)$, à $f(x, p)$ on peut associer une probabilité P_p (la loi de prob. de X)

$$dP_p(x) = f(x, p) dx \quad (x \in X).$$

$$P_p(C) = \int_C f(x, p) dx \\ = \sum_{x \in C} f(x, p).$$

Exemples: ① Modèle statistique par la ra de bernoulli de $X \rightarrow H$.

$$(X = \{0, 1\}, \mathcal{G}(\{0, 1\}), f(x, p), p \in [0, 1]) \\ \text{ou } f(x, p) = (1-p) \left(\frac{p}{1-p}\right)^x$$

② Modèle statistique par la ra binomiale

$$(X = \{0, 1, 2, \dots, n\}, \mathcal{G}(X), f(x, p), p \in [0, 1]) \\ \text{ou } f(x, p) = \binom{n}{x} p^x (1-p)^{n-x}$$

③ Modèle statistique par la ra de Poisson.

$$(X = \mathbb{N}, \mathcal{G}(\mathbb{N}), f(x, \lambda), \lambda \in \mathbb{R}^+) \\ f(x, \lambda) = e^{-\lambda} \cdot \frac{\lambda^x}{x!}$$

④ Modèle statistique de la loi normale.

$$(X = \mathbb{R}, \mathcal{B}_{\mathbb{R}}, f(x, m, \sigma), (m, \sigma) \in \mathbb{R} \times \mathbb{R}^+) \\ \text{ou } f(x, m, \sigma) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-m)^2}$$

Rappel :

Une v.a. X est dite complètement centrée si $E_p(X) = 0 \quad \forall p \in S$.

" " " " " de carré sommable si $E_p(X^2) < \infty \quad \forall p \in S$.

Définition 2: Soit x_1, x_2, \dots, x_n n.v.a. iid

On appelle fonction de vraisemblance d'un n-échantillon, la densité conjointe de n n.v.a.

$$L(x_1^n, p) = L_{(x_1, x_2, \dots, x_n)}(x_1, \dots, x_n, p) = \prod_{i=1}^n f(x_i, p).$$

Remarque: ① So $(x, b, f(x, p), p \in S)$ est le modèle de la n.v.a. X alors le modèle de l'échantillon de taille n est

$$(x^n, b^n, L(x_1^n, p), p \in S) = (x, b, f(x, p), p \in S)^n.$$

Nécessairement

$$\text{On a } \int_{x^n} L(x_1^n, p) dx_1 dx_2 \dots dx_n = 1.$$

$$\begin{aligned} \text{② } L(x_1^n, p) &= P_p(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) \\ &= P_p(X_1 = x_1) P_p(X_2 = x_2) \dots P_p(X_n = x_n). \end{aligned}$$

Exemples: ① Si $X \sim p(\lambda)$.

$(N^n, p(N^n), L(x_1^n, \lambda), \lambda \in \mathbb{R}^+)$

$$\text{on } L(x_1^n, \lambda) = \prod_{i=1}^n f(x_i, \lambda) = \prod_{i=1}^n e^{-\lambda} \cdot \frac{\lambda^{x_i}}{(x_i)!} = e^{-n\lambda} \cdot \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i)!}.$$

② Si $X \mapsto \mathcal{B}(k, p)$.

$$(\{0, 1, \dots, k\}^n, \mathcal{P}(\{0, 1\}^n), L(\hat{x}_1^n, p), p \in [0, 1]).$$

$$\begin{aligned} L(\hat{x}_1^n, p) &= \prod_{i=1}^n \binom{k}{x_i} p^{x_i} (1-p)^{k-x_i} \\ &= p^{\sum_{i=1}^n x_i} \cdot (1-p)^{nk - \sum_{i=1}^n x_i} \cdot \prod_{i=1}^n \frac{k!}{x_i! (k-x_i)!} \end{aligned}$$

③ Si $X \mapsto N(m, \sigma)$.

$$(\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n}, L(\hat{x}_1^n, m, \sigma), (m, \sigma) \in \mathbb{R} \times \mathbb{R}^+)$$

$$\text{on } L(\hat{x}_1^n, m, \sigma) = (2\pi\sigma^2)^{-\frac{n}{2}} \cdot e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2}.$$

Définition 3: Soit $X: \Omega \rightarrow (x, b, z, \sigma \in S)$.

Soit un n -échantillon $(x^n, b^n, z^n, \sigma \in S)$.

On appelle statistique (d'échantillonnage), une application, notée T , mesurable de $(x^n, b^n) \rightarrow (E, \mathcal{F})$

$$(x_1, \dots, x_n) \mapsto T(x_1, \dots, x_n).$$

$E = \mathbb{R}$ statistique scalaire

$E = \mathbb{Z}$ " discrète.

$E = \mathbb{R}^d$ " vectorielle.

Exemples: ① $X \mapsto \Gamma(a, 1)$ dont le module est

$$(\mathbb{R}^+, \mathcal{B}_{\mathbb{R}^+}, f(x, a), a \in \mathbb{R}^+) \text{ on } f(x, a) = \frac{1}{\Gamma(a)} e^{-x} \cdot x^{a-1}.$$

Son échantillon le donne $(\mathbb{R}^+{}^n, \mathcal{B}_{\mathbb{R}^+{}^n}, L(\hat{x}_1^n, a), a \in \mathbb{R}^+)$

$$L(\hat{x}_1^n, a) = (\Gamma(a))^n \cdot e^{-\sum_{i=1}^n x_i} \cdot \left(\prod_{i=1}^n x_i \right)^{a-1}.$$

(5)

Une statistique d'échantillonnage $T: \mathbb{R}_+^n \rightarrow \mathbb{R}$
 $(x_1, \dots, x_n) \mapsto T(x) = \frac{1}{n} \sum_{i=1}^n \log x_i.$

$$T = \frac{1}{n} \sum_{i=1}^n \log x_i$$

② Soit $Z = (X, Y)$ de modèle $(\mathbb{R}_+^2, \mathcal{B}_{\mathbb{R}_+^2}, f(x, y, s), s \in \mathbb{R}^+)$

$$s \quad f_s(x, y) = \exp(-sx - y/s)$$

(so: Vérifier que $f_s(x, y)$ est une densité de proba.)

1. échantillon

$$T: \mathbb{R}_+^2 \rightarrow \mathbb{R}$$

$(x, y) \mapsto T(x, y) = xy - 1$ est une statistique.

$$T = XY - 1$$

Remarque: Une statistique ne dépend pas du paramètre.

Définition: Soit X une va

Soit x_1, \dots, x_n un n -échantillon et T une statistique.

$$T: (\mathcal{X}^n, \mathcal{G}^n) \rightarrow (E, \mathcal{G}).$$

On appelle modèle statistique image par T le modèle statistique

la va $T \quad (E, \mathcal{G}, \mathbb{P}_s^T, s \in S)$ où \mathbb{P}_s^T est la loi de proba. de la va T

(En général T admet une densité de proba. $f_T(t, s)$ où
 $d\mathbb{P}_s^T(t) = f(t, s) dt$.)

2. Estimateur Sans biais Convergent Exhaustif.

(6)

Definition 1: Un estimateur T du paramètre θ du modèle statistique $(X, \mathcal{C}, \mathcal{F}, \mathcal{P})$, $\theta \in S$ est dit sans biais si

$$E_{\theta}(T) = \theta \quad \forall \theta \in S.$$

Exemples: ① Si $X \sim b(p)$ bernoulli

$$E(X) = p \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad E_p(\bar{X}) = p$$

\bar{X} est un estimateur sans biais de p .

② Si $X \sim B(n, p)$

$$E(X) = np \quad E_p(\bar{X}) = np \quad \text{est biaisé.}$$

③ Si $X \sim \chi^2(\lambda)$.

$$T = \frac{n}{n-1} S_n'^2 = S_n^2 \quad \text{est sans biais de } \lambda \quad \text{car.}$$

$$E_{\lambda}(T) = \frac{n}{n-1} E(S_n'^2) = \frac{n}{n-1} \cdot \frac{n-1}{n} \cdot \text{Var}_{\lambda}(X) = \lambda.$$

car

$$E(S_n'^2) = \frac{1}{n} \sum_{i=1}^n E(X_i^2) = \frac{1}{n} \sum_{i=1}^n (E(X_i^2) - \frac{\lambda^2}{n}) = \frac{1}{n} \sum_{i=1}^n ((n-1)\lambda) = \frac{n-1}{n} \lambda.$$

Souvent on veut estimer non pas $\theta \in S$ mais une fonction de θ .

Exemple: Si $X \sim P(a, p)$ $(a, p) \in \mathbb{R}^+ \times \mathbb{R}$.

$$\text{On sait que } E(X) = \frac{a}{p} \quad \text{et } \text{Var} X = \frac{a}{p^2}.$$

On pourra chercher à estimer non pas a et p mais

$$h(a, p) = \frac{a}{p} \quad \text{et } k(a, p) = \frac{a}{p^2}.$$

(7)

Définition 2: $(\mathcal{X}, \mathcal{G}, \mathcal{I}, \mathcal{S})$ est un modèle statistique,
on appelle paramètre du modèle une application $h: \mathcal{S} \rightarrow F$.
En particulier, on retrouve le paramètre initial si $h = \text{id}_{\mathcal{S}}: \mathcal{S} \rightarrow \mathcal{S}$.

Définition 3: Soit $(\mathcal{X}, \mathcal{G}, \mathcal{I}, \mathcal{S})$ et $h: \mathcal{S} \rightarrow F$ un paramètre.
On appelle estimateur du paramètre h toute statistique $T: \mathcal{X}^n \rightarrow F$.
Un tel estimateur est dit sans biais si

$$\forall \theta \in \mathcal{S} \quad E_p(T) = h(\theta).$$

Exemples: ① $X \rightsquigarrow \mathcal{P}(a, p), (a, p) \in \mathbb{R}^+ \times \mathbb{R}.$

$$h: \mathbb{R}^+ \times \mathbb{R} \rightarrow \mathbb{R} \\ (a, p) \mapsto \frac{a}{p} = h(a, p).$$

$$g: \mathbb{R}^+ \times \mathbb{R} \rightarrow \mathbb{R} \\ (a, p) \mapsto g(a, p) = \frac{a}{p^2}.$$

$$\text{Soit } T_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i: \mathcal{X}^n \rightarrow \mathbb{R}$$

$$T_1 = \bar{X} \text{ est un esti. s.b. pour } h. \\ E(\bar{X}) = \frac{a}{p}.$$

$$T_2 = \frac{n}{n-1} S_n^2 = S_n^2: \mathcal{X}^n \rightarrow \mathbb{R}$$

$$\text{On a } E(T_2) = E(S_n^2) = \frac{a}{p^2}$$

T_2 est s.b. de g .

$$\textcircled{2} \quad X \rightsquigarrow \mathcal{B}(n, p) \quad p \in [0, 1].$$

$$\text{Soit } h: [0, 1] \rightarrow \mathbb{R} \\ p \mapsto h(p) = np.$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i: \mathcal{X}^n \rightarrow \mathbb{R}$$

\bar{X} est un esti. sans biais de h car
 $E(\bar{X}) = np.$

et $T = \bar{X}$ est un esti. s.b. de h .

(8)

Définition 3: Soit h un paramètre de $(\mathcal{X}, \mathcal{G}, f(x|\theta), \theta \in S)$ (modèle).

Soit T_n un estimateur de h sur l'échantillon de taille n .

① On dit que T_n est asymptotiquement sans biais si

$$\forall \theta \in S \quad E_p(T_n) \xrightarrow{n \rightarrow \infty} h(\theta)$$

② Si $T_n \xrightarrow{L_2} h(\theta)$, $\forall \theta$, On dit qu'il est CV en proba.

$$\Leftrightarrow P_p(|T_n - h(\theta)| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

Exemple: $X \sim N(\mu, \sigma)$ σ connu.

alors $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ est un est. sans biais de μ .

$$\bar{X} \xrightarrow{L_1} E(X) = \mu$$

$$\bar{X}_n \xrightarrow{L_2} \mu \quad \text{car } E_p(|\bar{X}_n - \mu|^2) \xrightarrow{n \rightarrow \infty} 0$$

" $\frac{\sigma^2}{n}$

Définition 4: Soit $(\mathcal{X}, \mathcal{G}, f_\theta, \theta \in S)$ un modèle pour la v.a. X .
Une statistique $T(X_1, \dots, X_n)$ est dite exhaustive si la f.t.

② ~~$E_p(X_1, \dots, X_n | T=t) = k(t)$ est indépendante de θ .~~

car si $Y = (X_1, \dots, X_n)$ ~~$E_p(Y|T) = k(T, \theta) = k(T)$~~

Exemple:

① ~~$P(X|T=t)$~~ non f.t. de θ .

Exemples

(9)

① $X \sim b(p)$. $p \in [0, 1]$

$$f(x, p) = p^x (1-p)^{1-x}$$

Soit $T = \sum_{i=1}^n X_i$ une statistique.

T est exhaustive car.

$$P((X_1=x_1, \dots, X_n=x_n) | T=t) = \frac{P(X_1=x_1, \dots, X_n=x_n, \sum X_i=t)}{P(\sum X_i=t)}$$

$$= \begin{cases} 0 & \text{si } \sum_{i=1}^n X_i \neq t \\ \frac{P(X_1=x_1, \dots, X_n=x_n)}{P(\sum X_i=t)} & \text{sinon} \end{cases}$$

$$= \begin{cases} 0 & \text{si } \sum X_i \neq t \\ \frac{\prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}}{C_n^t p^t (1-p)^{n-t}} = \frac{p^{\sum x_i} (1-p)^{n-\sum x_i}}{C_n^t p^t (1-p)^{n-t}} = \frac{1}{C_n^t} \end{cases}$$

Indépendante de p .

La statistique est exhaustive.

② $X \sim g(\lambda)$. $T = \sum_{i=1}^n X_i$ est exhaustive pour λ .

$(T \sim g(\lambda)) \quad P(x_1, \dots, x_n | T=t) = \frac{P(x_1, \dots, x_n, T=t)}{P(T=t)}$

(10)

$$\begin{aligned}
 P(x_1, \dots, x_n | T=t) &= P(x_1, \dots, x_{n-1}, t - \sum_{i=1}^{n-1} x_i) \\
 &= \prod_{i=1}^{n-1} \left(\frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \right) \cdot \frac{e^{-\lambda} \lambda^{t - \sum_{i=1}^{n-1} x_i}}{(t - \sum_{i=1}^{n-1} x_i)!} \\
 &= \frac{e^{-n\lambda} \lambda^t}{x_1! x_2! \dots x_{n-1}! (t - \sum_{i=1}^{n-1} x_i)!}
 \end{aligned}$$

Donc $P(T=t) = e^{-n\lambda} \frac{(\lambda n)^t}{t!} = e^{-n\lambda} \frac{\lambda^t n^t}{t!}$

$$P(x_1, \dots, x_n | T=t) = \frac{t!}{n^t x_1! \dots x_{n-1}! (t - \sum_{i=1}^{n-1} x_i)!} \text{ Indép de } \lambda$$

Donc T est exhaustive


Théorème de factorisation de Fisher.

Soit $(X, \mathcal{B}, f_0, \mathcal{S}(\mathcal{S}))$ un modèle pour la var X dont un n-échantillon est $(X^n, \mathcal{B}^n, L(x^n, \theta), \mathcal{S}(\mathcal{S}))$. Alors une statistique T définie sur X^n et à valeurs dans E , est exhaustive par Δ si et seulement si

① \exists une ft mesurable $g_\Delta: E \rightarrow \mathbb{R}^T$

② \exists une fonction mesurable $h: X^n \rightarrow \mathbb{R}^T$ indépendante de Δ

et $L(x^n, \theta) = (g_\Delta \circ T)(x_1, \dots, x_n) \cdot h(x_1, \dots, x_n) \quad \forall \theta.$



Exemples : ① $X \rightsquigarrow b(p)$.

(4)

(x_1, \dots, x_n) de loi binaire $L(x_1^n, p) = p^{\sum x_i} \cdot (1-p)^{n - \sum x_i} = (1-p)^n \cdot \left(\frac{p}{1-p}\right)^{\sum x_i}$.

$T = \sum x_i$

$$L(x_1^n, p) = (1-p)^n \cdot \left(\frac{p}{1-p}\right)^{T(x_1, \dots, x_n)}$$

$$= (g_p \circ T)(x_1, \dots, x_n) \cdot 1$$

$T = \sum x_i$ est exhaustive.

$g_p(t) = (1-p)^n \cdot \left(\frac{p}{1-p}\right)^t$ et $h=1$.

② $X \rightsquigarrow N(\mu, \sigma)$.

$$L(x_1^n, \mu, \sigma) = (2\pi\sigma^2)^{-\frac{n}{2}} \cdot \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

① Si μ est connue $T = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$

T est une statistique exhaustive de σ

$$L(x_1^n, \sigma) = (2\pi\sigma^2)^{-\frac{n}{2}} \cdot \exp\left(-\frac{1}{2\sigma^2} T(x_1, \dots, x_n)\right)$$

$$= (g_\sigma \circ T)(x_1, \dots, x_n) \cdot 1$$

② Si σ est connue

$$L(x_1^n, \mu) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum x_i^2 - \frac{n\mu^2}{2\sigma^2} + \frac{n\mu}{\sigma^2} \sum x_i\right)$$

$$= \exp\left(-\frac{n\mu^2}{2\sigma^2} + \frac{n\mu}{\sigma^2} \cdot \frac{1}{n} \sum x_i\right) \cdot (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum x_i^2\right)$$

$$= (g_\mu \circ \bar{X})(x_1^n) \cdot h(x_1^n)$$

c) Si μ et σ inconnues

Ainsi (\bar{X}, S^2) est exhaustif par (μ, σ) $S^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$

Estimation à variance minimale
 Information de Fisher.
 Estimateur efficace.

Sur la classe des estimateurs sans biais $h: S \rightarrow E$.

$$\mathcal{E}_h = \{ T: X^n \rightarrow E \mid E_p(T) = h(p) \quad \forall p \in S \}.$$

On peut mettre un pré-ordre

$$T_1 \leq T_2 \quad \text{ssi} \quad \text{Var}_p(T_1) \geq \text{Var}_p(T_2) \quad \forall p \in S$$

Définition : On dit que $T \in \mathcal{E}_h$ est à variance minimale si

$$\forall T' \in \mathcal{E}_h \quad \text{Var}_p(T) \leq \text{Var}_p(T') \quad (\forall p \in S)$$

Proposition : Un estimateur sans biais T est à variance minimale

si $\forall p, E_p(TY) = 0$ pour toute statistique Y centrée et de carré sommable,

Preuve : Soit un autre estimateur sans biais S de h , alors $T-S$ est centrée donc $E_p(T(T-S)) = 0$ (car par hypothèse centrée).

$$E(T^2 - TS) = 0 \quad \text{d'où} \quad \text{Var}_p S - \text{Var}_p T \geq 0$$

$$\begin{aligned} \text{En effet} \quad \text{Var}_p S - \text{Var}_p T &= E(S^2) - E^2(S) - E(T^2) + E^2(T) \\ &= E(S^2) - E(T^2) - (h(p))^2 + (h(p))^2 = E(S^2) - E(T^2). \end{aligned}$$

$$\text{Var}_p(S-T) = E_p((S-T)^2) = E_p(S^2 + T^2 - 2ST) = E_p(S^2) + E_p(T^2) - 2E_p(TS) = E(S^2) - E(T^2)$$

$$\text{Donc} \quad \text{Var}_p S - \text{Var}_p T = \text{Var}_p(S-T) \geq 0$$

$$\Rightarrow \text{Var}_p S \geq \text{Var}_p T. \quad \forall S \text{ estimateur sans biais}$$

Donc T est à variance minimale.

Proposition: Si T est un estimateur sans biais du paramètre h et si Y est une statistique exhaustive de p alors $E(T|Y)$ est un estimateur sans biais de variance moindre que T .

Preuve: Puisque Y est exhaustive.

$$E_p(T|Y) = E(T|Y) \text{ ne dépend pas de } p.$$

$$\text{et est sans biais } E_p(E(T|Y)) = E_p(T) = h(p).$$

$$\text{et d'autre part } \text{Var}_p(E(T|Y)) \leq \text{Var}_p T.$$

Proposition: Il ne peut exister qu'un seul estimateur sans biais de variance minimale d'un paramètre h .

Preuve: Supposons qu'il existe T_1 et T_2 de même variance et minimale. (T_1 et T_2 sans biais) alors $T = \frac{T_1 + T_2}{2}$ est un estimateur sans biais

$$\text{et } \text{Var}_p\left(\frac{T_1 + T_2}{2}\right) < \text{Var}_p T_1 = \text{Var}_p T_2.$$

$$\text{Var}\left(\frac{T_1 + T_2}{2}\right) = \frac{1}{4} \text{Var}_p T_1 + \frac{1}{4} \text{Var}_p T_2 + \frac{1}{2} \text{Cov}(T_1, T_2) < \text{Var}_p T_1$$

$$\frac{1}{2} \text{Var}_p T_1 + \frac{1}{2} \text{Cov}(T_1, T_2) < \text{Var}_p T_1$$

$$\Rightarrow \text{Cov}(T_1, T_2) < \text{Var}_p T_1 \quad (1)$$

D'autre part on sait que

$$\text{Cov}_p(T_1, T_2) \leq (\text{Var}_p T_1, \text{Var}_p T_2)^{1/2} \quad (2).$$

$$\text{Cov}_p(T_1, T_2) \leq \text{Var}_p T_1 \quad (3).$$

$$(1) \text{ et } (3) \Rightarrow \text{Cov}_p(T_1, T_2) = \text{Var}_p T_1 \xrightarrow{(2)} (T_1 - E_p(T_1)) \text{ collinéaire à } (T_2 - E_p(T_2))$$

$$\text{donc } \exists k(p) \text{ tq } (T_1 - E_p(T_1)) = k(p)(T_2 - E_p(T_2)) \quad (4)$$

$$\text{donc } \text{Cov}_p(T_1, T_2) = k(p) \cdot \text{Var}_p T_1 \quad (5) \Rightarrow k(p) = 1 \xrightarrow{(4)} T_1 = T_2$$

(14)

Définition: Soit $(\mathcal{X}, \mathcal{b}, f_\theta, \theta \in S)$ un modèle.

Soit un n -échantillon dont la fonction de vraisemblance

est $L(x_1^n, \theta)$, $\theta \in S$, $(x_1^n) \in \mathcal{X}^n$

Soit la statistique

$$V_\theta(x_1^n) = \frac{d}{d\theta} \log L(x_1^n, \theta) \quad (\mathcal{X}^n \rightarrow \mathbb{R}) \quad (\text{ft score})$$

Si V_θ est définie

est complètement centrée

est de carré bornable

Mais on appelle Information de Fisher l'application $I_n(\theta) = E_\theta(V_\theta^2)$

$$I_n(\theta) = \begin{cases} \int_{\mathcal{X}^n} \left(\frac{d}{d\theta} \log L(x_1^n, \theta) \right)^2 \cdot L(x_1^n, \theta) dx_1 - dx_n & (\text{cas continu}) \\ \sum \left(\frac{d}{d\theta} \log L(x_1^n, \theta) \right)^2 L(x_1^n, \theta) & (\text{cas discret}) \end{cases}$$

Remarque: ① $I_n(\theta) = E_\theta(V_\theta^2) = \text{Var}_\theta(V_\theta)$

② On demande que V_θ soit centrée pour s'assurer de la dérivabilité sous le signe \int ou \sum de $\int_{\mathcal{X}^n} L(x_1^n, \theta) dx_1^n = 1$

Si on a pu dériver $\int_{\mathcal{X}^n} L(x_1^n, \theta) dx_1^n = 1$

$$\int_{\mathcal{X}^n} \frac{d}{d\theta} \log L(x_1^n, \theta) \cdot L(x_1^n, \theta) dx_1^n = 0$$

$$E(V_\theta) = 0.$$

③ V_θ peut être regardé comme une v. a $V_\theta: \mathcal{I} \rightarrow \mathbb{R}$

$$V_\theta = \frac{d}{d\theta} \log L(x_1, \dots, x_n, \theta).$$

$$4) V_n(x^n) = \sum_{i=1}^n \frac{d}{dx} \log f_0(x_i)$$

(15)

Exemples: Si $X \sim N(m, \sigma)$.

Supposons σ connu.

Recherche de V_n .

$$f(x, m, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-m)^2}$$

$$\log f(x, m, \sigma) = -\log \sigma\sqrt{2\pi} - \frac{1}{2\sigma^2}(x-m)^2$$

$$\frac{d}{dm} \log f(x, m, \sigma) = \frac{2}{2\sigma^2}(x-m) = \frac{x-m}{\sigma^2}$$

$$V_n(x^n) = \sum_{i=1}^n \frac{d}{dm} \log f(x_i, m, \sigma) = \sum_{i=1}^n \left(\frac{x_i - m}{\sigma^2} \right) = \frac{1}{\sigma^2} \left(\sum_{i=1}^n x_i - mn \right)$$

$$= \frac{n}{\sigma^2} (\bar{X} - m)$$

$$E_m(V_n^2) = E_m \left(\frac{n^2}{\sigma^4} (\bar{X} - m)^2 \right) = \frac{n}{\sigma^2} E_m \left(\left(\frac{\bar{X} - m}{\sigma/\sqrt{n}} \right)^2 \right)$$

$$\frac{\bar{X} - m}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\left(\frac{\bar{X} - m}{\sigma/\sqrt{n}} \right)^2 \sim P\left(\frac{1}{2}, \frac{1}{2}\right) \Rightarrow E \left(\left(\frac{\bar{X} - m}{\sigma/\sqrt{n}} \right)^2 \right) = 1$$

$$\Rightarrow \boxed{I_n(m) = \frac{n}{\sigma^2}}$$

(16)

Inégalité de Cramer-Rao (Fisher-Darmois-Cramer-Rao FDCR).

Soit un n -échantillon $(X^n, \mathcal{L}(X^n, \theta), \theta \in S \subset \mathbb{R})$

Soit T un estimateur de θ .

$$\text{Alors } \text{Var}_\theta(T) \geq \frac{\left(\frac{d}{d\theta} E_\theta(T)\right)^2}{I_n(\theta)} \quad (\text{Si } I_n(\theta) \text{ existe}).$$

Démonstration:

$$E_\theta(T) = \int T(x^n) L(x^n, \theta) dx^n$$

$$\frac{d}{d\theta} E_\theta(T) = \int T(x^n) \frac{d}{d\theta} L(x^n, \theta) dx^n$$

$$= \int T(x^n) \frac{d}{d\theta} \log L(x^n, \theta) \cdot L(x^n, \theta) dx^n$$

$$= E_\theta(T V_\theta)$$

$$\text{Alors } E_\theta((T - E_\theta(T)) V_\theta) = E_\theta(T V_\theta - E_\theta(T) V_\theta) = E_\theta(T V_\theta) - E_\theta(T) E_\theta(V_\theta) = E_\theta(T V_\theta)$$

$$\text{Donc } E_\theta((T - E_\theta(T)) V_\theta) = \frac{d}{d\theta} E_\theta(T) \Leftrightarrow$$

$$\text{Inégalité de Schwartz} \rightarrow \left(\frac{d}{d\theta} E_\theta(T)\right)^2 \leq E_\theta((T - E_\theta(T))^2) E_\theta(V_\theta^2)$$

$$\text{Donc } \left(\frac{d}{d\theta} E_\theta(T)\right)^2 \leq \text{Var}_\theta(T) \cdot I_n(\theta)$$

Corollaire: Si h est un paramètre du modèle, h dérivable et si T est un estimateur sans biais de h

$$\text{Alors } \boxed{\text{Var}_\theta(T) \geq \frac{\left(\frac{d}{d\theta} h(\theta)\right)^2}{n I_1(\theta)}}$$

cad que la variance de tout estimateur sans biais est minorée par un nombre qui ne dépend pas de cet estimateur. (17)

⇒ C'est donc un minorant universel pour la variance des estimateurs sans biais de h .

Donc si $\mathcal{E}_b(h) = \{ \text{des estimateurs sans biais de } h \}$

$$\inf \text{Var}_p(T) \geq \frac{(h'(p))^2}{I_n(p)} \quad \forall T \in \mathcal{E}_b(h).$$

Définition : Un estimateur sans biais T de h est dit efficace si $\text{Var}_p T = \frac{(h'(p))^2}{I_n(p)}$

Donc un estimateur efficace est à variance minimale (Réciproque est fausse).

Proposition : 1°) $I_n(p) = -E_p \left[\frac{d}{dp} V_p \right]$

2°) Si $I_1(p)$ est l'information donnée par le 1-échantillon alors $I_n(p) = n I_1(p)$.

Preuve : ① On sait que $\int_{\mathcal{X}^n} L(x_1^n, p) dx_1^n = 1$.

$$\int_{\mathcal{X}^n} \frac{d}{dp} \log L(x_1^n, p) \cdot L(x_1^n, p) dx_1^n = 0$$

$$\int_{\mathcal{X}^n} \frac{d^2}{dp^2} \log L(x_1^n, p) \cdot L(x_1^n, p) dx_1^n + \int_{\mathcal{X}^n} \left(\frac{d}{dp} \log L(x_1^n, p) \right)^2 L(x_1^n, p) dx_1^n = 0.$$

$$\Rightarrow E(V_0^2) = - \int \frac{d}{d\theta} V_0(x) \cdot L(x_1^n, \theta) dx_1^n$$

$$\Rightarrow E_0(V_0^2) = - E_p \left[\frac{d}{d\theta} V_0 \right]$$

$$2^o) L(x_1^n, \theta) = \prod_{i=1}^n f(x_i, \theta)$$

$$I_n(\theta) = - E_p \left[\frac{d^2}{d\theta^2} \log L(x_1^n, \theta) \right]$$

$$= - E_p \left[\sum_{i=1}^n \frac{d^2}{d\theta^2} \log f(x_i, \theta) \right] = - \sum_{i=1}^n E_p \left(\frac{d^2}{d\theta^2} \log f(x_i, \theta) \right) =$$

$$= - \sum_{i=1}^n E_p \left(\frac{d^2}{d\theta^2} \log f(x, \theta) \right) = - n E_p \left(\frac{d^2}{d\theta^2} \log f(x, \theta) \right)$$

$$= n \left[- E_p \left(\frac{d}{d\theta} V_0 \right) \right] = n I_1(\theta).$$

Example: $X \sim N(m, \sigma)$ n consue.

Information sur σ . $f(x, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-m)^2}$

$$I_n(\sigma) = n I_1(\sigma)$$

$$\log f(x, \sigma) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (x-m)^2$$

$$\frac{d}{d\sigma} \log f(x, \sigma) = -\frac{1}{2} \frac{\frac{2\pi \cdot 2\sigma}{\cancel{2\pi} \sigma^2}}{\cancel{2\pi} \sigma^2} - (x-m)^2 \left(-\frac{2\sigma}{2\sigma^3} \right)$$

$$V_0(x) = \frac{(x-m)^2}{\sigma^3} - \frac{1}{\sigma}$$

$$\frac{d}{d\sigma} V_0(x) = -\frac{3(x-m)^2}{\sigma^4} + \frac{1}{\sigma^2}$$

$$E_\sigma \left(\frac{d}{d\sigma} V_0(x) \right) = E \left[\frac{1}{\sigma^2} - \frac{3(x-m)^2}{\sigma^4} \right] = \frac{1}{\sigma^2} - \frac{3}{\sigma^2} E \left(\frac{(x-m)^2}{\sigma} \right) = \frac{1-3}{\sigma^2} = -\frac{2}{\sigma^2}$$

$$\text{Jmc } I_1(\sigma) = -E_\sigma \left(\frac{d}{d\sigma} V_0 \right) = \frac{2}{\sigma^2} \Rightarrow \boxed{I_n(\sigma) = n I_1(\sigma) = \frac{2n}{\sigma^2}}$$